



# CARL VON OSSIEZKY UNIVERSITÄT OLDENBURG

INFORMATIK

BACHELORARBEIT

---

## Vergleich von verschiedenen Deep Reinforcement Learning Agenten am Beispiel des Videospiels Snake

---

*Autor:*

Lorenz Mumm

*Erstgutachter:*

Apl. Prof. Dr. Jürgen Sauer

*Zweitgutachter:*

M. Sc. Julius Möller

Abteilung Systemanalyse und -optimierung

Department für Informatik

Oldenburg, 1. November 2021

# Inhaltsverzeichnis

<b>Abbildungsverzeichnis</b>	<b>v</b>
<b>Tabellenverzeichnis</b>	<b>vi</b>
<b>Abkürzungsverzeichnis</b>	<b>vii</b>
<b>1. Einleitung</b>	<b>1</b>
1.1. Motivation . . . . .	1
1.2. Zielsetzung . . . . .	2
<b>2. Grundlagen</b>	<b>3</b>
2.1. Game of Snake . . . . .	3
2.2. Reinforcement Learning . . . . .	4
2.2.1. Vokabular . . . . .	4
2.2.2. Funktionsweise . . . . .	7
2.2.3. Arten von RL Verfahren . . . . .	8
2.3. Proximal Policy Optimization . . . . .	9
2.3.1. Actor Critic Modell . . . . .	9
2.3.2. PPO Formelelemente . . . . .	10
2.3.3. PPO Fehlerfunktion . . . . .	11
2.3.4. PPO - Algorithmus . . . . .	15
2.4. Deep Q-Network . . . . .	16
2.4.1. DQN – Algorithmus . . . . .	17
<b>3. Anforderungen</b>	<b>19</b>
3.1. Anforderungen an das Environment . . . . .	19
3.1.1. Standardisierte Schnittstelle . . . . .	19
3.1.2. Funktionalitäten . . . . .	19
3.2. Anforderungen an die Agenten . . . . .	20
3.2.1. Funktionalitäten . . . . .	20
3.2.2. Diversität der RL Algorithmen . . . . .	21
3.3. Anforderungen an die Datenerhebung . . . . .	21
3.3.1. Mehrfache Datenerhebung . . . . .	21

3.3.2. Datenspeicherung . . . . .	21
3.4. Anforderungen an die Evaluation . . . . .	22
<b>4. Verwandte Arbeiten</b>	<b>24</b>
4.1. Autonomous Agents in Snake Game via Deep Reinforcement Learning	24
4.1.1. Diskussion . . . . .	26
4.2. UAV Autonomous Target Search Based on Deep Reinforcement Lear- ning in Complex Disaster Scene . . . . .	27
4.2.1. Diskussion . . . . .	28
4.3. Zusammenfassung . . . . .	29
<b>5. Konzept</b>	<b>30</b>
5.1. Vorgehen . . . . .	30
5.2. Environment . . . . .	32
5.2.1. Spiellogik . . . . .	32
5.2.2. Schnittstelle . . . . .	37
5.3. Agenten . . . . .	38
5.3.1. Netzstruktur . . . . .	38
5.3.2. DQN . . . . .	39
5.3.3. PPO . . . . .	42
5.3.4. Vorstellung der zu untersuchenden Agenten . . . . .	43
5.4. Optimierungen . . . . .	45
5.4.1. Optimierung A – Joined Reward Function . . . . .	45
5.4.2. Optimierung B – Anpassung der Lernrate . . . . .	46
5.5. Datenerhebung und Verarbeitung . . . . .	46
5.5.1. Datenerhebung . . . . .	47
5.5.2. Datenverarbeitung und Erzeugung von Statistiken . . . . .	48
<b>6. Implementierung</b>	<b>49</b>
6.1. Snake Environment . . . . .	49
6.2. AV-Network . . . . .	51
6.3. DQN . . . . .	51
6.3.1. Q-Network . . . . .	52
6.3.2. Memory . . . . .	52
6.3.3. Agent . . . . .	52
6.4. PPO . . . . .	53
6.4.1. Actor und Critic . . . . .	54
6.4.2. ActorCritic . . . . .	54
6.4.3. Memory . . . . .	54
6.4.4. Agent . . . . .	55

6.5. Train Methoden . . . . .	56
6.5.1. Test Methoden . . . . .	57
6.6. Statistik . . . . .	58
<b>7. Evaluation</b>	<b>59</b>
7.1. Ergebnisevaluation der Vergleiche . . . . .	59
7.1.1. Evaluation der Baseline Vergleiche . . . . .	59
7.1.2. Evaluation der Optimized Vergleiche . . . . .	64
7.1.3. Bestimmung des optimalen Agenten . . . . .	69
7.2. Anforderungsevaluation . . . . .	69
7.2.1. Anforderungsevaluation der Environment . . . . .	69
7.2.2. Anforderungsevaluation der Agenten . . . . .	70
7.2.3. Anforderungsevaluation an die Datenerhebung . . . . .	70
7.2.4. Anforderungen an die Evaluation . . . . .	71
<b>8. Fazit</b>	<b>72</b>
8.1. Beantwortung der Forschungsfrage . . . . .	72
8.2. Ausblick . . . . .	73
<b>Literaturverzeichnis</b>	<b>75</b>
<b>A. Anhang</b>	<b>78</b>
A.1. Implementierung . . . . .	78

# Abbildungsverzeichnis

2.1. Game of Snake . . . . .	3
2.2. Reinforcement Learning . . . . .	7
5.1. Aktivitätsdiagramm des Vorgehens . . . . .	31
5.2. Spielablauf . . . . .	33
5.3. Observation . . . . .	36
5.4. AV-Network . . . . .	38
5.5. Actor-, Critic- und Q-Net-Tail . . . . .	39
5.6. DQN Aktionsbestimmung . . . . .	40
5.7. Agenten . . . . .	44
6.1. Darstellung der Schnittstellenmethoden in einem Sequenzdiagramm . .	50
6.2. Ablaufdiagramm der action Methode . . . . .	51
6.3. Ablaufdiagramm der train Methode . . . . .	57
7.1. Performance - Auswertung der Trainingsdaten der Baseline Vergleiche	60
7.2. Siegrate- Auswertung der Trainingsdaten der Baseline Vergleiche . .	61
7.3. Robustheit - Auswertung der Testdaten der Baseline Vergleiche . . .	62
7.4. Effizienz - Auswertung der Trainingsdaten der Baseline Vergleiche . .	63
7.5. Effizienz - Auswertung der Testdaten der Baseline Vergleiche . . . .	64
7.6. Performance - Auswertung der Trainingsdaten der Optimized Vergleiche	65
7.7. Siegrate - Auswertung der Trainingsdaten der Optimized Vergleiche .	66
7.8. Robustheit - Auswertung der Testdaten der Optimized Vergleiche . .	67
7.9. Effizienz - Auswertung der Trainingsdaten der Optimized Vergleiche .	68
7.10. Effizienz - Auswertung der Testdaten der Optimized Vergleiche . . .	69
A.1. SnakeEnv Klassendiagramm . . . . .	78
A.2. DQN Klassendiagramm . . . . .	79
A.3. PPO Klassendiagramm . . . . .	80

# Tabellenverzeichnis

2.1. Formelemente des PPO Algorithmus . . . . .	11
3.1. Darstellung der zu erhebende Daten . . . . .	22
3.2. Auflistung der Evaluationskriterien . . . . .	23
5.1. Kodierung der Aktionen im Snake Environment . . . . .	34
5.2. Around_View – Erklärung der Channels . . . . .	35
7.1. Testdatenauswertung der Baseline Vergleiche für die Performance . .	60
7.2. Testdatenauswertung der Baseline Vergleiche für die Siegrate . . . .	62
7.3. Testdatenauswertung der Optimized Vergleiche für die Performance .	65
7.4. Testdatenauswertung der Optimized Vergleiche für die Siegrate . . .	67

# Abkürzungsverzeichnis

**KI** Künstliche Intelligenz

**RL** Reinforcement Learning

**DQN** Deep Q-Network

**DQL** Deep Q-Learning

**DDQN** Double Deep Q-Network

**PPO** Proximal Policy Optimization

**SAC** Soft Actor Critic

**A2C** Advantage Actor Critic

**Env** Environment

**Obs** Observation

**AV** around\_view

**SO** scalar\_obs

# **Kapitel 1**

## **Einleitung**

In dieser Ausarbeitung wird das Generische Maskulinum verwendet. Dieses soll niemanden beleidigen und oder diskriminieren.

Das Machine Learning ist weltweit auf dem Vormarsch und große Unternehmen investieren riesige Beträge, um mit KI basierten Lösungen größere Effizienz zu erreichen. Auch der Bereich des Reinforcement Learning gerät dabei immer mehr in das Blickfeld der Weltöffentlichkeit. Besonders im Gaming Bereich hat das Reinforcement Learning schon beeindruckende Resultate erbringen können, wie z.B. die KI AlphaGO, welche den amtierenden Weltmeister Lee Sedol im Spiel GO besiegt hat (Chunxue u. a., 2019). In Anlehnung an die vielen neuen Reinforcement Learning Möglichkeiten, welche in der letzten Zeit entwickelt wurden und vor dem Hintergrund der immer größer werdenden Beliebtheit von KI basierten Lösungsstrategien, soll es in dieser Bachelorarbeit darum gehen, einzelne Reinforcement Learning Agenten, mittels statistischer Methoden, genauer zu untersuchen und den optimalen Agenten für ein entsprechendes Problem zu bestimmen.

### **1.1. Motivation**

In den letzten Jahren erregte das Reinforcement Learning eine immer größer werdende Aufmerksamkeit. Siege über die amtierenden Weltmeister in den Spielen GO oder Schach führten zu einer zunehmenden Beliebtheit des RL. Weiterhin wurde dieser Effekt durch neue Verfahren, wie z.B. der Deep Q-Network Algorithmus aus dem Jahr 2015 (Mnih u. a., 2015), der Proximal Policy Optimization (PPO) aus dem Jahr 2017 (Schulman u. a., 2017) oder der Soft Actor Critic (SAC) aus dem Jahr 2018 (Haarnoja u. a., 2018), verstärkt. Heutzutage findet das RL auch in anderen Bereichen Anwendung, wie z.B. in der Finanzwelt, im autonomen Fahren usw.

Durch die jedoch große Menge an RL Verfahren gerät man zunehmend in die proble-

matische Situation, sich für einen diskreten RL Ansatz zu entscheiden. Weiter wird dieser Auswahlprozess erschwert durch die Tatsache, dass die einzelnen RL Agenten jeweils untereinander große Unterschiede aufweisen. Auch existieren gelegentlich mehrere Ausprägungen eines RL Algorithmus, so wird z.B. der Deep Q-Network Algorithmus (DQN) durch den Double Deep Q-Network Algorithmus (DDQN) erweitert. Die Wahl des Agenten kann großen Einfluss auf die Performance und andere Bewertungskriterien haben Bowei Ma (2016), deshalb soll in dieser Ausarbeitung ein Vorgehen entwickelt werden, welches, basierend auf einem Vergleich, den optimalen Agenten für ein entsprechendes Problem bestimmt.

Eine potenzielle Umgebung, in welcher Agenten getestet und verglichen werden können, ist das Spiel Snake. Mit der Wahl dieses Spiels ist zusätzlich noch ein weiterer Mehrwert in Erscheinung getreten.

So interpretieren neue Forschungsansätze das Spiel Snake als ein dynamisches Pathfinding Problem. Mit dieser Art von Problemen sind auch unbemannte Drohnen (UAV Drohnen) konfrontiert, welche beispielsweise Menschen in komplexen Katastrophensituationen, wie z.B. auf zerstörten Rohölbohrplattformen, finden und unterstützen sollen. Auch das Liefern von wichtigen Gütern in solche Gebiete zählt zu den Aufgaben dieser Drohnen. Mit der Forschung am Spiel Snake ist es möglich, zumindest einen kleinen Beitrag zu diesem Forschungsfeld zu leisten. (Chunxue u. a., 2019)

## 1.2. Zielsetzung

Basierend auf der Motivation ergibt sich folgende Fragestellung für diese Ausarbeitung

**„Wie kann am Beispiel des Spiels Snake für eine nicht triviale gering dimensionale Umgebung ein möglichst optimaler RL Agent ermittelt werden?“**

Diese Fragestellung zielt darauf ab, für die Umgebung Snake einen möglichst optimalen Agenten zu bestimmen, welcher spezifische Anforderungen erfüllen soll.

Durch Abnahme des Entscheidungsfindungsprozesses müssen Forscher und Anwender von RL Verfahren nicht mehr unreflektiert RL Agenten auswählen, sondern können auf Grundlage der Methodik und der daraus hervorgehenden Daten den passenden Agenten bestimmen.

# Kapitel 2

## Grundlagen

Im folgenden Kapitel soll das grundlegende Wissen, welches zur Untersuchung der Forschungsfrage benötigt wird, vermittelt werden. Dazu sollen verschiedene RL Algorithmen, wie auch die grundlegende Verfahrensweise des RL selbst, thematisiert werden. Zuerst wird sich jedoch mit dem Spiel Snake beschäftigt.

### 2.1. Game of Snake

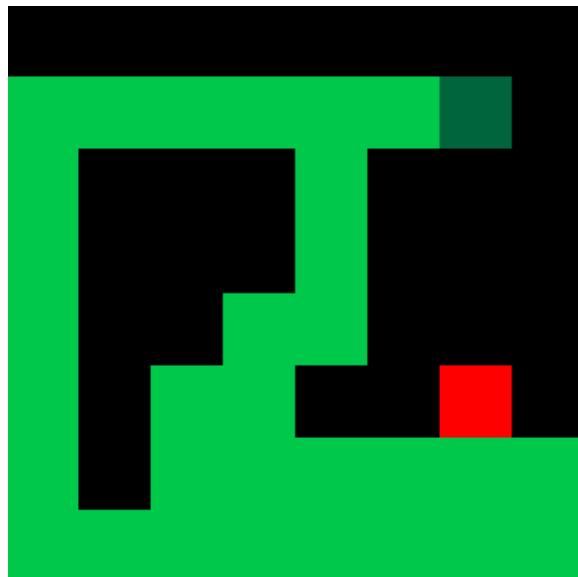


Abbildung 2.1.: Game of Snake – Abbildung eines Snake Spiels, in welchem der Apfel durch das rote und der Snake Kopf durch das dunkelgrüne Quadrat dargestellt wird. Die hellgrünen Quadrate stellen den Schwanz der Snake dar.

Snake zählt zu den bekanntesten Computerspielen unserer Zeit. Es zeichnet sich durch sein simples und einfach zu verstehendes Spielprinzip aus. Das komplette

Spielfeld wird durch eine zweidimensionale Ebene beschrieben, in welcher sich die Snake bewegt. Häufig wird diese als einfacher grüner Punkt (Quadrat) dargestellt. Dieser stellt den Kopf der Snake dar. Neben diesem befindet sich auf dem Spielfeld auch noch der Apfel. Dieser wird häufig als roter Punkt (Quadrat) dargestellt (siehe Abbildung 2.1). Ziel der Snake ist es Äpfel zu fressen, indem der Kopf der Snake auf das Feld des Apfels läuft. Danach verschwindet der Apfel und ein neuer erscheint in einem zufälligen freien Feld. Außerdem wächst, durch das Essen des Apfels, die Snake um ein Schwanzglied. Diese Glieder folgen dabei, in ihren Bewegungen, den vorangegangenen Schwanzglieder bis hin zum Kopf. Dem Spieler ist es nur möglich den Kopf der Snake zu steuern. Diesem ist es nicht erlaubt die Wände oder sich selbst zu berühren. Geschieht dies jedoch im Laufe des Spiels, so wird dieses sofort beendet. Diese Einschränkung führt zu einem Anstieg der Komplexität gegen Ende des Spiels. Ein Spiel gilt als gewonnen, wenn es der Snake gelungen ist das komplette Spielfeld auszufüllen.

## 2.2. Reinforcement Learning

Das Reinforcement Learning (RL) ist einer der drei großen Teilebereiche, des Machine Learning. Das RL wirkt, im Vergleich zu den anderen Disziplinen des Machine Learnings, am nachvollziehbarsten. Dies liegt an der Lernstrategie, welche Anwendung findet. Beim RL wird mithilfe eines „trial-and-error“ Verfahrens gelernt. Ein gutes Beispiel für eine solche Art des Lernens ist die Erziehung eines Kindes. Wenn das Kind etwas Gutes tut, dann wird es belohnt. Angetrieben von der Belohnung, versucht dieses das Verhalten fortzusetzen. Entsprechend wird das Kind bestraft, wenn es etwas Schlechtes tut, sodass schlechtere Verhaltensweisen weniger häufig zum Vorschein kommen, um Bestrafungen zu entgehen. (Sutton und Barto, 2018, S.1 ff.)

Beim RL funktioniert es ganz ähnlich, was auch der Grund dafür ist, dass viele der Aufgaben des RL dem menschlichen Arbeitsspektrum sehr nahe sind. Deshalb findet das RL auch immer mehr Anwendung, im Finanzhandel, in der Robotik, im autonomen Fahren usw. (Lapan, 2020, Kapitel 18)

### 2.2.1. Vokabular

Um ein tiefergehendes Verständnis für das RL zu erhalten, müssen zuerst die Begrifflichkeiten erklärt werden.

## **Agent**

Im Zusammenhang mit dem RL, ist häufig die Rede von Agenten. Sie sind zentrale Instanzen, welche die RL Algorithmen in ein festes Objekt einbinden. Dabei werden Methoden, Hyperparameter und das NN in die Agenten eingebunden. (Lapan, 2020, S. 31) Bei den Agenten handelt es sich gewöhnlich um die einzigen Instanzen, welche mit dem Environment (der Umgebung) interagieren. Zu diesen Interaktionen zählen das Entgegennehmen von Observations und Rewards, wie auch das Übergeben von Aktionen. (Sutton und Barto, 2018, S. 2ff.)

## **Environment**

Das Environment (Env) bzw. die Umgebung ist vollständig außerhalb des Agenten angesiedelt. Es spannt das zu manipulierende Umfeld auf, in welchem der Agent Interaktionen tätigen kann. An ein Environment werden unter anderem verschiedene Ansprüche gestellt, damit ein RL Agent mit ihm in Interaktion treten kann. Zu diesen gehören die Fähigkeiten Observations und Rewards zu liefern, sowie Aktionen zu verarbeiten. (Lapan, 2020; Sutton und Barto, 2018, S. 31 & S.2 ff.)

## **Action**

Die Actions bzw. Aktionen sind einer der drei Datenübermittlungswege. Bei ihnen handelt es sich um Handlungen, welche im Env ausgeführt werden. Aktionen können z.B. Züge in Spielen, das Abbiegen im autonomen Fahren oder das Ausfüllen eines Antrages sein. Es wird ersichtlich, dass die Aktionen, welche ein RL Agent ausführen kann, prinzipiell nicht in der Komplexität beschränkt sind. Dennoch ist es gängige Praxis geworden, dass diese möglichst einfach gestaltet werden sollen.

Im Environment wird zwischen diskreten und stetigen Aktionsräumen unterschieden. Der diskrete Aktionsraum umfasst eine endliche Menge an sich gegenseitig ausschließenden Aktionen. Ein Beispiel dafür wäre das Gehen an einer T-Kreuzung. Der Agent kann entweder Links, Rechts oder zurück gehen. Anders verhält es sich bei einem stetigen Aktionsraum. Dieser zeichnet sich durch stetige Werte aus. Das Steuern eines Autos wäre hierfür beispielhaft. Es stellen sich Fragen, wie z.B. um wie viel Grad muss der Agent das Steuer drehen und um wie viel Prozent muss er bremsen, damit das Fahrzeug in der Spur bleibt? (Lapan, 2020, S. 31 f.)

## **Observation**

Die Observation (Obs) bzw. die Beobachtung ist ein weiterer Datenübermittlungs- weg, welche den Agenten mit dem Env verbindet. Bei dieser handelt es sich um einen

oder mehrere Vektoren bzw. Matrizen, welche dabei den momentanen Zustand des Environments repräsentieren. (Sutton und Barto, 2018, S. 381)

Je nach Anwendungsbereich, fällt die Obs sehr unterschiedlich aus. In der Finanzwelt könnte diese z.B. die neusten Börsenkurse beinhalten oder in der Welt der Spiele könnte die aktuelle Punktezahl wiedergeben werden. (Lapan, 2020, S. 32)

### Reward

Der Reward bzw. die Belohnung ist der letzte Datenübertragungsweg. Bei diesem handelt es sich um einen einfachen skalaren Wert, welche vom Env übermittelt wird. Dieser gibt an, wie gut bzw. schlecht eine ausgeführte Aktion im Env war. (Sutton und Barto, 2018, S. 42)

Um eine solche Einschätzung zu tätigen, ist es nötig eine Bewertungsfunktion zu implementieren, welche den Reward bestimmt.

### State

Der State bzw. Zustand ist eine Widerspiegelung der zum Zeitpunkt  $t$  vorherrschenden Situation im Env. Dieser wird von der Obs (Observation) repräsentiert. Häufig findet sich der Begriff des State in der Fachliteratur und in anderen Ausarbeitungen zu diesem Themengebiet. (Sutton und Barto, 2018, s. 381 ff.)

### Policy

Informell lässt sich die Policy als eine Menge von Regeln beschreiben, welche das Verhalten eines Agenten steuern. Formal ist die Policy  $\pi$  als eine Wahrscheinlichkeitsverteilung über alle möglichen Aktionen  $a$  im State  $s$  des Env definiert. (Lapan, 2020, S. 44)

Sollte daher ein Agent der Policy  $\pi_t$  zum Zeitpunkt  $t$  folgen, so entspricht  $\pi_t(a_t|s_t)$  der Wahrscheinlichkeit, dass die Aktion  $a_t$  im State  $s_t$  gewählt wird. (Sutton und Barto, 2018, S. 45 ff.)

### Value

Die Values geben eine Einschätzung ab, wie gut oder schlecht ein State bzw. State-Action-Pair ist. Sie werden gewöhnlich mit einer Value Funktion  $V$  bestimmt, sodass beispielsweise  $V(s)$  dem Wert des States  $s$  gleichkommt. Der Value entspricht dabei der diskontierten Summe aller noch zu erwartenden Rewards in der verbleibenden Spielepisode. Damit ist dieser ein Maß dafür, wie gut es für den Agenten ist, in diesen State zu wechseln.

Der sogenannte Q-Value  $Q(s, a)$  gibt Aufschluss darüber, welche Aktion  $a$  im State  $s$  den größten Return (Summe aller diskontierten Rewards in der noch verbleibenden Spielepisode) erzielen wird.

Die Values werden ebenfalls unter einer Policy (Regelwerk des Agenten) bestimmt, daher folgt, dass für die Value Funktionen  $V_\pi(s)$  und  $Q_\pi(s, a)$ ,  $\pi$  die Policy ist. (Sutton und Barto, 2018, S. 46)

## 2.2.2. Funktionsweise

Die folgende Beschreibung der Funktionsweise orientiert sich an der Abbildung 2.2.

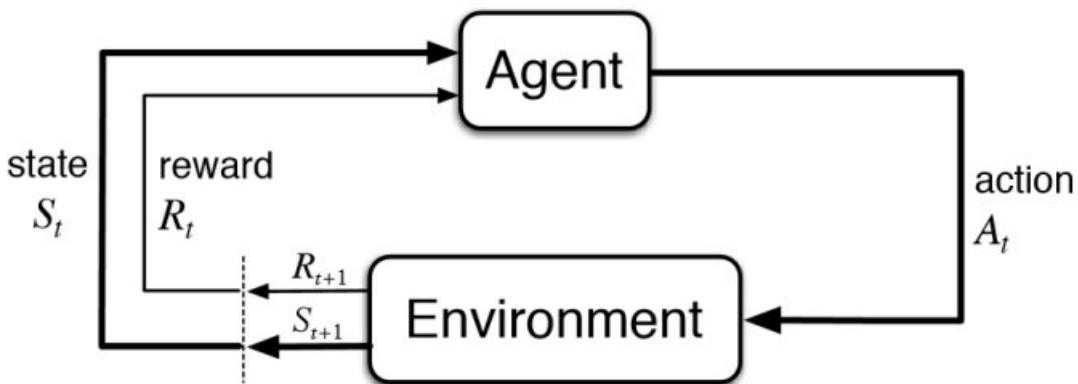


Abbildung 2.2.: Schematische Funktionsweise des Reinforcement Learning – Der Agent erhält einen state  $S_t$  und falls  $t \neq 0$  einen reward  $R_t$ . Daraufhin wird vom Agenten eine action  $A_t$  ermittelt, welche im Env ausgeführt wird. Das Env übermittelt den neuen state  $S_{t+1}$  und reward  $R_{t+1}$  an den Agenten. Diese Prozedur wird wiederholt. Bildquelle: (Sutton und Barto, 2018, S. 38)

Zu Beginn wird dem Agenten vom Env der initialer State  $S_{t=0}$  übermittelt, welcher einen Entscheidungsfindungsprozess anstößt. Es wird eine Aktion  $A_t$  ermittelt, welche an das Env weiterleitet und dort ausgeführt wird. Das manipulierte Env befindet sich nun im neuen State  $S_{t+1}$ , welcher an den Agenten weitergeleitet wird. Des Weiteren bestimmt und sendet das Env noch einen Reward  $R_{t+1}$ . Mit dem neuen State  $S_{t+1}$ , kann der Agent wieder eine Aktion  $A_{t+1}$  bestimmen, welche ausgeführt wird. Daraufhin werden wieder der neue State  $S_{t+2}$  und Reward  $R_{t+2}$  ermittelt und übertragen. (Sutton und Barto, 2018, S. 37 ff.)

### 2.2.3. Arten von RL Verfahren

Nachdem das Basisvokabular erklärt wurde, soll nun ein tieferer Blick in die verschiedenen Arten des RL geworfen werden.

Alle RL Verfahren lassen sich, in Klassen einordnen, welche Aufschluss über verschiedene Details des Algorithmus geben. Es existieren natürlich viele Möglichkeiten RL Verfahren zu klassifizieren, aber vorerst soll sich auf die folgenden zwei beschränkt werden. Diese bieten sich an, da sie zum einen gängiger Standard sind und zum anderen die verwendeten Agenten ideal klassifizieren.

#### Policy-Based und Value-Based Verfahren

Die Einordnung in policy-based und value-based Verfahren gibt Aufschluss über den Entscheidungsfindungsprozess des RL Verfahrens. Policy-Based Agenten versuchen unmittelbar die Policy zu berechnen, umzusetzen und sie zu optimieren. Sie besitzen dafür meist ein eigenes NN, welches die Policy  $\pi$  für einen State  $s$  bestimmt. Gewöhnlich wird diese als eine Wahrscheinlichkeitsverteilung über alle Aktionen angegeben (siehe Unterunterabschnitt 2.2.1). Jede Aktion erhält damit einen Wert zwischen null und eins, welcher Aufschluss über die Qualität der Aktion im momentanen Zustand des Env liefert. (Lapan, 2020, S. 100)

Basierend auf dieser Wahrscheinlichkeitsverteilung  $\pi$  wird die nächste Aktion  $a$  bestimmt. Dabei wird nicht immer die optimale Aktion gewählt, um die Exploration voranzutreiben.

Die value-based Verfahren bestimmen ihre Aktionen nicht mit einer Wahrscheinlichkeitsverteilung. Die Policy wird indirekt durch das Bestimmen aller Values, (siehe Unterunterabschnitt 2.2.1) für alle Aktionen, ermittelt. Es wird daher immer die Aktion  $a$  gewählt, welche zu dem State  $s^*$  führt, der über den größten Value verfügt. (Lapan, 2020, S. 100)

#### On-Policy und Off-Policy Verfahren

Eine Klassifikation in on-policy und off-policy Verfahren gibt Aufschluss über den Zustand der Daten.

Off-Policy RL Verfahren sind in der Lage, von Daten zu lernen, welche nicht unter der momentanen Policy (siehe Unterunterabschnitt 2.2.1) generiert wurden. Die Aktualität der Daten spielt daher keine Rolle für dieses RL Verfahren.

On-Policy RL Verfahren sind dagegen sehr wohl abhängig von der Aktualität der Daten, da sie versuchen die Policy indirekt oder direkt zu optimieren. Sollte ein on-policy Agent mit veralteten Daten trainiert werden, so würde dies die Policy des Agenten in negativer Weise beeinflussen. (Lapan, 2020, S. 210 f.)

Nach diesen Einordnungen sollen nun die ausgewählten Algorithmen näher erklärt werden. Begonnen wird mit dem Proximal Policy Optimization Algorithmus (PPO).

## 2.3. Proximal Policy Optimization

Der Proximal Policy Optimization Algorithmus (PPO) wurde von dem Open-AI-Team entwickelt. Im Jahr 2017 erschien das gleichnamige Paper, welches den Aufbau und die Umsetzung des Algorithmus genauer erläutert. (Schulman u. a., 2017)

Agenten, welche auf dem PPO Algorithmus basieren, konnten in der Vergangenheit bereits durch gute Leistungen überzeugen.

Um einen groben Überblick des Algorithmus zu erhalten, werden zuerst, im nächsten Abschnitt, dessen Architektur und Vorläufer näher thematisiert.

### 2.3.1. Actor Critic Modell

Der PPO Algorithmus ist ein policy-based (siehe Unterunterabschnitt 2.2.3) RL Verfahren, welches, im Vergleich zu anderen Verfahren, einige Verbesserungen aufweist. So ist der PPO eine Weiterentwicklung normaler Policy Gradient Verfahren und basiert intern auf dem sogenannten Actor bzw. Policy Network und auf dem Critic bzw. Value Network. (Sutton und Barto, 2018, S. 273 f.)

Beide neuronalen Netzwerke können aus mehreren Schichten bestehen, jedoch sind Actor und Critic streng voneinander getrennt und besitzen mit einer Ausnahme keine gemeinsamen Parameter. Gelegentlich werden jedoch beiden Netzen (Actor bzw. Critic) noch ein weiteres Netz vorgeschoben. In diesem Ausnahmefall können Actor und Critic gemeinsame Parameter besitzen.

Das Actor Network ist für die Bestimmung der Policy zuständig. Anders als bei value-based (siehe Unterunterabschnitt 2.2.3) RL Verfahren, wird diese direkt bestimmt und kann auch direkt angepasst werden. Die Policy wird als eine Wahrscheinlichkeitsverteilung über alle möglichen Aktionen vom Actor Network zurückgegeben. (siehe Unterunterabschnitt 2.2.1)

Das Critic bzw. Value Network evaluiert die Aktionen, welche vom Actor Network bestimmt worden sind. Genauer gesagt, schätzt das Value Network den sogenannten Return bzw. die Discounted Sum of Rewards (siehe Unterunterabschnitt 2.3.3) zu einem Zeitpunkt  $t$ , basierend auf dem momentanen State  $s$ . Auf dieser Architektur wird ein PPO Agent aufgebaut.

Neben der Architektur, ist die Aktualisierungsprozedur ein weiterer wichtiger Bestandteil des Algorithmus. Diese wird daher im Folgenden näher betrachtet.

### 2.3.2. PPO Formelelemente

Das Herzstück eines jeden RL Verfahrens wird durch seine Aktualisierungsprozedur dargestellt, in welcher der Fehler (Loss) des Algorithmus bestimmt wird. Um die dem PPO zugrunde liegende Aktualisierungsprozedur besser zu verstehen, folgt eine Erklärung ihrer einzelnen mathematischen Bestandteile. Diese basieren auf den PPO Paper (Schulman u. a., 2017).

Symbol	Erklärung
$t$	Zeitpunkt
$\hat{\mathbb{E}}[X]$	$\hat{\mathbb{E}}[X]$ ist der Erwartungswert einer zufälligen Variable $X$ , z.B. $\hat{\mathbb{E}}[X] = \sum_x p(x)x$ . (Sutton und Barto, 2018, Summary of Notation S. xv)
$\theta$	Theta beschreibt die Parameter, aus denen sich die Policy des PPO ergibt. Sie sind die Gewichte, welche das Policy Network definiert.
$\pi_\theta$	Die Policy bzw. Entscheidungsfindungsregeln sind eine Wahrscheinlichkeitsverteilung über alle möglichen Actions. Eine Aktion $a$ wird auf Basis der Wahrscheinlichkeitsverteilung gewählt (siehe (Sutton und Barto, 2018, Summary of Notation S. xvi) und Unterunterabschnitt 2.2.1).
$L^{\text{CLIP}}(\theta)$	$L^{\text{CLIP}}(\theta)$ bezeichnet den sogenannten Policy bzw. Actor Fehler, welche in Abhängigkeit zu der Policy $\pi_\theta$ steht. Dabei handelt es sich um einen Zahlenwert, welcher den Fehler über alle Parameter approximiert. Dieser wird für das Lernen des Actor Networks benötigt.
$r_t(\theta)$	$r_t(\theta)$ stellt den Quotienten zwischen alter Policy (nicht als Abhängigkeit angegeben, da sie nicht verändert wird) und aktueller Policy zum Zeitpunkt $t$ dar. Daher auch Probability Ratio genannt.
$\hat{A}_t(s, a)$	Erwarteter Vorteil bzw. Nachteil einer Aktion $a$ , welche im State $s$ ausgeführt wurde.
clip	Mathematische Funktion zur Beschneidung eines Eingabewertes. Clip setzt eine Ober- und Untergrenze fest. Sollte ein Wert, der dieser Funktion übergeben wird, sich nicht mehr innerhalb der Grenzen befinden, so wird der jeweilige Grenzwert zurückgegeben.
$\epsilon$	Epsilon ist ein Hyperparameter, welcher die Ober- und Untergrenze der Clip Funktion festlegt. Gewöhnlich wird für $\epsilon$ ein Wert zwischen 0.1 und 0.2 gewählt.

$\gamma$	Der Gamma-Wert bzw. Abzinsungsfaktor ist ein Hyperparameter, welcher die Zeitpräferenz des Agenten kontrolliert. Gewöhnlich liegt Gamma $\gamma$ zwischen 0.9 bis 0.99. Große Werte sorgen für ein weitsichtiges Lernen des Agenten, wohingegen kleine Werte zu einem kurzfristigen Lernen führen (Sutton und Barto, 2018, S. 43 bzw. Summary of Notation S. xv).
----------	---

Tabelle 2.1.: Formelemente des PPO Algorithmus

### 2.3.3. PPO Fehlerfunktion

Da die Grundlagen näher beleuchtet worden sind, ist das nächste Ziel die Fehlerfunktion des PPO zu verstehen, damit diese angewendet werden kann. Der PPO Fehler wird durch folgende Funktion definiert (Schulman u. a., 2017, S. 5):

$$L_t^{\text{PPO}}(\theta) = L_t^{\text{CLIP}} + \text{VF} + \text{S}(\theta) = \hat{\mathbb{E}}_t[L_t^{\text{CLIP}}(\theta) - c_1 L_t^{\text{VF}} + c_2 S[\pi_\theta](s_t)] \quad (2.1)$$

Dabei besteht die Fehlerfunktion aus dem Actor Fehler  $L_t^{\text{CLIP}}(\theta)$ , aus dem Critic Fehler  $L_t^{\text{VF}}$  und aus dem Entropy Fehler bzw. Bonus  $S[\pi_\theta](s_t)$ . Der Actor Fehler ist dabei durch folgenden Term gegeben (Schulman u. a., 2017, S. 3):

$$L_t^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t[\min(r_t(\theta)\hat{A}_t(s, a), \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)\hat{A}_t(s, a))] \quad (2.2)$$

Dieser wird im Weiteren kleinschrittig erklärt. Begonnen wird mit dem Advantage  $\hat{A}_t(s, a)$ , welcher sich aus dem Return und dem Baseline Estimate berechnet.

#### Return

Der Return  $R_t$  stellt die diskontierte Summe der Rewards in der vom Zeitpunkt  $t$  an verbleibenden Spieldiode dar. Die einzelnen Rewards werden dabei mit dem Discount Factor  $\gamma$  multipliziert (siehe Tabelle 2.1), um die Zeitpräferenz des Agenten besser zu steuern. Gamma  $\gamma$  liegt dabei gewöhnlich zwischen einem Wert von 0.9 bis 0.99. Kleine Werte für Gamma sorgen dafür, dass der Agent eher dazu tendiert Aktionen zu wählen, welche unmittelbar zu positiven Rewards führen. Entsprechend verhält es sich mit großen Werten für Gamma  $\gamma$ . (Sutton und Barto, 2018, S. 42 ff.) Für die Bestimmung des Advantage benötigt man neben dem Return jedoch auch noch den Baseline Estimate Wert.

## Baseline Estimate

Der Baseline Estimate Wert  $b(s_t)$  ist das Ergebnis der Value Funktion (siehe Unterabschnitt 2.2.1), welche durch das Critic Network (siehe Unterabschnitt 2.3.1) realisiert wird. Die Value Funktion schätzt den noch zu erwartenden Return  $R_t$ , vom aktuellen State  $s_t$  an. Da es sich hierbei um die Ausgabe eines NN handelt, wird in dieser immer eine Varianz bzw. ein Rauschen vorhanden sein. (Mnih u. a., 2016, Kapitel 3)

Mit diesem letzten Wert lässt sich nun der Advantage bestimmen.

## Advantage

Der Advantage  $\hat{A}_t(s, a)$  stellt einen Funktionsbestandteil des Actor Fehlers dar. Dieser wird durch die Subtraktion des Returns  $R_t$  mit dem Baseline Estimate Wert  $b(s_t)$  bestimmt. Die folgende Formel (siehe Gleichung 2.3) ist eine zusammengefasste Version der Originalformel aus (Schulman u. a., 2017):

$$\hat{A}_t(s, a) = R_t - b(s_t) \quad (2.3)$$

Der Advantage gibt an, um wie viel besser oder schlechter eine Aktion gewesen ist, basierend auf der Erwartung der Value Funktion des Critics. Es wird also die Frage beantwortet, ob eine gewählte Aktion  $a$  im Zustand  $s_t$  zum Zeitpunkt  $t$  besser oder schlechter als erwartet war. (Mnih u. a., 2016, Kapitel 3)

Um nun den ersten Surrogate Fehler, welcher im Weiteren noch thematisiert wird (siehe Unterunterabschnitt 2.3.3), zu bestimmen, wird noch die Probability Ratio benötigt.

## Probability Ratio

Die Probability Ratio  $r_t(\theta)$  ist der nächste Funktionsbestandteil des  $L_t^{\text{CLIP}}(\theta)$  (siehe Gleichung 2.2). In normalen Policy Gradient Methoden besteht ein Problem zwischen der effizienten Datennutzung und der Aktualisierung der Policy. Dieses Problem tritt z.B. im Zusammenhang mit dem Advantage Actor Critic (A2C) Algorithmus auf und reglementiert die effiziente Nutzung von Daten. So ist es dem A2C nur möglich von Daten zu lernen, welche on-policy (siehe Unterunterabschnitt 2.2.3) erzeugt wurden. Der PPO umgeht diese Problematik jedoch partiell durch das Importance-Sampling (IS, deutsch: Stichprobenentnahme nach Wichtigkeit). Bei der Fehlerfunktion des A2C Algorithmus (siehe Gleichung 2.4) wird deutlich,

$$\hat{\mathbb{E}}_t[\log_{\pi_\theta}(a_t|s_t) A_t] \quad (2.4)$$

dass die Daten für die Fehlerbestimmung nur unter der aktuellen Policy  $\pi_\theta$  generiert wurden (on-policy) (Lapan, 2020, S. 591).

Schulman et al. ist es jedoch gelungen, diesen Ausdruck durch einen approximalen Ersatzausdruck zu ersetzen, welcher auf zwei Policies basieren kann. Eine davon stellt die aktuelle  $\pi_\theta$  und die andere eine ältere  $\pi_{\theta_{\text{old}}}$  dar.

$$r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)} \quad (2.5)$$

Die Daten können nun mittels  $\pi_{\theta_{\text{old}}}$ , effizienter genutzt werden, da sie nun nicht mehr aus der aktuellen Policy stammen müssen. Dies erlaubt ein häufigeres Nutzen der Daten, ohne einen negativen Einfluss auf die Policy zu riskieren. (Schulman, 2017, Zeitpunkt: 9:25)

### **Surrogate Fehlerfunktion**

Die Surrogate Fehlerfunktionen ergeben sich aus der Tatsache, dass die Fehlerfunktion des PPO nicht mit der gewöhnlich verwendeten logarithmierten Policy  $\hat{\mathbb{E}}_t[\log_{\pi_\theta}(a_t|s_t)A_t]$  arbeitet, sondern mit dem Surrogate (Ersatz) der Probability Ratio  $r_t(\theta)$  (siehe Unterunterabschnitt 2.3.3) zwischen alter und neuer Policy. (Schulman u. a., 2015)

Der Actor Fehler wird mithilfe zweier Surrogate Fehlerfunktionen bestimmt. Die erste Fehlerfunktion  $surr_1$  (siehe Gleichung 2.6)

$$r_t(\theta)\hat{A}_t(s, a) \quad (2.6)$$

stellt die normale TRPO Schulman u. a. (2015) Fehlerfunktion dar, ohne die durch den TRPO Algorithmus vorgesehene KL-Penalty. Diese sorgt dafür, dass sich die Policy des TRPO nicht zu weit von der ursprünglichen entfernt. Die erste Fehlerfunktion  $surr_1$  kann sich daher weit von der ursprünglichen Policy entfernen. (Schulman u. a., 2017, S. 3 f.)

Die alleinige Nutzung dieser Funktion hätte jedoch destruktiv große Policy Aktualisierungen zufolge. Aus diesem Grund haben John Schulman et al. eine zweite Surrogate Fehlerfunktion  $surr_2$  (siehe Gleichung 2.7), dem PPO Algorithmus hinzugefügt.

$$\text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)\hat{A}_t(s, a) \quad (2.7)$$

Die einzige Veränderung dieser Funktion im Vergleich zur Ersten ist, dass der berechnete Fehler geclipped (abgegrenzt) wird. Sollte sich die Probability Ratio zu

weit von eins entfernen, so wird  $r_t(\theta)$  entsprechend auf  $1 - \epsilon$  bzw.  $1 + \epsilon$  begrenzt. Es wird sich daher in einer Trust Region bewegt, da man sich nie allzu weit von der ursprünglichen Policy entfernt. (Schulman u. a., 2015, 2017)

### Zusammenfassung der Actor Fehlerfunktion

Der Actor Fehler lässt sich nun für jede Erfahrung, welche gesammelt wurde, bestimmen. Dabei wird das Minimum der beiden Surrogate Fehlerfunktionen ausgewählt und als Fehler zurückgegeben (siehe Gleichung 2.8).

$$\min(r_t(\theta)\hat{A}_t(s, a), \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)\hat{A}_t(s, a)) \quad (2.8)$$

Da für das Lernen immer mehrere Erfahrungen genutzt werden, wird der empirische Durchschnittsfehler bestimmt. Dies wird durch  $\hat{\mathbb{E}}_t$  impliziert. Somit ergibt sich die Actor Fehlerfunktion (siehe Gleichung 2.2). (Schulman u. a., 2017, S. 3f.)

### Zusammenfassung der PPO Fehlerfunktion

Zum Schluss wird die PPO Fehlerfunktion definiert. Damit dies jedoch geschehen kann, muss vorher noch der Critic  $L_t^{\text{VF}}$  und Entropie Fehler  $S[\pi_\theta](s_t)$  bestimmt werden. Die Critic Fehlerfunktion setzt sich folgendermaßen zusammen:

$$L_t^{\text{VF}} = (V_\theta(s_t) - V_t^{\text{targ}})^2 \text{ wobei } V_t^{\text{targ}} = r_t(\theta) \quad (2.9)$$

Der letzte Teil, welcher für die Bestimmung der PPO Fehlerfunktion benötigt wird, ist der Entropy Fehler bzw. Bonus. Dabei handelt es sich um die Entropie der Policy (Wahrscheinlichkeitsverteilung (siehe Unterunterabschnitt 2.2.1)), welche mit der Shannon Entropie bestimmt wird. Diese ist wie folgt definiert (Shannon, 1948):

$$H(X) = - \sum_{i=0}^n P(x_i) \log_b P(x_i) \quad (2.10)$$

Dabei ist  $-\log_b P(x_i)$  als der Informationsgehalt mit  $b$  als Basis des Logarithmus und  $P_i$  ist als Wahrscheinlichkeit definiert. Als Basis wird häufig zwei oder zehn verwendet. Sollte beispielsweise die Policy definiert sein als  $p = (0.95, 0.05, 0.05)$  dann lässt sich eine Entropie von  $-(0.95 \times \log_2(0.95) + 0.05 \times \log_2(0.05) + 0.05 \times \log_2(0.05)) \approx 0.5025$  berechnen.

Es ergibt sich damit der bereits oben erwähnte PPO Training Loss (siehe Gleichung 2.1), wobei

$$L_t^{\text{PPO}}(\theta) = L_t^{\text{CLIP}} + \text{VF} + \text{S}(\theta) = \hat{\mathbb{E}}_t[L_t^{\text{CLIP}}(\theta) - c_1 L_t^{\text{VF}} + c_2 S[\pi_\theta](s_t)]$$

$c_1$  und  $c_2$  Steuerungsfaktoren zur Regulierung der Fehlerhöhe sind.

Um den PPO Algorithmus mit seiner Fehlerfunktion richtig anwenden zu können, wird im Weiteren noch der Algorithmus näher erklärt.

### 2.3.4. PPO - Algorithmus

Um die Theorie in die Praxis zu überführen, soll der Algorithmus komprimiert dargestellt werden, damit dieser später umgesetzt werden kann. Diese Darstellung basiert dabei auf der Quelle (Schulman u. a., 2017) und einigen weiteren Anpassungen.

1. Initialisiere alle Hyperparameter und die neuronalen Netzwerke für Actor und Critic mit den Gewichten  $\theta$  bzw.  $w$ . Erstelle einen Experience Buffer  $EB$ .
2. Bestimme mit dem Zustand  $s$  und dem Actor Network eine Aktion  $a$ . Dies geschieht durch  $\pi_\theta(s)$ .
3. Führe Aktion  $a$  aus und ermittle den Reward  $r$  und den Folgezustand  $s'$ .
4. Speichere Zustand, Aktion, Policy der Aktion, Reward und is\_terminal in  $EB$ .
5. Ersetze den Zustand mit dem Folgezustand  $s' \rightarrow s$ .
6. Wiederhole alle Schritte ab Schritt zwei, bis die Spielepisode endet.
7. Entnehme einen Batch aus dem EB.
8. Bestimmt die Ratios  $r_t(\theta)$ . (siehe Unterunterabschnitt 2.3.3).
9. Berechne die Advantages  $\hat{A}_t(s, a)$ . (siehe Unterunterabschnitt 2.3.3).
10. Berechne die Surrogate Fehler (siehe Unterunterabschnitt 2.3.3)  $surr_1$  und  $surr_2$ .
11. Bestimme den PPO Fehler. (siehe Unterunterabschnitt 2.3.3)
12. Aktualisiere die Gewichte des Actors und Critics mit Adam Optimizer (Schulman u. a., 2017).  $\theta_{\text{old}} \leftarrow \theta$  und  $w_{\text{old}} \leftarrow w$ .
13. Wiederhole alle Schritte ab Schritt sieben  $K$ -mal.  $K$  stellt ein Hyperparameter dar.
14. Wiederhole alle Schritte ab Schritt zwei erneut, bis das Verfahren konvergiert.

Neben dem PPO Algorithmus soll auch noch ein weiterer behandelt werden. Der DQN Algorithmus wird im Folgenden vorgestellt.

## 2.4. Deep Q-Network

Der DQN (Deep Q-Network-Algorithmus) ist ein weiterer Reinforcement Learning Algorithmus, welcher auf einer ihm zugrunde liegenden Formel basiert. Er hat bereits große Erfolge erzielen können, besonders im Gaming Bereich (Mnih u. a., 2013). Daher erscheint es auch nicht weiter verwunderlich, dass sich dieser Algorithmus einer großen Beliebtheit erfreut. Unter anderem wurden aus diesem Grund bereits viele Erweiterungen implementiert, wie der DDQN (Double Deep Q-Network) oder der DQN mit verrauschten Netzen usw.

Basierend auf seiner großen Beliebtheit ergibt sich die Frage, ob der DQN dieser auch gerecht wird? Diese Frage lässt sich am besten mit einem Vergleich beantworten, was diesen Algorithmus zu einem guten Kandidaten für diesen macht.

Angestrebtes Ziel aller Q-Learning-Algorithmen ist es, jedem State-Action-Pair  $(s, a)$  (Zustands-Aktions-Paar), einem Aktionswert (Q-Value)  $Q$  zuzuweisen (Lapan, 2020, S. 126). Dies ist beispielsweise über eine Tabelle möglich, was jedoch bei komplexen Environments schnell ineffizient wird. Ein weiterer Ansatz sind NN, welche die Q-Value Funktion nachbilden und erlernen können.

Ein Einsicht in die Logik des Algorithmus eröffnet dahingehend einen besseren Überblick. So ist die Idee von vielen RL Verfahren, die Aktionswert Funktion mithilfe der Bellman Gleichung iterativ zu bestimmen. Daraus ergibt sich die folgende Formel (Mnih u. a., 2013)

$$Q_{i+1}(s, a) = \mathbb{E} \left[ r + \gamma \max_{a'} Q_i(s', a') | s, a \right] \quad (2.11)$$

wobei,  $Q_{i+1}(s, a)$  den  $i + 1$  aktualisierten Aktionswert der Aktion  $a$  im Zustand  $s$  darstellt. Die iterativ angewendete Bellman Gleichung (siehe Gleichung 2.11) besagt daher, dass die Aktionswert Funktion  $Q$  dem empirischen Durchschnitt aller iterativen Aktualisierungen entspricht. In der Theorie konvergiert ein solches Iterationsverfahren  $Q_i \rightarrow Q^*$  jedoch nur, wenn  $i$  gegen unendlich läuft  $i \rightarrow \infty$ , wobei  $Q^*$  die optimale Aktionswert Funktion darstellt. Da dies jedoch nicht möglich ist, muss  $Q^*$  approximiert werden  $Q(s, a; \theta) \approx Q^*$ . Dies geschieht mittels eines NN. Damit dieses nicht ausschließlich zufällige Q-Values ermittelt, ist eine Anpassung der Gewichte nötig. Dafür muss jedoch zuerst der Fehler des DQN Algorithmus bestimmt werden, was mithilfe der Fehlerfunktionen geschieht. Diese ist wie folgt definiert (Lapan, 2020, S.146 f.):

$$L(\theta) = \mathbb{E} \left[ ((r(s, a) + \gamma \max_{a'} Q(s', a')) - Q(s, a))^2 \right] \quad (2.12)$$

Die Formel (siehe Gleichung 2.12) besagt, dass der Fehler eines zufällig ausgesuchten State-Action Tupels  $(s, a)$  sich wie folgt zusammensetzt. Der Fehler ist die Differenz aus dem Aktionswert  $Q(s, a)$ , welcher Aufschluss über den, in dieser Episode, zu erwartenden Reward liefert und  $y_i$ . Dabei ist  $y_i$  der Reward, welcher durch die Ausführung der Aktion  $a$  im Zustand  $s$  erzielt wurde, addiert mit dem maximalen Q-Value der Folgeaktion  $a'$  im Folgezustand  $s'$ .

Da  $Q(s, a)$  rekursiv definiert werden kann, ergibt sich in vereinfachter Form (Lapan, 2020, S.126 und S. 146 f.):

$$Q(s, a) = r + \gamma \max_{a' \in A} Q(s', a') = \mathbb{E}[r + \gamma \max_{a'} Q(s', a'; \theta) | s, a] = y_i \quad (2.13)$$

Es wird erkenntlich, dass  $Q(s, a)$  dem Q-Target  $y_i$  entsprechen soll  $Q(s, a) \rightarrow y_i$  (siehe Gleichung 2.13). Darum wird die Differenz zwischen beiden bestimmt und als Fehler deklariert. Dieser wird noch quadriert, damit er stets positiv ist. (siehe Gleichung 2.12)

Mit diesem berechneten Fehler werden dann die NN Parameter  $\theta$  aktualisiert  $\theta_i \rightarrow \theta_{i+1}$ .

#### 2.4.1. DQN – Algorithmus

Zur besseren Anwendbarkeit haben Volodymyr Mnhi et al. einen Algorithmus entworfen, welcher den DQN anschaulich erklärt (Mnih u. a., 2013). Da jedoch in diesem Algorithmus weiterhin auf Teile der Fehlerfunktion eingegangen wird, folgt eine bereinigte Version, welche sich auch für den allgemeinen Gebrauch besser anbietet. (Lapan, 2020, S. 149 f.)

1. Initialisiere alle Hyperparameter des Q-Network mit zufallsbasierten Gewichten. Setzte Epsilon  $\epsilon = 1.00$  und erzeuge einen leeren Experience Buffer  $EB$ .
2. Wähle mit der Wahrscheinlichkeit  $\epsilon$  eine zufällige Aktion  $a$  oder nutze  $a = \arg \max_a Q(s, a)$ .
3. Führe Aktion  $a$  aus und ermittle den Reward  $r$  und den Folgezustand  $s'$ .
4. Speicher Zustand  $s$ , Aktion  $a$ , Reward  $r$  und Folgezustand  $s'$ .
5. Reduziere  $\epsilon$ , sodass die Wahrscheinlichkeit eine zufällige Aktion zu wählen minimiert wird. Gewöhnlich existiert eine untere Grenze für  $\epsilon$ , sodass immer noch einige wenige Aktionen zufällig gewählt werden.
6. Entnehme zufallsbasiert einen Batch aus dem Experience Buffer  $EB$ .
7. Berechne  $y = r + \gamma \max_{a \in A} Q(s', a')$ .

8. Berechne den Fehler  $\mathbb{L} = (Q(s, a) - y)^2$ .
9. Aktualisiere die Aktionswertfunktion  $Q_{\theta_i}$  mithilfe von Gradientenabstiegsverfahren  $Q_{\theta_i} \rightarrow Q_{\theta_{i+1}}$ .
10. Wiederhole alle Schritte von Schritt zwei an, bis sich eine Konvergenz einstellt.

# Kapitel 3

## Anforderungen

In Kapitel 2 wurden Grundlagen für die weiteren Vergleiche der Reinforcement Learning Agenten gelegt, welche auf zwei unterschiedlichen Algorithmen (DQN und PPO) basieren.

Um diese Vergleiche zu realisieren, soll ein System entwickelt werden, dass diese durchführen, festhalten und auswerten kann. Dieses soll aus einem Environment, mehreren Agenten beider Algorithmen sowie aus statistischen Analysekomponenten zur Leistungsbestimmung bestehen. Zuzüglich sollen weitere Anforderungen an die Evaluation gestellt werden, um die Vergleichbarkeit sicherzustellen.

### 3.1. Anforderungen an das Environment

In diesem Abschnitt werden die Anforderungen an das Env dargestellt. Neben der Hauptanforderung, dass das Spiel Snake implementiert werden soll, ergeben sich weitere zusätzliche Anforderungen.

#### 3.1.1. Standardisierte Schnittstelle

Das Env soll eine standardisierte Schnittstelle besitzen, sodass drei Kommunikationskanäle implementiert werden (siehe Unterunterabschnitt 2.2.1). Es soll in der Lage sein, Aktionen zu empfangen. Des Weiteren soll eine Observation und ein Reward an den Agenten übergeben werden. Diese Standardisierung erleichtert die Verwendbarkeit, auch bei anderen Algorithmen.

#### 3.1.2. Funktionalitäten

Das Env soll die folgenden Funktionalitäten implementieren.

### Aktionsausführung

Das Env muss eine Funktionalität beinhalten, die eine Aktion ausführen kann. Diese Aktionsausführung muss sich nach den Regeln des Spiels Snake richten (siehe Abschnitt 2.1).

### Reset

Das Env muss eine Reset Funktionalität implementieren, um einen erbrachten Spielfortschritt zurückzusetzen. Dies ist für den Spielablauf unentbehrlich.

### Render

Das Env muss eine Render Funktionalität implementieren, um eine Visualisierung des Spiels Snake zu ermöglichen. Diese dient der besseren Evaluation und Demonstration.

## 3.2. Anforderungen an die Agenten

In diesem Abschnitt werden die Anforderungen an die Agenten, welche auf dem PPO bzw. DQN Algorithmus basieren, dargestellt.

### 3.2.1. Funktionalitäten

Die Agenten müssen folgende Funktionalitäten implementieren.

#### Aktionsbestimmung

Die Agenten müssen in der Lage sein, aus einer Observation eine Aktion zu bestimmen, welche wiederum dem Env übergeben werden muss, um einen Spelfortschritt erzielen zu können.

#### Lernen

Die Agenten müssen fähig sein, auf Grundlage vergangener Spielepisoden zu lernen und damit ihre Spielergebnisse zu verbessern.

### Parametrisierung

Das System muss die Möglichkeit besitzen, mehrere Agenten des gleichen Algorithmus zu erstellen, welche sich jedoch durch ihre verwendeten Hyperparameter unterscheiden. Diese Definition von Agenten ist in der Evaluation zu berücksichtigen und dient damit einer besseren Vergleichbarkeit.

### 3.2.2. Diversität der RL Algorithmen

Um nicht nur Agenten eines Algorithmus untereinander zu vergleichen, sondern auch den Vergleich zu anderen Algorithmen zu erbringen, sollen ein DQN und PPO Algorithmus miteinander verglichen werden. Diese bieten sich, wie in Abschnitt 2.3 und Abschnitt 2.4 beschrieben, für den Vergleich an.

## 3.3. Anforderungen an die Datenerhebung

In diesem Teil sollen Anforderungen an die statistische Datenerhebung und an die damit verbundenen Analysekomponenten gestellt werden.

### 3.3.1. Mehrfache Datenerhebung

Die Datenermittlung muss für jeden einzelnen Agenten mehrfach durchgeführt werden, um die Validität der Messung zu gewährleisten. (Goodfellow u. a., 2018, S. 135)

### 3.3.2. Datenspeicherung

Damit aus den erzeugten Test- und Trainingsdaten statistische Schlüsse gezogen werden können, ist es wichtig, dass diese gespeichert werden. Da jedoch die Menge an Daten schnell riesige Dimensionen annehmen würde, sollen stellvertretend nur die Daten ganzer Spiele gespeichert werden. Diese Strategie stellt einen Kompromiss zwischen Vollständigkeit und effizientem Speicherplatzmanagement dar.

Das System soll folgende Daten speichern:

Daten	Erklärung
steps	Die in einem Spiel durchgeführten Züge. Diese geben in der Evaluation später Aufschluss über die Effizienz und weisen auf Lernfehler der Agenten hin, wie beispielsweise das Laufen im Kreis.

apples	Die Anzahl der gefressenen Äpfel in einem Spiel ist ein maßgeblicher Evaluationsfaktor zur Einschätzung des Lernerfolges.
wins	Hat der Agent das Spiel gewonnen? Dieser Wert stellt die Endkontrolle des Agenten dar. Er gibt Aufschluss über das Konvergenzverhalten.

Tabelle 3.1.: Darstellung der zu erhebenden Daten für die statistische Auswertung

### 3.4. Anforderungen an die Evaluation

Bei der Evaluation soll der optimale Agent für jedes Evaluationskriterium ermittelt und durch aussagekräftige Statistiken untermauert werden. Das Kriterium der Performance wurde von der verwendeten Literatur Wei u. a. (2018) und Chunxue u. a. (2019) übernommen, die anderen ergeben sich aus den zu speichernden Daten. Die einzelnen Kriterien lauten:

Kriterium	Erläuterung
Performance	Welcher Agent erreicht das beste Ergebnis? Im Sachzusammenhang mit dem Spiel Snake bedeutet dies: Welcher Agent frisst die meisten Äpfel, nachdem er trainiert wurde?
Siegrate	Welcher Agent schafft die Spiele mit einem Sieg zu beenden? Im Gegensatz zur Performance, gibt die Siegrate Aufschluss über das Konvergenzverhalten.
Robustheit	Welcher Agent kann in einer modifizierten Umgebung die größte Performance erreichen? In Bezug auf Snake bedeutet dies: Welcher Agent ist in der Lage, auf einem größeren bzw. kleineren Spielfeld die meisten Äpfel zu fressen? Dies ist bei Real World Applikationen ein wichtiger Faktor, da sich unbemannte Drohnen auch in unbekannten Umgebungen zurechtfinden müssen.

Effizienz	Welcher Agent löst das Spiel mit der größten Effizienz? Bezogen auf das Spiel Snake bedeutet dies: Welcher Agent ist in der Lage, die Äpfel mit möglichst wenig Schritten zu fressen? Dieser Wert ist besonders in Real World Applikationen von Interesse, da beispielsweise selbstfahrende Autos ihre Ziele in einer möglichst geringen Strecke erreichen sollen, um Energie und Zeit zu sparen.
-----------	---

Tabelle 3.2.: Auflistung der Evaluationskriterien

# Kapitel 4

## Verwandte Arbeiten

In diesem Kapitel soll es thematisch über den momentanen Stand der bereits durchgeführten Forschung gehen. Dabei sollen die Arbeiten gezielt unter den folgenden Aspekten untersucht werden.

- Optimierungsstrategien
- Reward Funktion
- Evaluationskriterien

Anschließend folgt die Diskussion über die einzelnen verwandten Arbeiten. Ausgewählt wurde diese aufgrund ihres thematischen Hintergrundes zum Spiel Snake, in Verbindung mit dem RL.

### 4.1. Autonomous Agents in Snake Game via Deep Reinforcement Learning

In der folgenden Auseinandersetzung wird sich auf die Quelle Wei u. a. (2018) bezo gen. In der Arbeit „Autonomous Agents in Snake Game via Deep Reinforcement Learning“ wurden mehrere Optimierungen an einem DQN Agenten durchgeführt, um eine größere Performance im Spiel Snake zu erzielen. Sie wurde von Zhepei Wei et al. verfasst und im Jahr 2018 veröffentlicht.

Thematisch wurden in diesem Paper drei Optimierungsstrategien vorgestellt, welche auf einen Baseline DQN (Referenz DQN) Agenten angewendet worden sind. Bei diesen Strategien handelt es sich um den Training Gap, die Timeout Strategy und den Dual Experience Replay.

Dieser Dual Experience Replay (Splitted Memory) besteht aus zwei Sub-Memories,

in welchen Erfahrungen belohnungsbasiert eingesortiert und gespeichert werden. Mem1 besteht dabei nur aus Erfahrungen, welche einen Reward aufweisen, der größer als ein vordefinierter Grenzwert ist. Die restlichen Erfahrungen werden in Mem2 eingepflegt. Zu Beginn des Lernens werden 80% Erfahrungen aus Mem1 und 20% Erfahrungen aus Mem2 entnommen, um den Lernerfolg zu beschleunigen. Im weiteren Lernverlauf wird dieses Verhältnis normalisiert (Mem1: 50% and Mem2: 50%).

Der Training Gap beschreibt die Erfahrungen, welche der Agent zum Zweck des performanteren Lernens nicht verarbeiten soll. Zu diesen zählen die Erfahrungen direkt nach dem Konsum eines Apfels, sodass der Agent die Neuplatzierung dieses erlernen würde. Da der Agent auf diesen Prozess jedoch keinen Einfluss hat, könnte die Verarbeitung dieser Daten den Lernerfolg mindern, weshalb die Training Gap Strategie etwaige Erfahrungen nicht speichert und das Lernen während dieser Periode verhindert.

Die Timeout Strategy sorgt für eine Bestrafung, wenn der Agent über eine vordefinierte Anzahl an Schritten  $P$  keinen Apfel mehr gefressen hat. Dabei werden die Rewards der letzten  $P$  Erfahrungen mit einem Malus verrechnet, was den Agenten dazu anhält, die schnellste Route zum Apfel zu finden. Die Höhe des Malusses ist antiproportional zur Länge der Snake (geringe Länge → großer Malus; große Länge → geringer Malus).

Die optimierte Reward Funktion, welche das Paper verwendet, besteht damit aus dem Distanz Reward, welcher sich aus der Addition des vorherigen Rewards mit  $\Delta r$  ergibt (siehe Gleichung 4.1).

$$r_{res} = r_t + \Delta r \quad (4.1)$$

Zusätzlich wird der resultierende Reward noch zwischen eins und minus eins geclipt  
 $r_{res} = clip(r_{res}, -1, 1)$ .

$\Delta r$  ist dabei wie folgt definiert (siehe Gleichung 4.2):

$$\Delta r(L_t, D_t, D_{t+1}) = \log_{L_t} \frac{L_t + D_t}{L_t + D_{t+1}} \quad (4.2)$$

Wobei  $t$  den vorherigen und  $t + 1$  den aktuellen Zeitpunkt darstellt.  $L_t$  ist die Länge der Snake zum vorherigen Zeitpunkt und  $D_t$  und  $D_{t+1}$  stellen die Distanzen zwischen Snake und Apfel zum vorherigen und aktuellen Zeitpunkt dar.

Sollte die Timeout Strategy auslösen, so werden die letzten  $P$  Erfahrungen entsprechend angepasst und in Mem2 verschoben.

Als maßgebliches Kriterium zur Evaluation der Leistung des DQN wurde die Performance herangezogen, gemessen am Score und an den steps survived, also die überlebten Schritte.

### 4.1.1. Diskussion

Sowohl die Training Gap Strategy also auch Dual Experience Replay und Timeout Strategy stellen vielversprechende Optimierungen dar, welche auf experimentellen Resultaten basierend gute Ergebnisse erzielen konnten. Jedoch existieren auch Diskussionspunkte an der Ausarbeitung. Das Env wird im Paper nur kurz vorgestellt, jedoch lässt sich aus dem Abschnitt Game Environment schließen, dass alle Anforderungen des Env (siehe Abschnitt 3.1) erfüllt sind.

Die Verfasser führen keinen Vergleich mit anderen Algorithmen durch, lediglich ein DQN Agent wird betrachtet. Es ist unklar, ob auch die Optimierungen, darunter Dual Experience Replay, Training Gap und Timeout Strategy, für den PPO-Algorithmus geeignet wären. Zwar sind alle Funktionalitäten des im Paper verwendeten DQN gegeben (siehe Unterabschnitt 3.2.1), jedoch wurde der Fokus kaum auf eine Parametrisierung (siehe Unterunterabschnitt 3.2.1) gelegt, da dieses Paper hauptsächlich nur einen Agenten betrachtet hat und nicht mehrere Varianten, mit Ausnahme der optimierten Agenten. Diese unterscheiden sich nur durch die Optimierungen.

Auch bei der statistischen Datenerhebung existieren Abweichungen zu den Anforderungen in Abschnitt 3.3. Zhepei Wei et al. verzichteten auf eine mehrfache Datenerhebung ihrer experimentellen Ergebnisse. Dem Leser werden nur indirekt Informationen über die erhobenen Daten mitgeteilt. Aus Statistiken lässt sich jedoch schließen, dass der Score und die steps (Anzahl der Schritt) gespeichert wurden.

Weiterhin wurde sich bei den Evaluationskriterien einzig auf die Performance und Spielzeit konzentriert. Weitere Kriterien wie beispielsweise die Robustheit oder Siegrate (siehe Tabelle 3.2), werden nicht betrachtet.

Dies soll in dieser Ausarbeitung jedoch geschehen, da diese Faktoren ebenfalls wichtig für eine voll umfassende Bewertung der Agenten sind, besonders in Real World Applikationen (siehe Abschnitt 1.1).

Des Weiteren ist erwähnenswert, dass die Verfasser auf das Evaluationskriterium der steps survived setzten, welches im kompletten Widerspruch zur Effizienz (siehe Tabelle 3.2) steht. Zhepei Wei et al. sehen ein langes Überleben der Snake als positiv an, wohingegen dies in dieser Ausarbeitung kritisch betrachtet wird, da es kein zielgerichtetes Verhalten bestärkt. Ziel der Agenten in dieser Ausarbeitung ist es, das Spiel Snake möglichst effizient zu lösen und es nicht lange zu überleben.

## 4.2. UAV Autonomous Target Search Based on Deep Reinforcement Learning in Complex Disaster Scene

In der folgenden Auseinandersetzung wird sich auf die Quelle Chunxue u. a. (2019) bezogen. Die Arbeit „UAV Autonomous Target Search Based on Deep Reinforcement Learning in Complex Disaster Scene“ wurde von Chunxue Wu et al. verfasst und am 5. August 2019 veröffentlicht. Dabei wird das Spiel Snake als ein dynamisches Pathfinding Problem interpretiert, auf dessen Basis unbemannte Drohnen in Katastrophensituationen zum Einsatz kommen sollen.

Auch in diesem Paper verwenden die Autoren Optimierungen, um den Lernerfolg zu steigern. Einer dieser Optimierungen wurde auf Basis des Geruchssinnes konzipiert. Der Odor Effect erzeugt um den Apfel drei aneinanderliegende Geruchszonen, in welchen ein größerer Reward zurückgegeben wird als außerhalb der Geruchszonen. Dabei unterscheiden sich diese in der Höhe des zurückgegebenen Rewards, sodass die dritte Zone den geringsten und die erste Zone den größten Reward von allen zurückgibt ( $r_1 > r_2 > r_3$ , wobei  $r_x$  der Reward der x-ten Zone darstellt). Diese Zonen stellen den zunehmenden Duft von Nahrung dar, wobei dieser immer stärker wird, umso näher man sich der Quelle nähert.

Eine weitere Optimierungsstrategie basiert auf dem Loop Storm Effect, welcher das Verhalten beschreibt sich um den Apfel zu bewegen. Die Verfasser haben festgestellt, dass dieser Effekt zu einem schlechten Lernerfolg führt. Darum haben Wu et al. einen dynamischen Positionsspeicher konzipiert, welcher Loops erkennt und diese durch das Zurückgeben einer Zufallsaktion, welche nicht auf dem Loop liegt, unterbricht. Experimentelle Ergebnisse des Papers haben gezeigt, dass der Loop Storm Effect, nach Implementierung des dynamischen Positionsspeichers kaum mehr in Erscheinung trat.

Auf Basis einer Standard Reward Funktion, welche für das Essen eines Apfels +100 und für das Sterben -100 zurückgibt, wurde ein Versuch durchgeführt. Dem Agenten war es nicht möglich, gegen die optimale Lösung zu konvergieren, aufgrund von Loop Storms und einer unzureichende Reward Funktion. Hingegen war es dem Agenten mit Odor Effect und dynamischen Positionsspeicher möglich, eine Konvergenz zu erreichen.

Die Reward Funktion entspricht daher dem Odor Effect. Auch in diesem Paper bleibt die Performance maßgeblicher Evaluationsfaktor, wobei der Fokus auf den erreichten Reward gelegt wurde, welcher natürlich stark mit der Performance korreliert.

### 4.2.1. Diskussion

Auch dieses Paper besitzt interessante Verbesserungen, welche nach den ersten Ergebnissen gute Resultate vorweisen. Jedoch legt auch dieses Paper andere Schwerpunkte als diese Ausarbeitung mit ihren Anforderungen (siehe Kapitel 3).

Aus Grafiken geht hervor, dass die Verfasser ein Env mit einer Visualisierung verwenden. Weiterhin ist davon auszugehen, dass auch alle weiteren Anforderungen bezüglich des Env (siehe Abschnitt 3.4) erfüllt worden sind, da ansonsten kein Training eines Agenten möglich wäre. Dennoch wurde das Env nur auf grundlegende Weise behandelt.

Das Paper legt seinen Schwerpunkt deutlich mehr auf die Grundlagen des RL, wie z.B. auf den Markov Decision Process und die RL Kernbegriffe (siehe Unterabschnitt 2.2.1).

Auch erfüllt die Ausarbeitung alle Anforderungen an die Funktionalitäten von Agenten (siehe Abschnitt 3.2). Dennoch wurde auch hier weniger der Fokus auf eine Parametrisierung der Agenten gelegt, da wieder nur ein DQN Agent näher untersucht wurde. Zwar werden, gegen Ende, einige Vergleiche zu einer Handvoll anderer Agenten getätigt, jedoch sind diese Vergleiche nur sehr oberflächlich, da auf diesem Punkt nicht das Hauptaugenmerk der Arbeit liegt. Im Gegensatz dazu, soll in dieser Ausarbeitung der Vergleich von Agenten im Mittelpunkt liegen.

Wie auch im ersten Paper (siehe Unterabschnitt 4.1.1), setzen die Verfasser nicht auf eine mehrfache Datenerhebung für die statistische Auswertung ihrer experimentellen Ergebnisse. Eine direkte Erwähnung der Daten, welche im Verlauf des Trainings und des Testens gespeichert werden, wird nicht durchgeführt. Auch dies soll im Rahmen dieser Ausarbeitung geschehen, um die Parametrisierung (siehe Unterunterabschnitt 3.2.1) herauszustellen. Die gezeigten Statistiken weisen jedoch darauf hin, dass der Score sowie der mittlere Aktionswert (Q-Value) gespeichert wurden. Zuzüglich werden, für die Optimierungen, die steps und das Auftreten von Loop Storms erfasst und gespeichert. Anders als in dieser Ausarbeitung, wo immer die gleichen Daten erhoben werden (siehe Tabelle 3.1).

Chunxue Wu et al. verwendeten zudem hauptsächlich den Score und die Q-Values als Evaluationskriterien. Um die Effizienz der im Paper verwendeten Strategien (Optimierungen) zu zeigen, wurden ebenfalls die gemittelten Steps pro Spiel und das Auftreten von Loop Stoms als weitere untergeordnete Evaluationskriterien verwendet. In diesem Paper werden daher im Vergleich zum ersten Paper, deutlich mehr

Evaluationskriterien genutzt, welche sich partiell mit denen aus dieser Ausarbeitung überschneiden. Dennoch legt das hier betrachtete Paper deutlich mehr Wert auf den Fehler des Agenten. In dieser Ausarbeitung liegt der Fokus deutlich mehr auf der Leistung und Effizienz.

### 4.3. Zusammenfassung

Sowohl „Autonomous Agents in Snake Game via Deep Reinforcement Learning“ (siehe Abschnitt 4.1) als auch „UAV Autonomous Target Search Based on Deep Reinforcement Learning in Complex Disaster Scene“ (siehe Abschnitt 4.2) bieten einige Optimierungsstrategien, welche im weiteren Verlauf dieser Ausarbeitung, als Vorbild dienen sollen.

Besonders zu betonen ist, dass die vorgestellten Arbeiten alle verschiedene Schwerpunkte gesetzt haben und daher nicht immer die Anforderungen dieser Ausarbeitung erfüllt haben.

So wurden zwar die Anforderungen zum Env (siehe Abschnitt 3.1) und zu den Agenten (siehe Abschnitt 3.2), mit Ausnahme der Parametrisierung (siehe Unterabschnitt 3.2.1) und der Diversität der Algorithmen (siehe Unterabschnitt 3.2.2), alle erfüllt. Dennoch wurden auch Anforderungen bei der statistischen Datenerhebung und Evaluation nicht erfüllt. Zu diesen zählen z.B. die mehrfache Datenerhebung (siehe Unterabschnitt 3.3.1) und die Evaluation-Anforderungen (siehe Abschnitt 3.4). Letztere weichen, verständlicherweise, von den Anforderungen ab, da sich die Verfasser der Arbeiten auf andere Aspekte konzentriert haben und daher nicht dieselben Evaluationskriterien gewählt haben.

Insgesamt scheinen die betrachten Arbeiten jedoch ungeeignet zu sein, um die in dieser Ausarbeitung aufgestellte Forschungsfrage zu beantworten (siehe Abschnitt 1.2). Sie führen keinen Vergleich durch, um einen optimalen Agenten zu erhalten sondern setzen mehr auf das optimieren einzelner ausgewählter Agenten. In dieser Arbeit soll daher ein Auswahlprozess stattfinden und kein Optimierungsprozess eines einzelnen Agenten.

Im Weiteren wird nun mit dem Konzept dieser Ausarbeitung fortgefahrene.

# Kapitel 5

## Konzept

In diesem Kapitel soll das Konzept dieser Ausarbeitung vorgestellt werden. Dabei ist es das Ziel, eine Menge an Agenten mittels eines hier entwickelten Verfahrens zu untersuchen. Diese Agenten können selbst definiert werden oder von außerhalb stammen. Das vorzustellende Verfahren entscheidet auf Basis von Vergleichen, welcher Agent für welches Evaluationskriterium der jeweils optimale ist. Dazu werden im Laufe des Verfahrens die Agenten mit Optimierungen versehen, um die Leistungsfähigkeit noch weiter zu steigern. Zum Schluss wird dann der optimale Agent für das Spiel Snake bestimmt, dies geschieht mithilfe von Statistiken, welche erstellt werden.

Damit dies durchgeführt werden kann, müssen sowohl die Agenten (PPO und DQN) mit ihren Optimierungen als auch das Spiel Snake, das Vorgehen und das Erstellen von Statistiken erklärt werden.

### 5.1. Vorgehen

Das Vorgehen lässt sich am besten mithilfe eines Aktivitätsdiagramms darstellen, in welchem die einzelnen Schritte des Vergleichs visuell dargestellt werden.

Als erstes werden die Agenten erstellt (siehe Abbildung 5.1), indem mehrere Instanzen der Agent Klasse von DQN und PPO mit verschiedenen Hyperparametern generiert werden.

Mit diesen Agenten werden nun die weiteren Baseline Vergleiche durchgeführt, in welchen für jedes Evaluationskriterium der jeweils beste Agent bestimmt wird. Grund dafür ist, dass das Anwenden der Optimierungen viele Ressourcen bindet. Daher sollen nur die vielversprechendsten Agenten zu den Optimized Vergleichen zugelassen werden. Der verwendete Algorithmus besitzt dabei keinen Einfluss auf die Auswahl der Agenten, sodass auch nur DQN oder PPO Agenten Gewinner der Baseline Vergleiche sein können. Genauere Details zur Durchführung der Baseline Vergleiche

finden sich im Unterabschnitt 5.5.1. Auf die Sieger Agenten der Baseline Vergleiche werden daraufhin die Optimierungen angewendet (siehe Abbildung 5.1). Mit diesen optimierten Agenten werden nun die sogenannten Optimized Vergleiche bezüglich jedes einzelnen Evaluationskriteriums (siehe Tabelle 3.2) erneut wiederholt. Im vorletzten Schritt soll wieder der optimale Agent für jedes Evaluationskriterium ermittelt werden. Dabei können dies auch Baseline Agenten sein.




Abbildung 5.1.: Darstellung des Vorgehens

Zum Schluss wird auf Grundlage der Sieger Agenten entsprechend der Forschungsfrage der optimale Agent ermittelt. Dafür ist eine Priorisierung der Evaluationskriterien nötig, um zu bestimmen, welche Eigenschaften des Agenten am wichtigsten für den

Benutzer sind. In dieser Ausarbeitung wird die Performance priorisiert, gefolgt von der Sieg-Rate, der Robustheit und zum Schluss der Effizienz. Diese Priorisierung bedeutet jedoch nicht, dass der Agent mit der besten Performance automatisch gewonnen hat. Sie liefert lediglich ein Verhältnis zwischen den Evaluationskriterien, auf dessen Basis der Benutzer den nach seinen Maßstäben besten Agenten auswählen kann.

## 5.2. Environment

Das Env besteht im Wesentlichen aus der Hauptkomponente der Spiellogik, welche von einer Schnittstellen-Komponente umschlossen wird. Diese soll mit einer standardisierten Schnittstelle (siehe Unterabschnitt 3.1.1) implementiert werden.

Die Spiellogik kapselt die Game-, Player-, Reward-, Observation- und GUI-Komponenten, welche im Folgenden näher erklärt werden.

### 5.2.1. Spiellogik

Die Spiellogik besteht aus den fünf Unterkomponenten, welche im obigen Abschnitt Environment bereits benannt wurden.

Die Game-Komponente stellt die Hauptkomponente dar, da sie die eigentliche Aktionsdurchführung implementiert. Sie beinhaltet jeweils eine Instanz der Reward-, Observation-, GUI- und Player-Komponente. Letztere ist eine Datenhaltungskomponente, die die Daten der Snake, wie z.B. Position oder Ausrichtung (direction) beinhaltet.

Die Reward-Komponente bestimmt den auszugebenden Reward nach jeder Aktionsabfertigung. Dieser berechnet sich, wie in Unterunterabschnitt 5.2.1, angegeben. Zuzüglich wird im Rahmen der Optimierungen A (siehe Unterabschnitt 5.4.1), eine weitere Reward Funktion implementiert.

In der Game-Komponente werden wichtige spielbezogene Daten verwaltet. Zu diesen gehören das Spielfeld (ground) sowie die Form des Spielfelds (shape) und die Position des Apfels. Die Game-Komponente beinhaltet zudem viele Methodiken, wie z.B. die Aktionsausführung, die Observation- und Reward-Erstellung usw.

In der Player-Komponente werden spielerbezogene Daten verwaltet. Zu diesen zählen die Position des Kopfes der Snake, sowie die Positionen aller Schwanzglieder, die Ausrichtung (direction), die gelaufenen Schritte seit dem letzten Fressen eines Apfels (inter\_apple\_steps) und der Lebensstatus (is\_terminal).

Die Observation-Komponente beinhaltet viele einzelne Funktionen zur schrittweisen Erstellung der Observation, wie sie in Unterunterabschnitt 5.2.1 erklärt wird.

Zur Erzeugung der grafischen Oberfläche implementiert die GUI-Komponente die Funktionalität ein Fenster zu öffnen, welches das Spielgeschehen anzeigt.

## Spielablauf

Die eigentliche Aktionsabarbeitung wird durch das Aufrufen der step Funktionalität in der Schnittstellen-Komponente (siehe Unterabschnitt 5.2.2) bewirkt. Diese ruft daraufhin die Routinen zur Erstellung des Rewards (evaluate) und der Observation (observe) auf, welche in der Game-Komponente implementiert sind. Um die Abarbeitung einer Aktion durchzuführen, wird die action Funktionalität aufgerufen. Der Ablauf einer Aktionsabarbeitung ist in der Abbildung 5.2 dargestellt. Zu Beginn wird überprüft, ob die Snake, seit dem letzten Fressen, mehr Schritte als die eigentliche Spielfeldgröße gegangen ist. Diese liegt standardmäßig bei  $8 \times 8 \rightarrow 64$ .




Abbildung 5.2.: Darstellung eines Schritts in der Spielepisode

Im Rahmen der Bestimmung der Robustheit wird sich diese im Testverlauf jedoch ändern (siehe Unterabschnitt 5.5.1).

Sollte die Snake mehr Schritte gelaufen sein als die Größe des Spielfelds, so wird das Spiel terminiert, da die Snake eventuell in einer Schleife steckt. Andernfalls wird die

Aktion verarbeitet, indem die Ausrichtung (direction) der Snake manipuliert wird. Das Spiel Snake besitzt drei Aktionen: turn left, turn right oder do nothing.

Aktion	Erklärung
turn left	Die Snake verändert ihre Richtung um $90^\circ$ nach links. Z.B. von N → W
turn right	Snake verändert ihre Richtung um $90^\circ$ nach rechts. Z.B. von N → O
do nothing	Die Richtung der Snake wird nicht verändert.

Tabelle 5.1.: Kodierung der Aktionen im Snake Environment

Entsprechend der Tabelle 5.1 wird deutlich, dass die Ausrichtung (direction) entweder nur Norden, Osten, Süden oder Westen sein kann. Als Nächstes wird ein Schritt, mit aktualisierter Ausrichtung, hypothetisch durchgeführt. Dabei wird festgestellt, ob die Ausführung des Schritts zum Tod der Snake führt. Sollte dies der Fall sein, so wird der Spielablauf terminiert. Andernfalls wird der Schritt durchgeführt. Dabei wird zwischen zwei Fällen unterschieden.

Sollte die Snake einen Apfel gefressen haben, also Kopf und Apfel dieselbe Position einnehmen, so wächst die Snake um ein Schwanzglied. Der alte Apfel wird entfernt und ein neuer erscheint, zufallsbasiert, auf einem freien Feld des Spielfelds (siehe Abschnitt 2.1).

Sollte die Snake keinen Apfel gefressen haben, so führt sie den Schritt aus und es bewegen sich alle Schwanzglieder auf die Vorgängerposition, mit Ausnahme des Kopfes, welcher die neue Position einnimmt (siehe Abschnitt 2.1).

Nach der Ausführung einer dieser beiden Fälle, wird die Spieloberfläche (ground) und GUI aktualisiert. Danach ist die Aktionsabarbeitung abgeschlossen.

Damit der Agent die neue Observation und den neuen Reward erhält, werden diese in der Reward bzw. Observation-Komponente bestimmt und zurückgegeben.

## Reward

Der Reward wird in der Reward-Komponente, basierend auf dem letzten Zug, gebildet. Dies geschieht nach folgendem Vorbild.

Der Standard Reward ist abhängig vom Fressen eines Apfels, vom Sieg und vom Verlust einer Spielepisode. Sollte keiner dieser genannten Faktoren eintreten, wird ein Reward von -0.01 zurückgegeben. Dies hält den Agenten dazu an den kürzesten Pfad zum Apfel zu finden, da jeder Schritt geringfügig bestraft wird. War es der Snake möglich einen Apfel zu fressen, so wird ein Reward von +2.5 zurückgegeben, da ein Zwischenziel erreicht wurde. Sollte die Snake gestorben sein, so wird ein Reward

von -10 zurückgegeben, um dieses Verhalten in seiner Häufigkeit zu minimieren. Hat die Snake alle Äpfel gefressen, sodass das gesamte Spielfeld mit ihr ausgefüllt ist, so wird ein Reward von +10 zurückgegeben, um ein solches Verhalten in seiner Häufigkeit zu maximieren. Die Snake hat zu diesem Zeitpunkt das Spiel gewonnen (siehe Abschnitt 2.1). Die zweite Reward Funktion wird in Unterabschnitt 5.4.1 erklärt.

## Observation

Die Observation wird in der Observation-Komponente mithilfe verschiedener Unterfunktionen erzeugt und besteht aus der around\_view (AV) und der scalar\_obs (SO).

Die AV lässt sich als ein Ausschnitt des Spielfelds (ground) beschreiben, welcher einen festen Bereich um den Kopf der Snake abdeckt. Strukturen wie Wände und Teile des eigenen Schwanzes werden deutlich. Mathematisch ist die AV eine one-hot-encoded Matrix der Form (6x13x13).

Das One-Hot-Encoding ist ein binäres Codierungsschema. Sollte ein Merkmal vorhanden sein, so wird dieses mit eins codiert anderenfalls mit null. (Lapan, 2020, S. 359 f.) Dies ist auch der Grund, warum die AV Matrix sechs Channel (zweidimensionale Schichten) besitzt. Diese geben Aufschluss über folgende Informationen (siehe Tabelle 5.2):

Channel der Matrix (Ax13x13)	Erklärung
A = 0	Die erste Feature Map signalisiert den Raum außerhalb des Spielfelds.
A = 1	Diese Feature Map stellt alle Schwanzglieder mit Ausnahme des Kopfes und es letzten Schwanzgliedes dar.
A = 2	In dieser Feature Map wird der Kopf der Snake dargestellt.
A = 3	Damit gegen Ende des Spiels der Agent noch freie Felder erkennen kann, wird in dieser Feature Map jedes freie und sich im Spielfeld befindliche Feld mit eins codiert.
A = 4	Die vorletzte Feature Map codiert das Schwanzende der Snake.
A = 5	In der letzte Feature Map wird der Apfel abgebildet.

Tabelle 5.2.: Channel-Erklärung der AV (around\_view)

Vorteilhaft an der AV ist, dass im Gegensatz zu den verwandten Arbeiten (Wei u. a., 2018) und (Chunxue u. a., 2019), nicht das gesamte Spielfeld übertragen wird, sondern nur der wichtigste Ausschnitt. Dies reduziert die Menge an zu verarbeitenden Daten. Ein Nachteil dieser Obs ist jedoch die Unvollständigkeit. Sollte beispielsweise der blaue Punkt (der Apfel) in Abbildung 5.3 außerhalb des grauen Kastens und daher außerhalb der AV liegen, so bleibt der Agent im Unklaren über den Aufenthaltsort des Apfels. Aus diesem Grund wurde die AV durch die scalar\_obs (SO) ergänzt. Die SO beinhaltet skalare Informationen und ist eine Konkatenation aus Raytracing Distanzbestimmung, Hunger- und Blickrichtungsanzeige (direction). In Quelle (Glassner, 1989) wird das grundlegende Verfahren, auf welchem die Raytracing Distanzbestimmung basiert, vorgestellt.

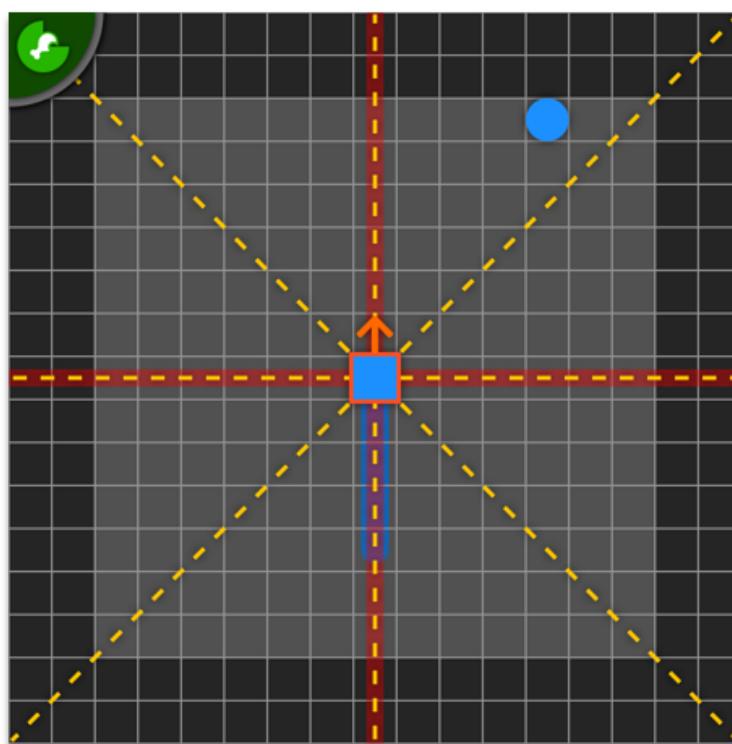


Abbildung 5.3.: Partielle Darstellung der verwendeten Observation. Das blaue Rechteck und dessen Schwanz stellt die Snake dar. Schwarze Rechtecke werden nicht von der AV abgedeckt und Graue liegen innerhalb dieser. Die gelben gestrichelten Linien stellen die Raytracing Distanzbestimmung dar. Der blaue Kreis stellt den Apfel dar und der grüne Viertelkreis oben links symbolisiert den Hunger.

Zuzüglich werden der SO noch zwei Kompasse für die relativen Positionsinformationen zwischen Kopf und Apfel bzw. letztem Schwanzglied hinzugefügt.

Letztere sind eindimensionale Vektoren, welche mithilfe des One-Hot-Encoding anzeigen, ob sich das gesuchte Objekt relativ zum Kopf oberhalb, unterhalb oder in derselben Zeile befindet (Matrixsicht). Analog verhält es sich mit den Spalten.

Die Blickfeldanzeige ist ebenfalls one-hot-encoded und stellt mit ihrem Vektor die vier Ausrichtungen Norden, Osten, Süden und Westen dar.

Der Hunger ist die Differenz zwischen der Anzahl der gegangenen Schritte seit dem letzten Fressen (`inter_apple_steps`) und der maximalen Schrittanzahl (`max_steps`) (siehe Unterunterabschnitt 5.2.1). Zur besseren Verarbeitung für die neuronalen Netzwerke, wird diese Differenz zudem mit minus eins potenziert, es wird daher der Kehrwert gebildet. Um mit der Unendlichkeit auftretende Probleme zu umgehen wird zwei zurückgegeben, wenn die Differenz null wird. Daraus ergibt sich die folgende Formel (siehe Gleichung 5.1).

$$\min(2, \frac{1}{\text{inter\_apple\_steps} - \text{max\_steps}}) \quad (5.1)$$

In ähnlicher Weise wird mit den Raytracing Distanzbestimmungen verfahren. Bei diesen handelt es sich um acht Distanzmesserlinien, die in  $45^\circ$  Abständen ausgesandt werden (siehe Abbildung 5.3). Befindet sich das gesuchte Objekt in dieser Linie, so wird die Distanz ermittelt und analog zum Hunger angepasst. Gesuchte Objekte der Raytracing Distanzbestimmungen sind Wände, der eigene Schwanz und der Apfel. Daher wird die Raytracing Distanzbestimmung in einem Vektor der Größe 24 ( $3 * 8 = 24$ ) gespeichert.

## GUI

Die grafische Oberfläche oder auch GUI genannt kann optional ein- oder ausgeschaltet werden. Beim Lernen der Agenten bietet es sich beispielsweise an, diese auszuschalten, da diese die Lerngeschwindigkeit senkt. Beim Start der GUI wird ein Fenster geöffnet, welches den momentanen Stand des Spielgeschehens anzeigt. Nach jeder Aktionsdurchführung wird die GUI aktualisiert.

### 5.2.2. Schnittstelle

Die Schnittstelle umschließt die Spiellogik-Komponente mit ihren Unterkomponenten, zum Zwecke der Standardisierung. Die `step` Funktionalität ist für das Aufrufen der Aktionsausführung zuständig. Entsprechend der Anforderung der standardisierten Schnittstelle (siehe Unterabschnitt 5.2.2) gibt sie nur Reward und Observation zurück.

`Reset` setzt den bereits vorhandenen Spielfortschritt zurück (siehe Unterunterabschnitt 3.1.2).

`Render` ist für die Visualisierung der Spieloberfläche verantwortlich (siehe Unterunterabschnitt 3.1.2).

## 5.3. Agenten

In diesem Abschnitt des Konzepts sollen die Agenten inklusive ihrer Netzstruktur vorgestellt werden. Zu diesem Zweck müssen die Algorithmen (DQN und PPO) näher beleuchtet werden.

### 5.3.1. Netzstruktur

Zu Beginn soll die Netzstruktur erklärt werden, wobei dies unabhängig von den Algorithmen geschehen kann, da sowohl DQN als auch PPO Agenten das annähernd gleiche Netz nutzen. Im Rahmen dieser Ausarbeitung soll sich nur auf eine Netzstruktur konzentriert werden, um die Vergleichbarkeit der einzelnen Algorithmen zu erhöhen. Dennoch müssen aufgrund dieser Mehrfachnutzung kleinere Anpassungen an den Netzen vorgenommen werden.

In den Ausarbeitungen von (Wei u. a., 2018) und (Chunxue u. a., 2019) wurden einzig große CNNs (Convolutional Neural Network) genutzt, die viele unwesentliche Informationen verarbeiten, welche nicht für das erfolgreiche Lösen des Spiels benötigt werden. Zusätzlich können noch Probleme mit variablen Spielfeldgrößen auftreten, sodass in dieser Ausarbeitung eine zweiteilige Netzstruktur verwendet wird. Die gesamte Netzstruktur besteht aus dem AV-Network und dem Actor-, Critic-, Q-Net-Tail. Begonnen wird mit dem AV-Network, welches die AV durch zwei Convolutional Layer mit einer ReLU Aktivierungsfunktion propagiert. Dabei erhöht sich die Channel-Anzahl auf acht, wobei eine weitere Erhöhung aufgrund der bereits sehr stark optimierten AV nicht nötig ist.

Danach werden allen Feature Maps eine Null-Zeile und Null-Spalte hinzugefügt (Padding), damit beim Max-Pooling auch die letzte Zeile und Spalte der originalen AV verarbeitet werden. Nach dem max-pooling besitzen die Feature Maps eine Größe von 7x7 (Tensor: 8x7x7).

Dann folgt die Einebnung (Flatten) zu einem eindimensionalen Tensor, welcher daraufhin durch zwei weitere Fully Connected Layer (FC) propagiert wird. Der resultierende Tensor besitzt die Größe 1x128 und ist ein Zwischenergebnis, da dieser nun mit der SO verbunden wird (Join).

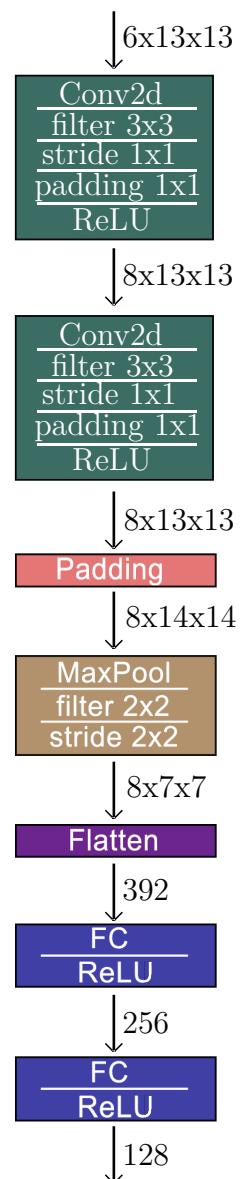


Abbildung 5.4.  
AV-Network

Der Vorgang ist in der Abbildung 5.4 dargestellt. Da das NN in beiden Algorithmen verwendet wird, müssen Network-Tails für den Actor, Critic und für das Q-Network (Q-Net) definiert werden. Alle unterscheiden sich jedoch nur in ihrer Ausgabe. Nachdem der Joined Tensor ( $1 \times 169$ ), welcher aus der Ausgabe des AV-Networks und der SO besteht, durch zwei weitere FC Layer propagierte wurde, benötigt der Actor des PPO Algorithmus eine Wahrscheinlichkeitsverteilung über alle Aktionen. Daher auch die Ausgabe eines Tensors der Größe drei. Um diese Wahrscheinlichkeitsverteilung zu erhalten, wird die SoftMax Funktion angewendet (Abbildung 5.5, links). Der Critic des PPO Algorithmus verwendet hingegen den Critic-Tail, siehe (Abbildung 5.5, Mitte). Dieser leitet den Joined Tensor durch zwei weitere FC Layers. Da der Critic für jeden State die Discounted Sum of Rewards bestimmt (siehe Unterabschnitt 2.3.3), gibt dieser einen Tensor mit einem einzigen Wert zurück (Skalar). Der Q-Net-Tail ist in seinem Aufbau sehr ähnlich zum Critic-Tail (Abbildung 5.5, rechts). Da dieser jedoch die Q-Values für jede Aktion im Zustand bestimmten soll, muss ein Tensor der Größe drei zurückgegeben werden.




Abbildung 5.5.: Darstellung des Actor-Tail (links), Critic-Tail (Mitte) und des Q-Net-Tail (rechts)

### 5.3.2. DQN

Der DQN Algorithmus und damit auch die Agenten, welche auf diesem basieren, bestehen aus drei Komponenten. Diese ermöglichen die Aktionsbestimmung und Lernprozedur. Diese Hauptfunktionalitäten sind in der DQN-Komponente eingebettet, welche die zentrale Instanz des DQN darstellt. In ihr werden wichtige Konstanten für den Algorithmus, wie z.B. Gamma, Epsilon (eps), Epsilon-Dekrementierung (eps\_dec), der Minimalwert für Epsilon (eps\_min), die Batch-Size (batch\_size), die maximale Größe des Memory (max\_mem\_size) und die Lernrate (lr), gespeichert.

Diese Memory-Komponente speichert Erfahrungen des DQN Agenten in einer Ring-Buffer Struktur. Sollte dieser Buffer voll sein, so werden die ältesten Erfahrungen mit den neuen überschrieben. Dies Verfahren wird in Quelle (Mnih u. a., 2013, S. 5) dargestellt. Abzuspeichernde Werte für jeden Schritt sind die around\_view (AV), die scalar\_obs (SO) die Aktion (action), der Reward (reward), die Information, ob man sich in einem terminalen Zustand befindet (terminal) und die around\_view (AV\_) und scalar\_obs (SO\_) des Nachfolgezustandes (siehe Unterabschnitt 2.4.1). Die Q-Network-Komponente verwaltet das NN (Q-Network). Dieses wird zur Q-Value Bestimmung und damit zur Aktionsbestimmung genutzt. Zudem wird es durch den Lernprozess aktualisiert.

Im Weiteren folgt die Erklärung dieser Prozeduren. Begonnen wird dabei mit der Aktionsbestimmung.

### Aktionsauswahlprozess

Eine genaue Darstellung der Aktionsbestimmung befindet sich in Abbildung 5.6. Um eine Aktion zu bestimmen, muss zuerst ein Zufallswert zwischen null und eins, was den Wahrscheinlichkeiten von 0% bis 100% entspricht, generiert werden.

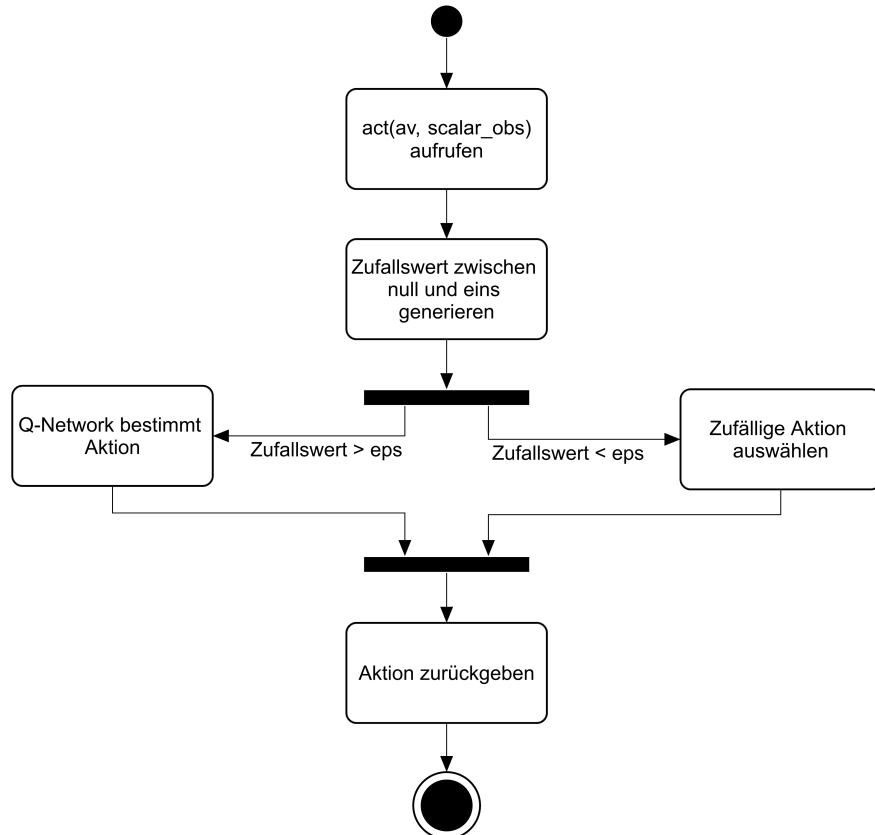


Abbildung 5.6.: Darstellung der Aktionsbestimmung des DQN Agent

Ist der Zufallswert größer als der momentane Epsilon-Wert, so wird die Aktion durch das Q-Network bestimmt. Andernfalls wird eine zufällige Aktion ausgewählt. Die Bestimmung der Aktion durch das Q-Network geschieht dabei wie folgt.

Die around\_view (AV) und die scalar\_obs (SO) werden durch das Q-Network entsprechend der Ausführungen in Unterabschnitt 5.3.1 geleitet. Dieses gibt einen Tensor der Größe drei wieder, welcher die Q-Values der Aktionen turn left (0), turn right (1) und do nothing (2) beinhaltet. Es wird daraufhin die Aktion gewählt, welche dem Index des größten Q-Values entspricht.

Sei  $q = (0.32, -0.11, 0.45)$  ein Tensor, welcher vom Q-Network zurückgegeben wurde, so würde no nothing (2) gewählt werden, da 0.45 der größte Q-Value ist und dieser an Stelle (2) steht.

Die oben beschriebene Prozedur stellt den Aktionsauswahlprozess während des Trainings dar. Während Testläufen, wird die Aktion immer durch das Q-Network bestimmt (siehe Unterunterabschnitt 6.3.3).

## Lernprozess

Der Lernprozess stellt sich wie folgt dar:

Zuerst wird überprüft, ob im Memory genügend Erfahrungen (Experiences – Exp) gespeichert sind, um einen Mini-Batch mit der zuvor definierten Batch-Size, zu entnehmen. Sollte dies nicht der Fall sein, wird die Methode terminiert. Andernfalls wird ein Mini-Batch aus zufälligen Exp gebildet. Ab diesem Punkt wird das Verfahren der Übersichtlichkeit wegen nur noch für eine einzige Erfahrung beschrieben.

Danach wird der Q-Value  $Q(s_t, a_t; \theta_t)$  der gespeicherten Aktion  $a_t$  im State  $s_t$  unter den Netzwerkparametern  $\theta_t$  bestimmt (siehe Gleichung 2.12). Dieser wird als Q-Eval definiert.

Danach werden die Q-Values  $Q(s'_t, A_t)$  aller Aktionen  $A_t$  des Folgezustandes  $s'_t$  bestimmt. Sollte der Folgezustand ein terminaler Zustand sein, so werden die Q-Values auf null gesetzt, da diese die zu erwartende Discounted Sum of Rewards angeben. In einem terminalen Zustand ist diese Summe gleich null, da keine Zustände mehr besucht werden (siehe Abschnitt 2.4).

Daraufhin wird der maximale Q-Value des Folgezustands bestimmt  $Q(s'_t, a'_t)$ , mit Gamma multipliziert und zuletzt mit dem erhaltenen Reward addiert ( $r_t(s_t, a_t) + \gamma \max_{a'_t} Q(s'_t, a'_t; \theta_t)$ ) Gleichung 2.12. Dieser Wert wird als Q-Target definiert und soll Q-Eval entsprechen.

Am Ende wird der Mean Squared Error zwischen Q-Targets und Q-Evals aus dem Mini-Batch gebildet. Auf Basis dieses Fehlers, wird das Q-Network, mittels Backpropagation und Gradientenverfahren, angepasst.

### 5.3.3. PPO

Der PPO Algorithmus und seine Agenten bestehen aus vier Komponenten. Diese ermöglichen die Implementierung der Aktionsbestimmung und Lernprozedur.

In der PPO-Komponente werden wichtige Konstanten für den PPO Algorithmus, wie z.B. Gamma (gamma), der Epsilon-Clip-Wert (eps\_clip) (siehe Unterunterabschnitt 2.3.3), die Anzahl der Trainingsläufe pro Datensatz (K\_Epochs), die Lernrate (lr) und weitere statische Konstanten, gespeichert. Auch Instanzen der Unterkomponenten, die im weiteren Verlauf erklärt werden, sind in dieser Komponente enthalten.

Die Memory-Komponente speichert Erfahrungen eines PPO Agenten. Abzuspeichernde Werte für jeden Schritt sind dabei die around\_view (AV), die scalar\_obs (SO), die Aktion (action), der Reward (reward), die Information, ob man sich in einem terminalen Zustand befindet (is\_terminal) und die logarithmierte Wahrscheinlichkeit der ausgewählten Aktion (log\_prob).

Die Actor-Komponente verwaltet das Actor-Network, welches zur Aktionsauswahl genutzt wird und die Critic-Komponente verwaltet das Critic-Network, welches einzig von der Lernprozedur verwendet wird, um die erwartete Discounted Sum of Rewards zu bestimmen (siehe Unterunterabschnitt 2.3.3). Mit dieser wird im Trainingsverlauf der Critic Fehler bestimmt (siehe Gleichung 2.9).

#### Aktionsauswahlprozess

Der Aktionsauswahlprozess wird in der PPO-Komponente angestoßen. Die AV und SO werden daraufhin durch das Actor-Network propagiert. Der vom Actor ausgegebene Tensor der Größe drei (drei mögliche Aktionen) beinhaltet eine Wahrscheinlichkeitsverteilung, auf dessen Basis die nächste Aktion bestimmt wird (siehe Unterabschnitt 5.3.1).

Sei  $p = (0.05, 0.05, 0.9)$  die Wahrscheinlichkeitsverteilung über alle Aktionen. Bestimmt man 100 Aktionen unter dieser Verteilung, so würde durchschnittlich 90-mal die Aktion zwei gewählt werden. Aktion null und eins nur rund fünfmal.

Für die Testläufe wird immer die Aktion ausgewählt, welche die größte Wahrscheinlichkeit vorweist (siehe Unterunterabschnitt 5.3.2).

#### Lernprozess

Beim Lernprozess des PPO wird sich auf die Ausführungen in Abschnitt 2.3 bezo-gen. Dabei wird beim Lernprozess wie folgt verfahren:

Zu Beginn werden die Erfahrungen aus den gespielten Spielen aus dem Memory (Replay-Buffer) entnommen. Um den Return zu erhalten, werden die einzelnen Re-

wards aus dem Memory diskontiert.

Danach wird die folgende Prozedur mehrmals ausgeführt, um Actor und Critic zu trainieren. Als Nächstes terminiert die Lernprozedur. Für ein besseres Verständnis, wird der Ablauf exemplarisch an einer einzelnen Erfahrung erklärt.

Zunächst wird die logarithmierte Wahrscheinlichkeit  $\pi_\theta(a_t|s_t)$  für die gespeicherte Aktion  $a_t$  im State  $s_t$  bestimmt. Dazu wird die, aus dem Memory entnommene, AV und SO durch das Actor- und Critic-Network propagiert. Anschließend wird die logarithmierte Wahrscheinlichkeit der Aktion bestimmt und zusammen mit dem Baseline Estimate und der Entropie der Wahrscheinlichkeitsverteilungen zurückgegeben. Daraufhin wird die Probability Ratio aus der soeben bestimmten logarithmierten Wahrscheinlichkeit und der alten logarithmierten Wahrscheinlichkeit bestimmt ( $r_t(\theta)$ ). Nachfolgend wird der Advantage, durch Subtraktion des Return mit dem Baseline Estimate, berechnet  $\hat{A}_t(s, a) = R_t - b(s_t)$ .

Als Nächstes werden die Surrogate Fehler Surr1:  $r_t(\theta)\hat{A}_t(s, a)$  und Surr2:  $\text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon)\hat{A}_t(s, a)$  bestimmt, mit welchen der Actor Fehler  $L^{\text{CLIP}}(\theta)$  berechnet wird. Um den Gesamtfehler des PPO zu bestimmen, wird zusätzlich noch der Critic Fehler  $L^{\text{VF}}(\theta)$  und der Entropy Fehler bzw. Bonus bestimmt. Diese werden dann alle miteinander verrechnet, entsprechend der Formel:

$$L_t^{\text{PPO}}(\theta) = L_t^{\text{CLIP}} + \text{VF} + \text{S}(\theta) = \hat{\mathbb{E}}_t[L_t^{\text{CLIP}}(\theta) - c_1 L_t^{\text{VF}} + c_2 S[\pi_\theta](s_t)].$$

Actor- und Critic-Network werden dann mit dem Fehler unter Zuhilfenahme von Backpropagation und Gradientenverfahren aktualisiert.

### 5.3.4. Vorstellung der zu untersuchenden Agenten

Ein zentraler Aspekt eines Vergleichs von verschiedenen RL Agenten ist die genaue Definition dieser einzelnen Agenten. Basierend auf den Grundlagen (siehe Abschnitt 2.3 und Abschnitt 2.4), sollen an dieser Stelle die zu vergleichenden Agenten vorgestellt werden.

Da die ausgewählten Hyperparameter einen immensen Einfluss auf das Verhalten der Agenten besitzen, ist ein Vergleich zwischen DQN und PPO Agenten mit wahllos gewählten Hyperparametern folglich wenig aussagekräftig. Darum soll im Weiteren die Auswahl der Hyperparameter begründet werden.

Wie in der Abbildung 5.1 zu erkennen ist, können beliebig viele Agenten miteinander verglichen werden. In dieser Ausarbeitung hingegen sollen sechs Agenten definiert und miteinander verglichen werden (siehe Abbildung 5.7). Dabei sollen die Hyperparameter so gewählt werden, dass stets ein langsamer, ein schneller und ein Hybrid aus beiden zuvor erwähnten Agenten definiert wird.

PPO-01 LR_ACTOR= 2e-4 LR_CRITIC=4e-4 GAMMA=0.99 K_EPOCHS=10 EPS_CLIP=0.15	PPO-02 LR_ACTOR= 1.0e-4 LR_CRITIC=2.0e-4 GAMMA=0.93 K_EPOCHS=12 EPS_CLIP=0.2	PPO-03 LR_ACTOR= 1.5e-4 LR_CRITIC=3.0e-4 GAMMA=0.95 K_EPOCHS=10 EPS_CLIP=0.2	DQN-01 LR= 8.0e-4 GAMMA=0.99 BATCH_SIZE=128 MAX_MEM_SIZE = 2**11 EPS_DEC=3e-5 EPS_END=0.001	DQN-02 LR= 2.0e-4 GAMMA=0.90 BATCH_SIZE=128 MAX_MEM_SIZE = 2**10 EPS_DEC=6e-5 EPS_END=0.005	DQN-03 LR= 2.5e-4 GAMMA=0.95 BATCH_SIZE=128 MAX_MEM_SIZE = 2**11 EPS_DEC=4.0e-5 EPS_END=0.002
--	---	---	---	---	---

Abbildung 5.7.: Darstellung der zu untersuchenden Agenten

Der erste Agent PPO-01 soll ein langsamer, jedoch stetiger Lerner sein. Mit einer Actor Lernrate (Actor) von 2e-4 und einer CRITIC-Lernrate von 4e-4 (Critic) wurden Lernraten gewählt, welche spezifisch für diese Netzstruktur im Mittelfeld liegen. Ein hoher Wert für GAMMA von 0.99 sorgt für ein zukunftsorientiertes Lernen. Damit der PPO-01 keine zu großen Aktualisierungen der Netze unternimmt, wurde EPS\_CLIP auf 0.15 gesetzt, was verglichen mit der Literatur (Schulman u. a., 2017, S. 6) recht niedrig ist.

Der PPO-02 soll ein schnell lernendes Verhalten zeigen. Zu diesem Zweck wurden zwar niedrige Lernraten von 1e-4 (Actor) und 2.5e-4 (Critic) gewählt, jedoch sorgt der relativ große K\_EPOCHS-Wert von zwölf für ein stärkeres Aktualisieren der Netzwerkparameter von Actor und Critic. Der GAMMA-Wert von 0.95 bestärkt zudem den schnelleren Lernerfolg, aufgrund der Kurzzeitpräferenz des Agenten.

PPO-03 soll ein Kompromiss zwischen schnellem Lernen und stetigem Fortschritt sein. Mit mittleren Lernraten von 1.5e-4 (Actor) bzw. 2.5e-4 (Critic) sollte ein schneller und zugleich stetiger Lernfortschritt erzielt werden. Der GAMMA-Wert von 0.95 soll das schnelle Lernen unterstützen. Auch die Werte von K\_EPOCHS mit zehn und EPS\_CLIP von 0.2 werden in der Literatur (Schulman u. a., 2017, Anhang A) empfohlen und stellen ein gutes Mittelmaß dar.

Der DQN-01 ist wieder als langsamer Lerner gedacht. Mit einer großen LR von 8.0e-4 und einem großen GAMMA-Wert von 0.99, wird ein stetiges und zukunftsorientiert Lernen bestärkt. Eine Batch-Size von 128 soll zudem das Lernen beständiger machen. Ein niedriger Wert für EPS\_MIN von 0.001 soll die Neugierde des Agenten zu Beginn stärken und die Wahl von Zufallsaktionen in späteren Trainingsphasen senken.

DQN-02 ist wieder als Schnelllerner konzipiert worden. Eine vergleichsweise hohe Lernrate (LR) von 2.0e-4 in Verbindung mit einem kleinen Wert für Gamma von 0.90 soll einen schnellen Lernfortschritt generieren. Dies wird durch eine normale Memory-Size (MAX\_MEM\_SIZE) von 2\*\*11 und durch eine große Epsilon-

Dekrementierung (EPS\_DEC) von 6e-5 verstrt. Auch sorgt der verhtnismig groe Wert fr EPS\_MIN von 0.0075 fr eine schnellere Exploration und damit fr ein schnelles Lernen.

Der DQN-03 ist wieder als Kompromiss gedacht. Eine kleine Lernrate (LR) von 2.5e-4 und eine groe Epsilon-Dekrementierung (EPS\_DEC) von 4e-5 sind dem schnell lernenden Agenten zuzuordnen. Eine groe Batch- (BATCH\_SIZE) und Memory-Size (MAX\_MEM\_SIZE) von 128 und 2\*\*11 sind dagegen dem langsam lernenden Agenten zuzuschreiben.

## 5.4. Optimierungen

In diesem Abschnitt werden die anzuwendenden Optimierungen vorgestellt, welche nach dem Baseline-Vergleich die Leistung in den einzelnen Evaluationskategorien noch weiter verstren sollen. Zu diesem Zweck sollen zwei Optimierungen auf die Baseline Agenten (Agenten ohne Optimierungen) angewendet werden. Die Erstellung von Optimierung A wurde durch die verwandten Arbeiten Chunxue u. a. (2019) und Wei u. a. (2018) untersttzt. Die Optimierung B wurde nach (Lapan, 2020, S. 331 f.) entwickelt.

### 5.4.1. Optimierung A – Joined Reward Function

Die Joined Reward Function wurde im Paper „Autonomous Agents in Snake Game via Deep Reinforcement Learning“ Wei u. a. (2018) vorgestellt und im Abschnitt 4.1 erklrt. Sie setzt sich aus drei Teilen zusammen. Die Basis bildet ein Distanz Reward, welcher abhngig von der Distanz und Schwanzlnge ist. Um unerwnschte Lerneffekte, von beispielsweise der Neuerzeugung eines Apfels, zu verhindern, werden diese Erfahrungen nicht im Memory gespeichert. Zur Verstrkung des Pathfindings wird die Timeout Strategy angewendet, welche den Agenten fr nicht zielgerichtetes Verhalten, wie z.B. das ziellose Umherlaufen, bestraft.

Eine genaue Implementierung dieser vorgestellten Reward Funktion erscheint jedoch nicht sinnvoll, da bereits in der Diskussion (siehe Unterabschnitt 4.1.1) zur Quelle Wei u. a. (2018) festgestellt worden ist, dass die Agenten nicht fr das effiziente Lsen des Spiels konzipiert worden sind, sondern fr das lange berleben. Daher muss die Reward Funktion entsprechendes Verhalten begnstigen.

Dennoch erscheint die Adaptierung einiger Elemente der Reward Funktion als sinnvoll, um eine eigene auf Performance und Effizienz optimierte Reward Funktion zu

designen.

Die Implementierung dieser neuen Reward Funktion findet in der Reward-Komponente statt. Dabei wird der Distanz Reward der Quelle Wei u. a. (2018) benutzt, da dieser, im Gegensatz zur Standard Reward Funktion (siehe Unterunterabschnitt 5.2.1), viele Faktoren des Spiels berücksichtigt. Dabei wird der Reward wie folgt berechnet:

$$\Delta r(L_t, D_t, D_{t+1}) = \log_{L_t} \frac{L_t + D_t}{L_t + D_{t+1}} \quad (5.2)$$

Wobei  $t$  den vorherigen und  $t + 1$  den aktuellen Zeitpunkt darstellt.  $L_t$  ist die Länge der Snake zum vorherigen Zeitpunkt und  $D_t$  und  $D_{t+1}$  stellen die Distanzen zwischen Snake und Apfel zum vorherigen und aktuellen Zeitpunkt dar.

Dieser Distanz Reward wird wie in Quelle Wei u. a. (2018) dargestellt auf einen Initial-Wert aufaddiert. Nur setzt sich dieser nicht aus den vergangenen Rewards zusammen, sondern ist in dieser Ausarbeitung fest auf -0.01 gesetzt. Zum Schluss wird dann der Reward noch zwischen -0.02 und -0.005 geclipt, damit der Agent stetig bemüht ist den optimalen Weg zu finden ( $r_{res} = clip((-0.01 + \Delta r), -0.02, -0.005)$ ).

#### 5.4.2. Optimierung B – Anpassung der Lernrate

Die zweite Optimierung wurde mithilfe von Anregungen aus der Literatur (Lapan, 2020, S. 331 f.) erzeugt. In dieser wurde die Steigerung der Lernrate diskutiert, um einen schnelleren Lernerfolg zu erzielen. Gegenteilig könnte jedoch die Senkung der Lernrate während des Trainings die Performance und Siegrate verstärken, da die Aktualisierung des NN nicht mehr so stark ausfällt und bestehender Fortschritt damit erhalten bleibt. Darum soll die Lernrate immer dann mit 0.95 multipliziert werden, sobald keine Performance Steigerung in den letzten 100 Epochs bzw. Trainingsspielen erzielt wurde.

### 5.5. Datenerhebung und Verarbeitung

In diesem Abschnitt soll die Datenerhebung näher thematisiert werden. Daher soll zuerst der Hauptablauf näher erklärt werden, welcher Agenten und Env miteinander interagieren lässt. Danach wird die Statistik-Komponente mit ihren Funktionalitäten vorgestellt.

### 5.5.1. Datenerhebung

Die Hauptablaufroutine wird durch die eigentlichen Test- und Trainingsabläufe implementiert, welche wichtige Hyperparameter des Ablaufs, wie z.B. die zu absolvierenden Trainingsspiele (N\_ITERATIONS), die Spielfeldgröße (BOARD\_SIZE) und weitere spezifische Hyperparameter, übergeben bekommen. Um einen angemessenen Zeitraum für das Lernen zu schaffen, sollen 30.000 Spiele bzw. Epochs für einen Trainingslauf absolviert werden. Die Spielfeldgröße soll dabei standardmäßig, für das Training bei (8x8) liegen.

Bei der Datenerhebung ist streng zwischen Test- und Trainingsdaten zu unterscheiden, wobei die Testdaten aus einfachen Spielabläufen bzw. Testläufen und die Trainingsdaten aus den Trainingsläufen stammen. Letztere werden wie folgt erhoben. Zu Beginn werden die Datenhaltungsobjekte apples, wins und steps initialisiert, welche für jedes absolvierte Trainingsspiel die entsprechenden Werte speichert (siehe Tabelle 3.1). Nach der Erstellung des Agenten und Environments startet der Spielverlauf.

Dabei wird wie in Unterabschnitt 2.2.2 vorgegangen. Der Agent erhält eine Obs, bestimmt seine Aktion und diese wird im Env ausgeführt. Danach wird die neue Obs und der neue Reward sowie weitere Statusinformationen ausgegeben. Diese Daten werden im Memory des jeweiligen Agenten für das sich anschließende Training gespeichert, wie im DQN-Lernprozess (siehe Unterunterabschnitt 5.3.2) bzw. PPO-Lernprozess (siehe Unterunterabschnitt 5.3.3) dargestellt. Danach werden die oben genannten Datenhaltungsobjekte aktualisiert und die Prozedur beginnt von Neuem. Wenn alle Epochs (N\_ITERATION) absolviert wurden, werden die erhobenen Daten weiter in der Statistik-Komponente verarbeitet (siehe Unterabschnitt 5.5.2).

Die Datenerhebung für Testdaten findet annähernd auf die gleiche Weise statt, jedoch werden die Daten nicht aus Trainingsläufen entnommen, sondern aus Testläufen. Der Unterschied zwischen Test- und Trainingsläufen besteht darin, dass die Spielfeldgröße im Rahmen des Testlaufes für die Robustheit variiert wird. Sie kann dabei Größen zwischen (6x6) bis (10x10) annehmen. Bei den übrigen Evaluationskriterien bleibt das Spielfeld jedoch konstant bei einer Größe von (8x8). Anders als bei Trainingsläufen werden zudem keine 30.000 Epochs durchgeführt sondern nur 5.000. Dies entspricht ungefähr der Größe einer Datenmenge zur Validierung (Goodfellow u. a., 2018, S. 134).

Diese Testdaten werden dann ebenfalls der Statistik-Komponente übergeben (siehe Unterabschnitt 5.5.2). Um die Validität der Statistiken zu garantieren, sollen alle Daten für die Statistiken zweimal erhoben werden. Damit soll der Anforderung der

mehrfachen Datenerhebung entsprochen werden (siehe Unterabschnitt 3.3.1).

### **5.5.2. Datenverarbeitung und Erzeugung von Statistiken**

Nach der Erstellung der Test- und Trainingsdaten für jeden Agenten werden diese entsprechend der Evaluationskriterien (siehe Tabelle 3.2) verarbeitet. Sie werden dabei mit Statistiken und Tabellen abgebildet. Die Verarbeitung der Daten geschieht dabei wie folgt:

Die Performance wird anhand der gefressenen Äpfel gemessen. Es entsteht daher die Äpfel pro Epoch (Spiel) Rate.

Die Effizienz wird durch die durchschnittliche Schrittanzahl pro Apfelanzahl dargestellt.

Die Robustheit wird durch die durchschnittliche Apfelanzahl pro Spielfeldgröße dargestellt. Die Spielfeldgröße variiert dabei zwischen (6x6) und (10x10).

Die Siegrate wird mithilfe der wins bestimmt. Dazu wird jedem Sieg eine eins und jedem Verlust eine null zugeordnet. Damit lässt sich dann die Siegrate bestimmen. Diese Daten werden dann mithilfe von Statistiken und Tabellen ausgewertet, welche aus den mehrfachen Erhebungen stammen. Dazu sollen diese bei der Auswertung gemittelt werden, um jeweils eine Statistik bzw. Tabelle für jedes Evaluationskriterium zu erhalten. Weitere Details zur statistischen Auswertung befinden sich in der Evaluation (siehe Unterabschnitt 7.2.3).

# Kapitel 6

## Implementierung

In diesem Kapitel soll die Implementierung des Spiels Snake, der beiden Algorithmen, der Ablaufroutinen sowie der Statistik Erzeugung thematisiert werden. Als Programmiersprache wurde Python (3.7) gewählt, da diese über viele Frameworks im Bereich Machine Learning verfügt. In dieser Implementierung wird das Machine Learning Framework PyTorch (<https://pytorch.org/>) verwendet.

### 6.1. Snake Environment

Zur Implementierung des Spiels Snake wurde das Framework gym von OpenAI genutzt (siehe <https://gym.openai.com/>). Eine Darstellung der Implementierung findet sich in der Abbildung A.1. Das Snake Environment implementiert entsprechend der Anforderung 3.1.1 drei zentrale Methoden, welche für den Informationsaustausch mit dem Agenten sorgen.

Die step Methode (siehe Abbildung 6.1) wird in der Ablaufprozedur (Test- bzw. Trainingsmethode) aufgerufen. Um eine Aktion auszuführen, ruft diese die action Methode auf. Diese führt die Aktion aus und manipuliert damit das SnakeGame. Nach dem Aufruf von action wird die nächste Obs mithilfe der make\_obs Methode bestimmt. Im Anschluss werden zudem noch der Reward sowie weitere Statusinformation gebildet und zurückgegeben (siehe Abbildung 6.1).

Die reset Methode (siehe Abbildung 6.1) wird zu Beginn des Spielablaufs aufgerufen, um eine initiale Obs zu erhalten. Sie setzt dazu den momentanen Spielfortschritt zurück und generiert eine neue Obs (siehe Unterunterabschnitt 5.2.1).

Die render Methode (siehe Abbildung 6.1) aktualisiert die GUI, indem diese die updateGUI Methode aufruft. Sie kann nur in Testläufen aufgerufen.

Da die action Methode die eigentliche Aktionsausführung implementiert, wird diese noch näher erläutert (siehe Unterunterabschnitt 5.2.1). Die Spiellogik ist haupt-

sächlich in der action Methode implementiert (siehe Unterunterabschnitt 5.2.1). Ein schematischer Ablauf der action Methode ist in Abbildung 6.2 dargestellt.




Abbildung 6.1.: Darstellung der Schnittstellenmethoden step, reset und render in einem Sequenzdiagramm

Zu Beginn wird geprüft, ob die maximale Anzahl an Schritten ohne einen Apfel gefressen zu haben überschritten ist. Sollte dies der Fall sein, so wird `is_terminal` gesetzt und die Methode terminiert. Andernfalls wird die Aktion umgesetzt, indem die `Player.direction` angepasst wird. Diese gibt die Laufrichtung für den nächsten Schritt an. Daraufhin wird überprüft, ob der neue Kopf außerhalb des Spielfelds liegt. Wenn dies zutrifft, wird das Spiel terminiert. Ansonsten wird der neue Kopf in die Liste aller Snake-Glieder (`Player.tail`), eingepflegt. Sollte die Snake zu diesem Zeitpunkt das gesamte Spielfeld ausfüllen, so hat sie gewonnen und die Methode terminiert. Ansonsten wird geprüft, ob die Snake im momentanen Schritt einen Apfel gefressen hat. Ist dem so, wird der Apfel entfernt und ein neuer generiert. Zudem wird der `inter_apple_steps` Zähler zurückgesetzt. Hat die Snake keinen Apfel gefressen, wird das letzte Schwanzstück entfernt, um die Illusion von Bewegung zu erzeugen und der `inter_apple_steps` Zähler wird inkrementiert.

Zum Schluss wird `Player.tail` noch auf Duplikate überprüft, um auszuschließen, dass die Snake in sich selbst gelaufen ist. Sind keine vorhanden, wird das Spielfeld (`playground`) mit den Elementen der Snake aktualisiert, andernfalls wird sie terminiert.

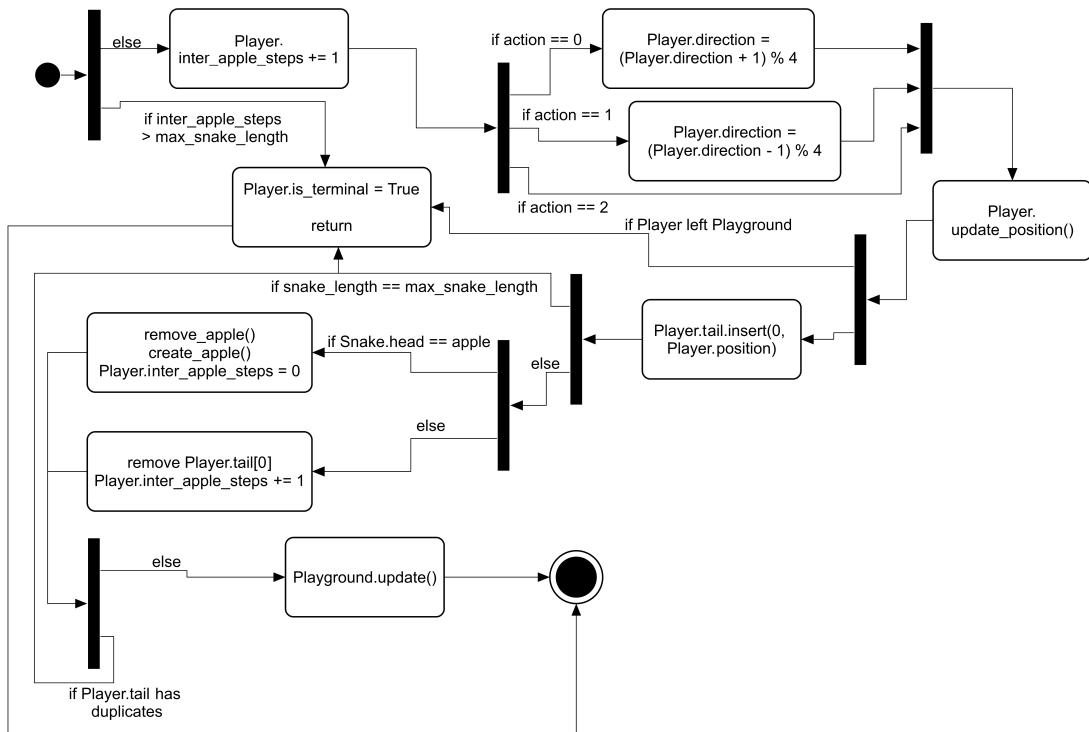


Abbildung 6.2.: Darstellung des Ablaufs der `action` Methode in einem Ablaufdiagramm

## 6.2. AV-Network

Das AV-Network stellt die Netzstruktur dar, welche die AV (around\_view) verarbeitet. Um dies bewerkstelligen zu können, wird das Netz mithilfe des PyTorch Frameworks erstellt. Die Implementierung des NN findet dabei analog zu den Schilderungen in Unterabschnitt 5.3.1 statt. Das AV-Network wird von allen Algorithmen und daher auch von den DQN Agenten genutzt, welche als Nächstes thematisiert werden.

## 6.3. DQN

Die Implementierung des DQN Algorithmus basiert auf Tabor (2020).

Der DQN Algorithmus stellt einen der beiden zu implementierenden Algorithmen dar und beinhaltet die folgenden Klassen (siehe Abbildung A.2):

Die Agent Klasse implementiert die act (siehe Unterunterabschnitt 5.3.2) und learn (siehe Unterunterabschnitt 5.3.2) Methoden. Die Memory Klasse entspricht der Memory-Komponente. Die QNetwork Klasse beinhaltet das NN zur Aktionsbestimmung (siehe Unterabschnitt 5.3.1)) und wird im Folgenden näher thematisiert.

### 6.3.1. Q-Network

Das Q-Network stellt das Instrument zur Bestimmung der Q-Values dar und besteht aus dem AV-Network (AV\_NET) und dem Q-Network-Tail (Q-net) (siehe Unterabschnitt 5.3.1). Es verfügt über eine forward Methode, welche die AV (around\_view) durch das AV\_NET leitet. Danach wird der Output des AV\_NET mit der SO (scalar\_obs) verbunden und durch das Q\_net propagiert. Das Ergebnis wird zurückgeliefert und im Memory gespeichert.

### 6.3.2. Memory

Die Klasse Memory besteht aus einer Reihe von Tensoren, welche Daten mittels einer zusätzlichen Dimension speichern. Das Memory verfügt über eine get\_data Methode, welche einen zufallsbasierten Batch an Erfahrungen zurückliefert. Die im Konzept erwähnte Ring Buffer Funktionalität wird durch einen Zähler realisiert. (siehe Unterabschnitt 5.3.2)

### 6.3.3. Agent

Der DQN Agent besteht aus den act Methoden, welche die Aktionen bestimmen und aus der learn Methode, die für das Training zuständig ist.

#### Aktionsbestimmung

In der Agent Klasse werden die zwei Methoden act und act\_test definiert. Die act Methode wird dabei analog zur Beschreibung im Unterunterabschnitt 5.3.2 implementiert. Die act\_test Methode ist für die Aktionsbestimmung während der Testläufe zuständig und ermittelt Aktionen ausschließlich mittels des Q-Networks.

#### Trainingsroutine

Die learn Methode, welche nach den Darstellungen im Konzept implementiert wurde, stellt die Trainingsroutine dar (siehe Unterunterabschnitt 5.3.2).

Sie überprüft als Erstes, ob das Memory genügend Daten für einen Mini-Batch

besitzt. Ist dem nicht so, terminiert die Methode. Danach wird die `get_data` aufgerufen, welche einen Mini-Batch zurückliefert.

Zu Beginn werden daher die Q-Values der gespeicherten Aktion bestimmt. Im Anschluss folgen die Q-Values aller Aktionen der Nachfolgezustände (siehe Code Listing 6.1).

```
av, scalar_obs, actions, rewards, is_terminal, av_, scalar_obs_, \
    batch_index = self.MEM.get_data()
q_eval = self.Q_NET(av, scalar_obs)[batch_index, actions]
q_next = self.Q_NET(av_, scalar_obs_)
```

Code Listing 6.1: Bestimmung der Q-Values

Daraufhin wird, wie in Gleichung 2.12 und Unterunterabschnitt 5.3.2 dargestellt, Q-Target bestimmt (siehe Code Listing 6.2).

```
q_next[is_terminal] = 0.0
q_target = rewards + self.GAMMA * T. max(q_next, dim=1)[0]
```

Code Listing 6.2: Bestimmung von Q-Target

Zum Schluss wird der Fehler des DQN mit dem MSE (Mean Squared Error) bestimmt und das Q-Net aktualisiert (siehe Code Listing 6.3).

```
loss = self.LOSS(q_target, q_eval)
self.Q_NET.OPTIMIZER.zero_grad()
loss.backward()
self.Q_NET.OPTIMIZER.step()
```

Code Listing 6.3: Bestimmung des DQN Loss & Update des Q-Networks

Zusätzlich wird noch Epsilon verringert, um die Anzahl an Zufallsaktionen während des nächsten Trainingslaufs zu senken.

Neben dem DQN Agenten wurde jedoch noch gefordert (siehe Unterabschnitt 3.2.2), dass ein PPO Agent implementiert wird. Dies geschieht im Folgenden.

## 6.4. PPO

Die Implementierung des PPO basiert auf Barhate (2021) und Tabor (2020).

Der PPO Algorithmus beinhaltet die folgenden Klassen (siehe Abbildung A.2):

Die Agent Klasse definiert die `learn` Methode und ist als PPO-Komponente zu interpretieren (siehe Unterabschnitt 5.3.3). Die Memory Klasse speichert die gesammelten Erfahrungen. Die ActorNetwork und CriticNetwork Klassen beinhalten die

Networks. In der ActorCritic Klasse befinden sich zentrale Methoden zur Durchführung des Lernens, wie z.B. evaluate. Des Weiteren verbindet die ActorCritic Klasse das Actor- und Critic-Network miteinander, welche im nächsten Abschnitt näher betrachtet werden.

### 6.4.1. Actor und Critic

Der Actor bzw. Critic wird durch die ActorNetwork bzw. CriticNetwork Klasse aufgespannt. Neben dem AV-Network wird für den Actor bzw. Critic noch der Actor-Tail bzw. Critic-Tail definiert. Dabei handelt es sich um das Pendant zum Q-Network-Tail (Q-net) (siehe Unterabschnitt 6.3.1).

Die forward Methoden von Actor und Critic sind dabei ebenfalls analog zu der des Q-Network-Tail. Sowohl ActorNetwork als auch CriticNetwork findet man jedoch nur gekapselt in der ActorCritic Klasse vor.

### 6.4.2. ActorCritic

Die ActorCritic Klasse verbindet Actor und Critic miteinander. Sie dient daher als Schnittstelle und definiert die drei Methoden act, act\_test und evaluate.

Diese ist in der Lage, aus ActorNetwork und CriticNetwork ein Gesamtnetzwerk aufzuspannen, welches alle Parameter der beiden Networks enthält. Eine der wichtigsten Aufgaben dieser Klasse ist das Bestimmen von Aktionen.

#### Aktionsbestimmung

Die PPO Agenten verfügen, wie die DQN Agenten, über die zwei Methoden act und act\_test. Die act Methode bestimmt mithilfe des Actors eine Wahrscheinlichkeitsverteilung über alle Aktionen. Daraufhin wird eine Aktion entsprechend dieser bestimmt (siehe Unterunterabschnitt 5.3.3).

Die act\_test Methode verzichtet, wie beim DQN, wieder auf Zufallselemente. Am Ende der act\_test Methode wird die Aktion ausgewählt, welche die größte Wahrscheinlichkeit vorweist.

### 6.4.3. Memory

Das Memory oder auch Replay Buffer genannt, besteht aus einer Reihe von Tensoren, welche die generierten Daten mittels einer zusätzlichen Dimension speichern. Die Rewards und Terminals (is\_terminal) werden jedoch in Listen eingepflegt, da dies das spätere Diskontieren (Abzinsen) erleichtert.

Mit der `get_data` Methode werden die gesamten Erfahrungen der letzten Spielepisoden zurückgegeben.

#### 6.4.4. Agent

Die `Agent` Klasse implementiert die `learn` Methode und verwaltet das `Memory` und zwei `ActorCritic Networks`. Diese stellen die alte und neue Policy dar. Während mit der alten Policy immer die Trainingsdaten generiert werden, wird mit der neuen Policy trainiert. Nach dem Lernen wird die alte Policy mit der neuen aktualisiert.

##### Trainingsroutine

Die hier dargestellte Implementierung basiert auf den Grundlagen des PPO Algorithmus (siehe Abschnitt 2.3) und auf dem Konzept (siehe Unterabschnitt 5.3.3). Als Erstes wird überprüft, ob das `Memory` genügend Erfahrungen besitzt, um ein effektives Lernen durchzuführen. Sollte dies nicht der Fall sein, so wird die Methode terminiert. Ansonsten werden die Daten aus dem `Memory` mit der `get_data` Methode entnommen. Danach werden die Rewards mit der `generate_rewards` Methode diskontiert (abgezinst).

Daraufhin wird die folgende Prozedur  $K\_Epochs$ -mal wiederholt.

Zu Beginn wird die `evaluate` Methode aufgerufen. Diese bestimmt die neuen logarithmierten Wahrscheinlichkeiten (`log_probs`) aller gespeicherten Aktionen. Mit diesen und den gespeicherten alten (`old_log_probs`) werden daraufhin die ratios gebildet. Zuzüglich werden mithilfe der Values, welche ebenfalls von `evaluate` bestimmt wurden, die Advantages erstellt (siehe Code Listing 6.4).

```
probs, state_values, dist_entropy = self.POLICY. \
evaluate(old_av_b, old_scalar_b, old_action_b)
ratios = T.exp(probs - probs_old_b)
advantages = rewards_b - state_values.detach()
```

Code Listing 6.4: Bestimmung der Ratios und Advantages

Mit diesen Werten ist es nun möglich, die Surrogate Fehler und anschließend den Actor Fehler zu bestimmen. In dem Actor Fehler befindet sich zur einfacheren Handhabung noch der Entropy Fehler bzw. Bonus.

```

surr1 = ratios * advantages
surr2 = T.clamp(ratios, 1 - self.EPS_CLIP, 1 + self.EPS_CLIP) * \
advantages
loss_actor = -(T. min(surr1, surr2) + dist_entropy * \
self.ENT_COEFFICIENT).mean()

```

Code Listing 6.5: Bestimmung des Surrogate und Actor Fehlers

Zur Bestimmung des gesamten Fehlers fehlt noch der Critic Fehler, welcher sich aus der Differenz zwischen Returns und den Values des Critics ermittelt. Danach werden Actor und Critic Fehler zusammenaddiert, sodass der PPO Fehler entsteht. Dieser wird dann dazu genutzt, um das Actor\_Critic NN zu aktualisieren (siehe Code Listing 6.5).

```

loss_critic = self.CRITIC_COEFFICIENT * \
self.LOSS(rewards_b, state_values)
loss = loss_actor + loss_critic
self.POLICY.OPTIMIZER.zero_grad()
loss.backward()
self.POLICY.OPTIMIZER.step()

```

Code Listing 6.6: Bestimmung des PPO-Losses und Update der Netze

Zum Schluss wird, nachdem die Prozedur  $K_Epochs$ -mal durchgeführt wurde, die alte Policy mit der neuen aktualisiert. Zuzüglich wird das Memory geleert. Damit jedoch die Lernprozedur aufgerufen wird, benötigt es zentrale Ablaufroutinen, welche in den train und test Methoden implementiert sind.

## 6.5. Train Methoden

Zu Beginn werden Agent und Env zusammen mit den Datenhaltungslisten (siehe Unterabschnitt 5.5.1) erstellt. Ein Scheduler wird für die Optimierung B ebenfalls erzeugt (siehe Unterabschnitt 5.4.2). Danach wird die Trainingsprozedur durchgeführt, welche in Abbildung 6.3 dargestellt ist.

Zu Beginn wird eine Obs bestehend aus AV (around\_view) und SO (scalar\_obs) durch die reset Methode (siehe Unterabschnitt 5.2.2) generiert. Diese Obs wird dem Agenten übergeben, welcher eine Aktion und weitere Daten zurückgibt.

Danach wird die bestimmte Aktion mit der step Methode im Env ausgeführt (siehe Unterabschnitt 5.2.2). Anschließend wird das Memory mit den entstandenen Erfahrungen aktualisiert und die alte Obs wird durch die neue ersetzt.

Sollte die Spielepisode terminieren, so wird die learn Methode des Agent aufgerufen und die generierten Episodendaten werden in die Datenhaltungslisten eingefügt.

Wird die Optimierung B verwendet, so wird alle 100 Spielepisoden die Steigung der Performance der letzten 100 Trainingsspiele bzw. Epochs ermittelt. Sollte diese nicht größer als null sein, so wird die Lernrate mit 0.95 multipliziert.

Sind alle 30.000 Epochs abgeschlossen, werden das NN und die Trainingsdaten gespeichert und die Methode terminiert.

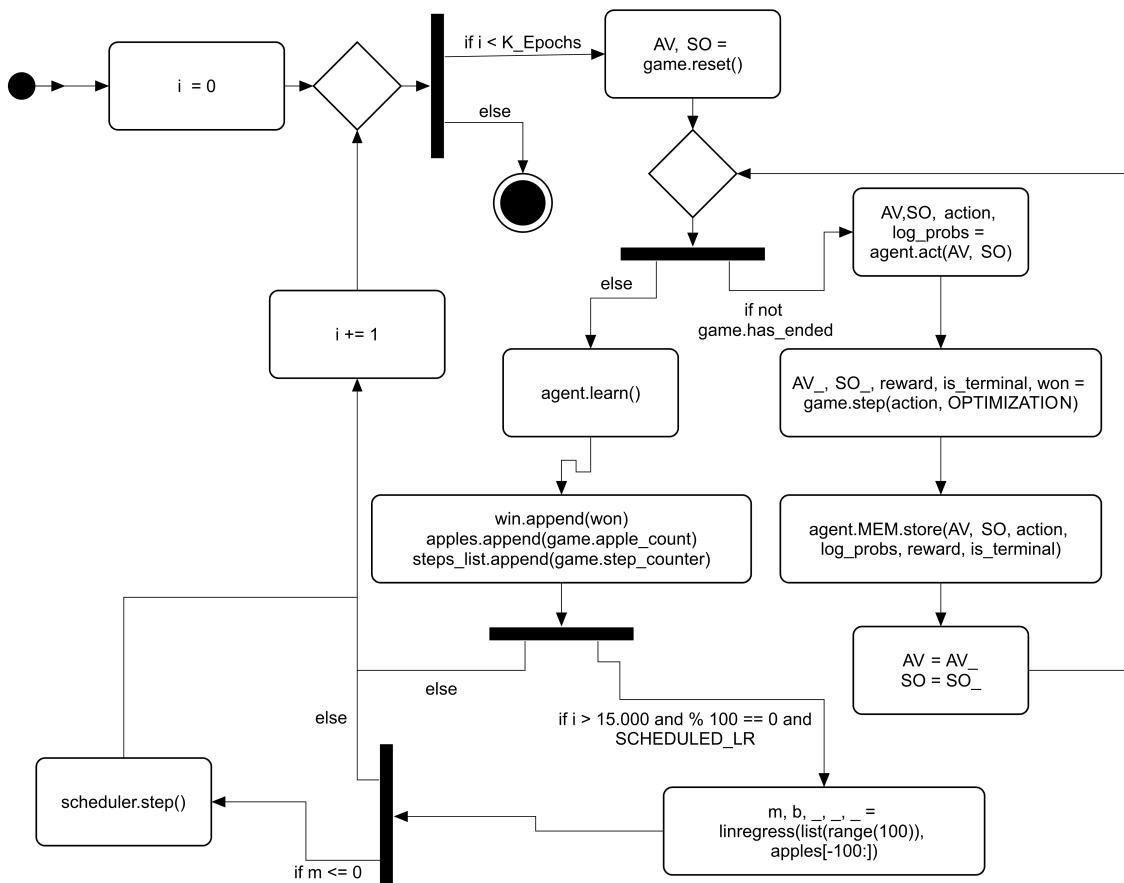


Abbildung 6.3.: Ablaufdiagramm der Train Methode

Neben der train Methode wird jedoch auch eine Testmethode zur Erstellung von Testdaten benötigt.

### 6.5.1. Test Methoden

Die Testmethoden sind bis auf wenige Ausnahmen mit den train Methoden übereinstimmend. Es werden in diesem Abschnitt daher nur die Unterschiede aufgezeigt. Einer dieser Unterschiede ist, dass das NN geladen und nicht erzeugt wird. Mit diesem wird dann der Test durchgeführt. Alle Elemente des Lernens sind aus der test Methode entfernt worden. Zu diesen gehören der Scheduler, das Aufrufen der learn Methode und das Speichern des NNs. Hinzukommt die Prozedur, um die Spielfeld-

größe zu ändern, für die Bestimmung der Robustheit (siehe Unterabschnitt 5.5.2). Des Weiteren wird für die Aktionsbestimmungen nur die `act_test` Methode verwendet und es kommt die Funktionalität der grafischen Umsetzung hinzu. Ansonsten treten keine Unterschiede zwischen den `train` und `test` Methoden auf.

## 6.6. Statistik

Die Statistiken werden mit der `generate_statistic` Funktion erstellt. Zuerst werden alle CSV-Dateien, welche die Test- und Trainingsdaten beinhalten, eingelesen. Dabei findet auch die Mittelung der Daten aus den verschiedenen Datenerhebungen (siehe Unterabschnitt 3.3.1) statt. Danach werden die eingelesenen Daten jedem Agenten zugeordnet und dann der `make_statistics` Methode übergeben, wo die eigentlichen Statistiken generiert und gespeichert werden.

# Kapitel 7

## Evaluation

In diesem Kapitel sollen die Ergebnisse der angewendeten Methodik präsentiert werden. Des Weiteren wird eine Abdeckungsanalyse durchgeführt, um zu beurteilen, welche Anforderungen umgesetzt wurden. Sollen einige nicht umsetzbar gewesen sein, so werden diese erläutert.

### 7.1. Ergebnisevaluation der Vergleiche

In der Evaluation sollen die Ergebnisse, welche aus den Vergleichen stammen, präsentiert werden.

#### 7.1.1. Evaluation der Baseline Vergleiche

Basierend auf dem Vorgehen (siehe Abschnitt 5.1) wird mit den Baseline Vergleichen begonnen. Bei diesen handelt es sich um die Vergleiche, welche von nicht optimierten Agenten (Baseline Agenten) durchgeführt worden sind (siehe Abbildung 5.7)). Diese Agenten wurden in einem Trainingsverlauf, entsprechend der Beschreibung in Unterabschnitt 5.5.1, trainiert. Währenddessen wurden die Trainingsdaten erhoben, die grafisch dargestellt wurden. Als nächster Schritt wurden die Testdaten ermittelt, welche im Folgenden tabellarisch ausgewertet werden mit Ausnahme der Robustheit und Effizienz. Bei diesen bietet sich eine grafische Auswertung der Testdaten an.

#### Performance

Die Baseline Vergleichsauswertung soll mit der Performance beginnen. Dabei ist in der Abbildung 7.1 die durchschnittliche Performance bzw. Apfelanzahl der letzten 200 Epochs pro Epoch abgebildet.

Die DQN Agenten waren in den Vergleichen nicht in der Lage, eine durchschnittliche Apfelsammelrate von 30 Äpfeln pro Spiel zu erreichen. Eine vermutliche Erklärung warum die Agenten des DQN Algorithmus keine guten Leistungen erzielen konnten, liegt in der Wahl von Zufallsaktionen. Die Komplexität des Spiels Snake steigt gegen Ende immer weiter an, da die Snake mit zunehmendem Spielfortschritt keine nicht zielführenden Schritte mehr gehen darf. In einer beengten Spielsituation könnte jeder falsche Schritt zum Tod führen, wobei durch zufällige Aktionen falsche Schritte durchgeführt werden könnten. Dadurch, dass das Spiel immer vorzeitig beendet werden würde, könnte der DQN Agent auch seine Leistung nicht weiter steigern, weil ihm die Daten zum Lernen fehlen würden.




Abbildung 7.1.: Trainingsdatenauswertung der Baseline Vergleiche für die Performance. Die Performance ist als Apfanzahl pro Epoch definiert. Für einen besseren Kurvenverlauf wird die durchschn. Performance der letzten 200 Epochs abgebildet.

Im Training konnten besonders die Leistungen der PPO Agenten PPO-03 und PPO-01 überzeugen. Der PPO-03 kann dabei besonders mit seinem schnellen Lernerfolg punkten, wohingegen der PPO-01 mit seiner annähernd linearen Stetigkeit überzeugen kann.

Agent	Durchschn. Performance	Standardabweichung
DQN-01	17.7812	2.9577
DQN-02	26.4226	4.3482
DQN-03	25.4506	4.8280
PPO-01	44.4544	19.6957
PPO-02	38.7325	11.5756
PPO-03	46.4268	14.0280

Tabelle 7.1.: Testdatenauswertung der Baseline Vergleiche für die Performance

PPO-02 konnte zwar ebenfalls eine fast lineare Steigerung seiner Performance erzielen, jedoch konvergierte dieser früher als der PPO-01. Dieses Verhalten der Agenten entspricht den Darstellungen in Unterabschnitt 5.3.4. Auch die Auswertung der Testdaten (siehe Tabelle 7.1) zeigt den, sich in den Trainingsdaten abzeichnenden, Trend. So erbringt der PPO-03 die beste und der PPO-01 die zweitbeste Leistung. Die Standardabweichungen des PPO-03 und PPO-01 zeigen jedoch, dass die Leistungen nicht konsistent sind. Besonders PPO-01 zeigte eine schwankende Performance, welche auch in den Trainingsdaten (siehe Abbildung 7.1) zu beobachten ist. Daher bleibt der PPO-03 für das Evaluationskriterium der Performance der Sieger. Stark mit der Performance korrelierend, stellt die Siegrate das nächste zu untersuchende Evaluationskriterium dar.

## Siegrate

Ähnlich wie bei der Performance verhält es sich auch mit dem Evaluationskriterium der Siegrate. PPO-03 und PPO-01 besitzen die besten Siegraten während des Trainings (siehe Abbildung 7.2).




Abbildung 7.2.: Trainingsdatenauswerten der Baseline Vergleiche für die Siegrate. Für den besseren Kurvenverlauf wird die durchschn. Siegrate der letzten 200 Epochs abgebildet.

Die DQN Agenten sind nicht in der Lage gewesen Siege zu erreichen und fallen daher aus der Betrachtung heraus. Der PPO-02 zeigt eine deutlich geringe Siegrate, trotz ähnlicher Performances zu den anderen PPO Agenten. Bemerkenswert ist des Weiteren, dass der PPO-03 zwar ähnliche Leistungen wie der PPO-01 erreicht (siehe Abbildung 7.1), jedoch der PPO-01 eine deutlich bessere Siegrate erzielt. Dies ist möglicherweise auf den stetigen Lerncharakter des Agenten zurückzuführen (siehe Unterabschnitt 5.3.4). Auch die Testdaten in Tabelle 7.2 zeigen, dass PPO-01 der

Sieger ist, wobei sich der eben beschriebene Trend aus den Trainingsdaten in den Testdaten widerspiegelt. Daher ist der PPO-01 der Sieger für das Evaluationskriterium der Siegrate.

Agent	Durchschn. Siegrate	Standardabweichung
PPO-01	0.6759	0.33306
PPO-02	0.0926	0.20478
PPO-03	0.3316	0.32751

Tabelle 7.2.: Testdatenauswertung der Baseline Vergleiche für die Siegrate

## Robustheit

Die Robustheit stellt ein besonderes Evaluationskriterium dar, denn sie wird ausschließlich aus Testdaten bestimmt. Diese werden zur besseren Übersicht in eine Grafik überführt. Die Robustheit ist als durchschn. Apfelanzahl dividiert durch die Spielfeldgröße pro Quadratwurzel aus der Spielfeldgröße definiert.

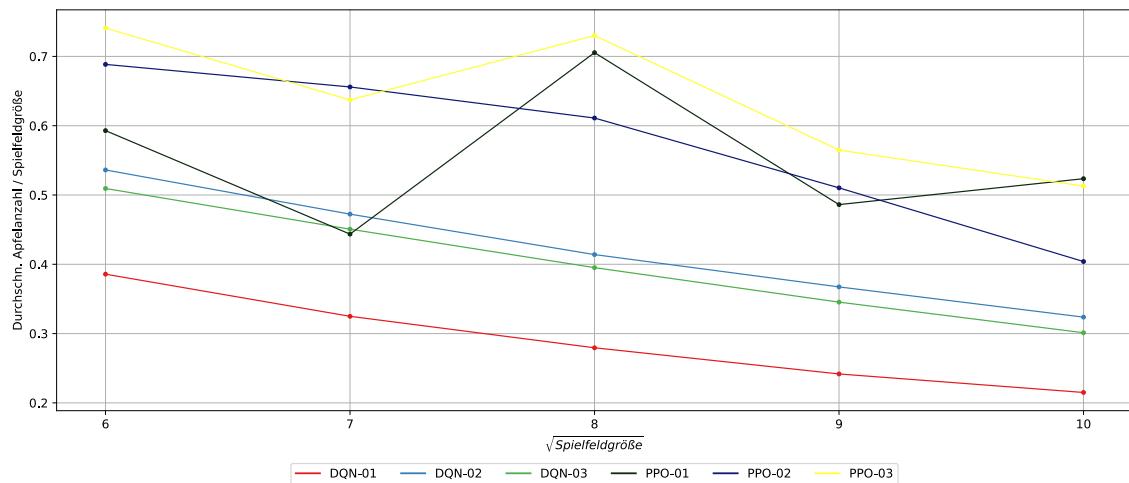


Abbildung 7.3.: Testdatenauswertung der Baseline Vergleiche für die Robustheit. Diese wird als durchschn. Apfelanzahl dividiert durch die Spielfeldgröße pro Quadratwurzel aus der Spielfeldgröße dargestellt.

Wie in Abbildung 7.3 zu erkennen ist, zeigen die DQN Agenten keine guten Resultate. Sie erreichen auf kleineren Spielfeldgrößen bessere Ergebnisse als auf der Standardspielfeldgröße von 8x8. Sollte sich jedoch das Spielfeld vergrößern, so stagnieren ihre Leistungen. Bei den PPO Agenten zeigt sich ein ähnliches Bild. Ihre Leistungen steigen ebenfalls nicht mit dem sich vergrößernden Spielfeld an. Jedoch ist der PPO-03 in der Lage, die besten Ergebnisse in den unbekannten Gebieten zu erzielen.

Bemerkenswert ist des Weiteren, dass sich ein Trend abzeichnet, nachdem Agenten

auf geraden Spielfeldgrößen (z.B. (6x6), (8x8) und (10x10)) bessere Leistungen erzielen können als auf ungeraden (z.B. (7x7) und (9x9)).

Aus diesem Vergleich geht dennoch der PPO-03 Agent als Sieger für das Evaluationskriterium der Robustheit hervor.

## Effizienz

Die Effizienz stellt zusammen mit der Robustheit ein besonderes Evaluationskriterium dar. Sie ist als durchschn. Schrittanzahl pro Apfelanzahl definiert.

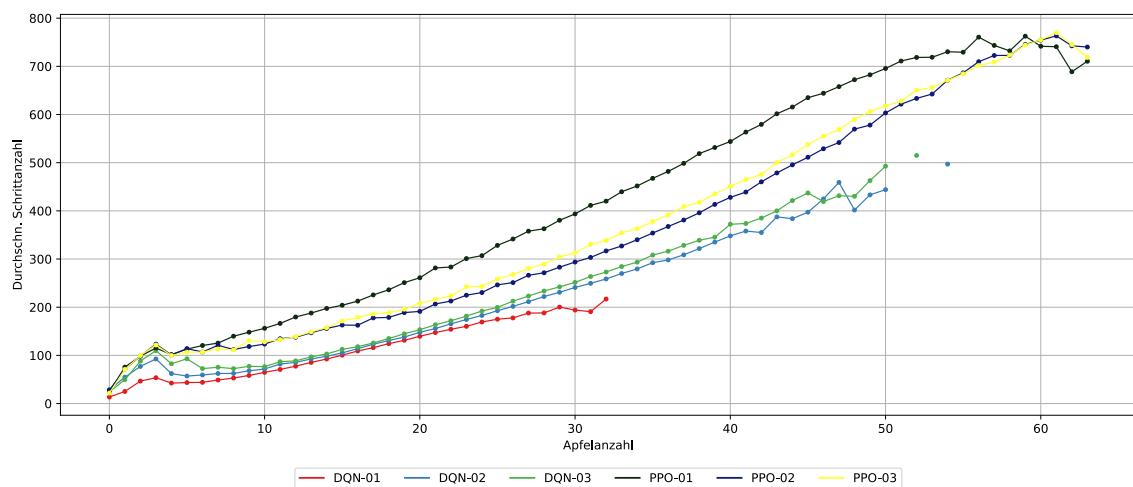


Abbildung 7.4.: Trainingsdatenauswertung der Baseline Vergleiche für die Effizienz. Diese ist als durchschn. Schrittanzahl pro Apfelanzahl dargestellt.

Wie in der Abbildung 7.4 zu erkennen ist, sind DQN-01 und DQN-02 diejenigen, welche die wenigsten Schritte für die jeweilige Apfelanzahl durchführen müssen. Dies gilt jedoch nicht kontinuierlich. Denkbar wäre daher die DQN Agenten in Einsatzgebieten mit wenigen Zielen aber großen Distanzen einzusetzen, sodass der Effizienzcharakter der Agenten hilft beispielsweise Kraftstoff bzw. Energie zu sparen. Eine weitere Betrachtung der DQN Agenten unter dem Kriterium der Effizienz wird jedoch aufgrund der fehlenden Daten nicht durchgeführt. Da die DQN Agenten ausgeschieden sind, bleiben nur noch die PPO Agenten. Diese verfügen über den gesamten Trainingslauf eine solide Effizienz. Der PPO-02 konnte bei der Auswertung der Trainingsdaten die besten Ergebnisse erzielen, gefolgt vom PPO-03.

Erwähnenswert ist ebenfalls, dass die Effizienzdifferenz zwischen den PPO Agenten gegen Ende deutlich abnimmt, da durch die Gesetzmäßigkeiten des Spiels Snake, kaum effizientere Routen zum Apfel zu finden sind.

Auch bei der Auswertung der Testdaten wird dieser Trend deutlich, wobei einzelne Graphen in der Abbildung 7.5 immer wieder Abschnitte besitzen, in welchen der Graph abbricht. Dies bedeutet, dass der Agent eine solche Anzahl an Äpfeln nie

erreicht hat. Das muss nicht negativ angesehen werden.

Die gute Effizienz des PPO-02 kann dabei unter anderem auf den niedrigen Gamma-wert von 0.93 zurückgeführt werden, welcher den Agenten dazu anhält, schnell viele gute Rewards zu erzielen (siehe Unterabschnitt 5.3.4). Da der PPO-02 sowohl in den Trainingsdaten als auch in den Testdaten bessere Ergebnisse als seine Konkurrenten aufweist, ist dieser der Sieger des Evaluationskriteriums der Effizienz.

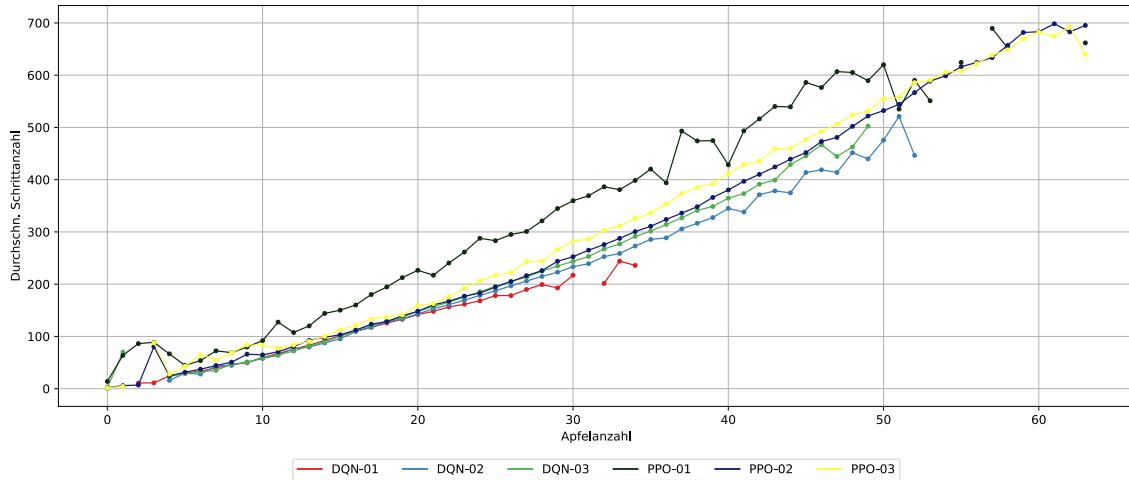


Abbildung 7.5.: Testdatenauswertung der Baseline Vergleiche für die Effizienz.

### 7.1.2. Evaluation der Optimized Vergleiche

Nach der Durchführung der Baseline Vergleiche werden nun entsprechend des Vorgehens (siehe Abschnitt 5.1) die Baseline Gewinner Agenten (siehe Abbildung 5.1) optimiert und dann untereinander verglichen. Dabei ist es auch möglich, sofern sich die Optimierungen nicht gegenseitig ausschließen, die Agenten mit mehr als nur einer Optimierung als zusätzlichen Parameter auszustatten. Dies wird jedoch in dieser Ausarbeitung, trotz der bestehenden Möglichkeit, nicht durchgeführt, um damit die Menge an Agenten nicht zu stark auszuweiten. Dadurch wird eine besser Übersichtlichkeit bei den Auswertungen geschaffen.

Ebenfalls werden die Gewinner der Baseline Vergleiche mit in die Optimized Vergleiche eingebunden. Die Ergebnisse finden sich in den folgenden Abschnitten.

#### Performance

Wie in Abbildung 7.6 zu erkennen ist, sind die Leistungen der einzelnen Agenten sehr unterschiedlich. Alle Agenten, welche auf dem PPO-02 aufbauen (Dunkelgrün, Dunkelblau und Gelb), konnten sich in diesen Vergleichen nicht behaupten und schnitten schlechter als alle anderen ab. Dies könnte mit der Kurzzeitpräferenz, welche durch den niedrigen Gammawert hervorgerufen wird, in Verbindung stehen. Die

Ergebnisse der PPO-01 Agenten (Rot, Hellblau, Hellgrün) liegen im Mittelfeld, mit Ausnahme des PPO-01-opt-b, welcher das zweitbeste Ergebnis erzielen konnte. Im oberen Mittelfeld sind die Agenten, welche vom PPO-03 abstammen. Diese beinhalten auch den Gewinner bezüglich der Trainingsdaten. PPO-03-opt-b konnte seine Leistungen in den letzten 5.000 Trainingsspielen noch verbessern, im Gegensatz zum PPO-01-opt-b.

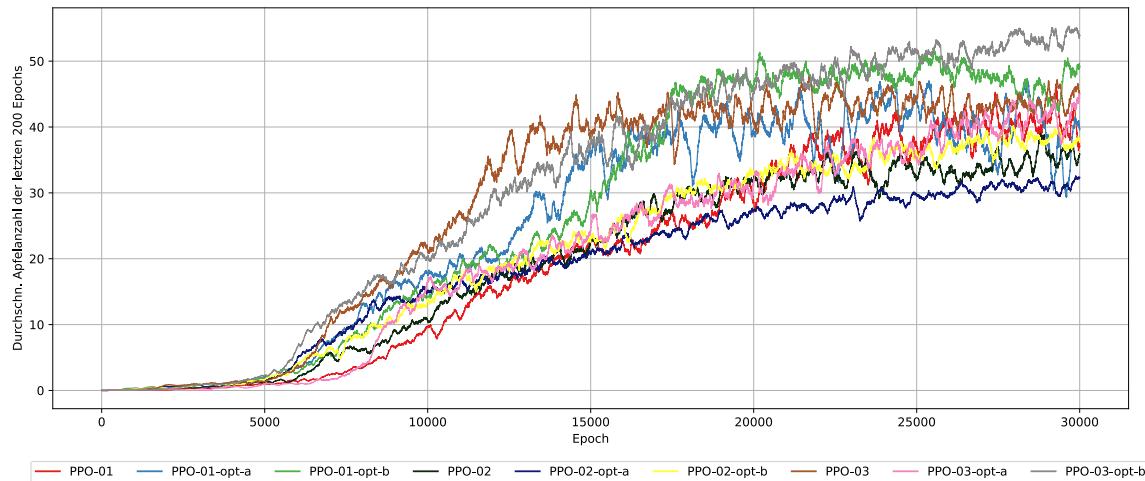


Abbildung 7.6.: Trainingsdatenauswertung der Optimized Vergleiche für die Performance.

Insgesamt schnitten die Agenten mit der Optimierung B immer besser ab als die mit der Optimierung A (PPO-01-opt-a, PPO-02-opt-a, PPO-03-opt-a) und die nicht optimierten (PPO-01, PPO-02, PPO-03). Optimierung A stellte sich unter dem Gesichtspunkt der Performancesteigerung sogar als hinderlich heraus, da die Leistungen der optimierten Agenten entweder ungefähr gleich blieben (siehe die Agenten von PPO-01 und PPO-03) oder schlechter wurden (siehe die Agenten von PPO-02).

Agent	Durchschnittliche Performance	Standardabweichung
PPO-01	44.4544	19.6957
PPO-01-opt-a	45.8125	18.1183
PPO-01-opt-b	45.6213	18.7242
PPO-02	38.7325	11.5756
PPO-02-opt-a	34.8827	6.9273
PPO-02-opt-b	42.5969	12.4416
PPO-03	46.4268	14.0280
PPO-03-opt-a	48.7674	14.9580
PPO-03-opt-b	56.1117	12.3773

Tabelle 7.3.: Testdatenauswertung der Optimized Vergleiche für die Performance

Auch aus den Testdaten (siehe Tabelle 7.3) geht hervor, dass der PPO-03-opt-b der Sieger dieses Vergleichs ist. Mit einer Standardabweichung von 12.3773, welche sich insgesamt im Mittelfeld befindet, zeigt sich jedoch, das der PPO-03-opt-b diese Leistung nicht kontinuierlich erzielen kann. Jedoch bleibt der PPO-03-opt-b, selbst unter Einbeziehung der Standardabweichung der Gewinner im Evaluationskriterium der Performance.

Als nächstes Evaluationskriterium wird die Siegrate, entsprechend der Priorisierung (siehe Abschnitt 5.1), thematisiert.

### Siegrate

Die Siegrate spiegelt ein ähnliches Bild wider, wie bei der zuvor thematisierten Performance (siehe Unterunterabschnitt 7.1.2). Der PPO-03-opt-b konnte auch hier die besten Ergebnisse zeigen (siehe Abbildung 7.7). Die Auswertung der Trainingsdaten zeigt, dass der PPO-03-opt-b mit einem kleinen Vorsprung vor dem PPO-01-opt-b liegt.




Abbildung 7.7.: Trainingsdatenauswertung der Optimized Vergleiche für die Siegrate.

Die PPO-02 Agenten konnten wieder keine guten Leistungen erreichen. Interessant ist jedoch die Tatsache, dass die PPO-03 Agenten mit Ausnahme des PPO-03-opt-b bei den Siegraten eher im unteren Mittelfeld liegen und die PPO-01 Agenten mit Ausnahme des PPO-01-opt-b im oberen Mittelfeld. Dies stellt ein gegensätzliches Verhalten zur Performance dar.

Auch die Auswertung der Testdaten (siehe Tabelle 7.4) zeigt, dass der PPO-03-opt-b der Gesamtsieger des Evaluationskriteriums der Siegrate ist. Mit einer Rate von 0.8466 übertrifft er selbst den Zweitplatzierten PPO-01-opt-b, welcher nur eine Siegrate von 0.7186 erreichte.

Agent	Durchschnittliche Siegrate	Standardabweichung
PPO-01	0.6759	0.3331
PPO-01-opt-a	0.6551	0.3377
PPO-01-opt-b	0.7186	0.3011
PPO-02	0.0926	0.2048
PPO-02-opt-a	0.0001	0.0071
PPO-02-opt-b	0.2354	0.2496
PPO-03	0.3316	0.3275
PPO-03-opt-a	0.5273	0.3479
PPO-03-opt-b	0.8466	0.2482

Tabelle 7.4.: Testdatenauswertung der Optimized Vergleiche für die Siegrate

## Robustheit

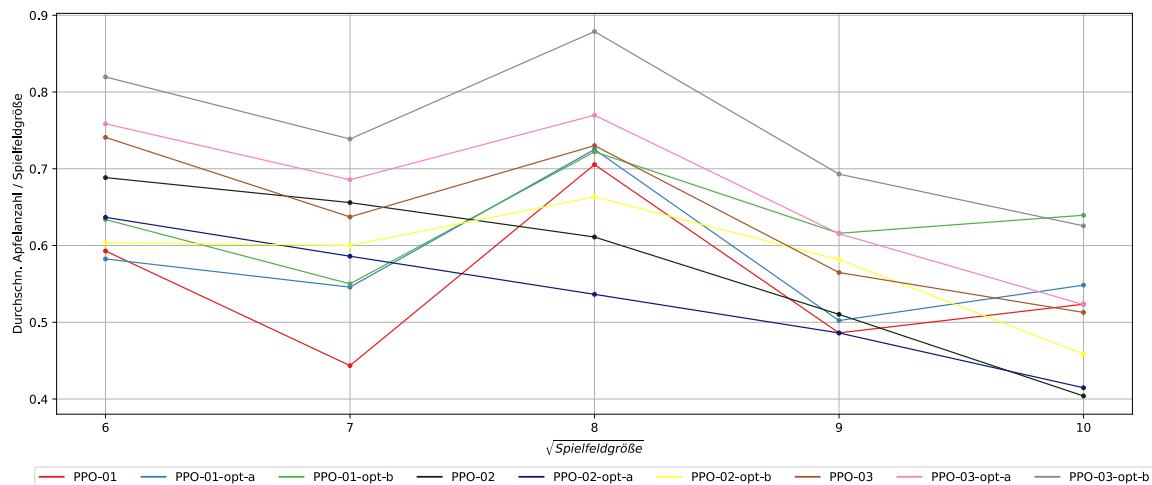


Abbildung 7.8.: Testdatenauswertung der Optimized Vergleiche für die Robustheit.

Die Auswertung der Testdaten zeigt, dass der PPO-03-opt-b der robusteste Agent ist. Von allen wies er die kontinuierlichsten Ergebnisse auf (siehe Abbildung 7.8). So wohl auf größeren als auch auf kleineren Spielfeldern zeigt er eine gute Leistung und damit eine solide Robustheit. Einzig bei einer Spielfeldgröße von (10x10) unterlag er knapp dem PPO-03-opt-a. Interessant ist des Weiteren, dass der PPO-01-opt-b nicht der zweitbeste Agent ist, wie er es in den vorherigen Evaluationskriterien war. Zweitplatzierter in diesen Vergleichen ist der PPO-03-opt-a. Es lässt sich daher vermuten, dass die Robustheit nicht nur primär von der Performance sondern auch von den gewählten Hyperparametern abhängig ist. So könnte der niedrigere Gammawert

der PPO-03 Agenten die Robustheit verstärken.

Zudem ist zu beobachten, dass der Trend aus Unterunterabschnitt 7.1.1 sich auch bei den Optimized Vergleichen zeigt. Es kann daher angenommen werden, dass dieser keinen Zufall darstellt. Weiterhin ist zu vermuten, dass die Strategie der Agenten in irgendeiner Form von der Spielfeldgröße abhängig ist, obwohl diese nicht direkt übergeben wird (siehe Unterunterabschnitt 5.2.1).

## Effizienz

Wie in Abbildung 7.9 zu erkennen ist, benötigt der PPO-02-opt-a die wenigsten Schritte um die jeweilige Apfanzahl zu sammeln. Dieser scheidet jedoch aufgrund seiner unzureichenden Leistungen bzw. Daten aus. Der beste Agent, basierend auf den Trainingsdaten, ist damit der PPO-02 gefolgt vom PPO-03-opt-a. Insgesamt ist jedoch zu bemerken, dass beide Agenten sehr ähnliche Effizienzen besitzen. Der PPO-02 liefert bessere Ergebnisse bei kleineren Apfanzahlen und der PPO-03-opt-a bei größeren. Die Auswertung der Testdaten zeigt auch hier ein ähnliches Bild (siehe Abbildung 7.10).

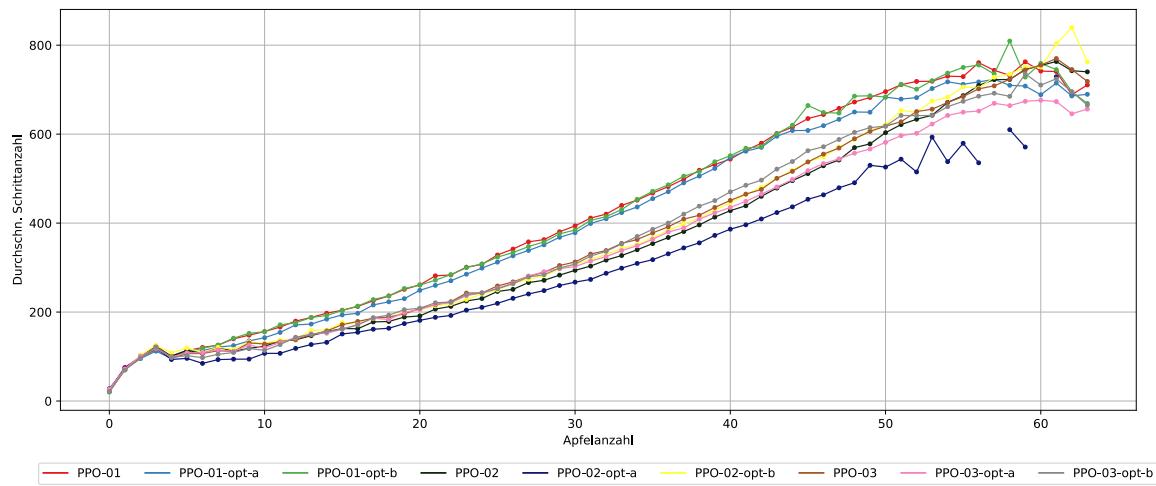


Abbildung 7.9.: Trainingsdatenauswertung der Optimized Vergleiche für die Effizienz.

Wie bereits im Unterunterabschnitt 7.1.1 erwähnt, besitzen die einzelnen Graphen immer wieder Abschnitte, in welchen der Graph abbricht. Dies bedeutet, dass der Agent eine solche Anzahl an Äpfeln nie erreicht hat. Der PPO-03 ist wie zuvor in den Trainingsdaten der Gewinner, gefolgt vom PPO-03-opt-a. Der Sieger dieses letzten Vergleichs soll jedoch trotzdem der PPO-03-opt-a sein, da gerade die Effizienz bei größeren Apfanzahlen von besonderer Wichtigkeit ist. Des Weiteren liegen die Leistungen der Agenten so nahe beieinander, dass die Unterschiede der Leistungen nicht ins Gewicht fallen.

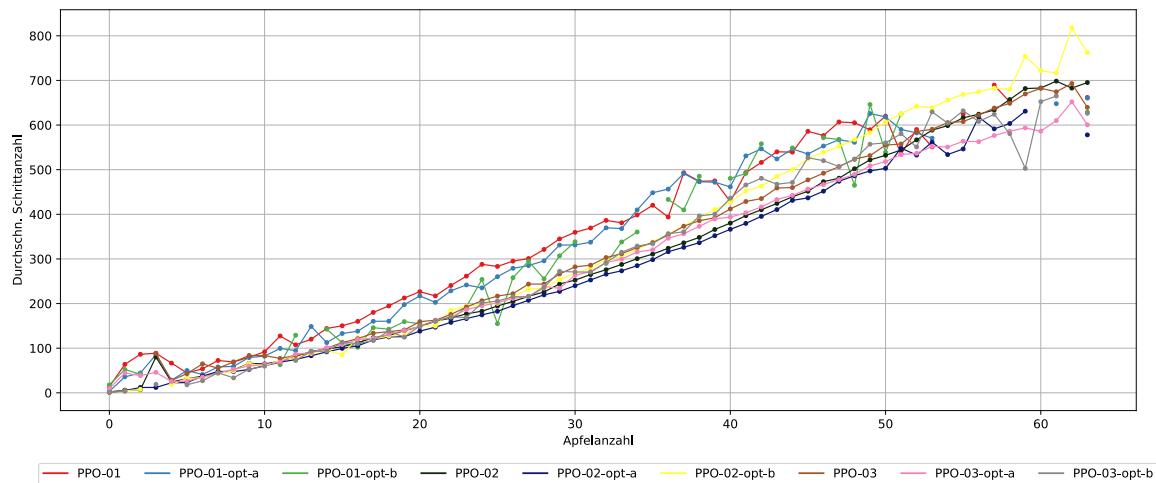


Abbildung 7.10.: Testdatenauswertung der Optimized Vergleiche für die Effizienz.

### 7.1.3. Bestimmung des optimalen Agenten

In diesem Abschnitt soll nun der optimale Agent ermittelt werden. Basierend auf den Ergebnissen der Vergleiche stellt sich heraus, dass der PPO-03-opt-b Agent der optimale Agent ist. Er liefert die besten Resultate in den Evaluationskriterien der Performance, Siegrate und Robustheit. Einzig bei der Effizienz schnitt der Agent mittelmäßig ab. Basierend auf der Priorisierung (siehe Abschnitt 5.1) ist damit der PPO-03-opt-b der Gesamtsieger.

## 7.2. Anforderungsevaluation

Zu Beginn sollen die Anforderungen an das Environment evaluiert werden. Danach folgen die Anforderungsevaluationen der Agenten und Datenerhebung. Zum Schluss soll bewertet werden, ob alle Anforderungen bezüglich der Statistiken und der Evaluation selbst erfüllt worden sind.

### 7.2.1. Anforderungsevaluation der Environment

Die Hauptanforderung an das Env besagt, dass das Spiel Snake implementiert werden soll. Im Rahmen dieser Ausarbeitung wurde das Spiel Snake nach der Beschreibung in Abschnitt 2.1 implementiert. Diese Anforderung kann daher als erfüllt angesehen werden. Eine Darstellung der Implementierung befindet sich im Abschnitt des Konzepts (siehe Abschnitt 5.2) und in der Implementierung (siehe Abschnitt 6.1). Ebenfalls wurde die Anforderung der standardisierten Schnittstelle (siehe Unterabschnitt 3.1.1), welche zu einer Normung und damit zu einer einfacheren Benutzung

des Environments führen soll, erfüllt. Wie in dem Unterabschnitt 5.2.2 und Abschnitt 6.5 zu sehen ist, werden Aktionen durch die step Methoden entgegengenommen und Rewards und Observationen zurückgegeben. Neben der step Methode wird die Observation auch noch durch die Schnittstellenmethode reset geliefert. Diese beiden Methoden spannen die standardisierte Schnittstelle auf.

Auch sind die funktionalen Anforderungen, welche den geregelten Ablauf im Environment garantieren, beachtet worden. So wird die Aktionsausführung (siehe Unterunterabschnitt 3.1.2) durch die action Methode in der SnakeGame Klasse durchgeführt, welche von der Schnittstellenmethode step aufgerufen wird. Die reset und render Anforderungen werden durch die gleichnamigen Schnittstellenmethoden abgedeckt (siehe Unterunterabschnitt 5.2.1 und Abschnitt 6.1).

## 7.2.2. Anforderungsevaluation der Agenten

Der nächste große Anforderungsbereich behandelt die Agenten. Zu diesem Zweck wurden die Anforderungen der Aktionsbestimmung und des Lernens aufgestellt. Diese stellen die grundlegenden Funktionen der Agenten dar. Wie im Konzept dargestellt, wurden sowohl DQN als auch PPO Agenten mit Aktionsauswahlmethoden und einer learn Methode ausgestattet (siehe Kapitel 6). Diese implementieren das geforderte Verhalten aus den Anforderungen 3.2.1. Des Weiteren wurde die Anforderung der Parametrisierung umgesetzt (siehe Abschnitt 7.1), da vom System mehrere Agenten des gleichen Algorithmus erstellt werden können, welche sich durch ihre Hyperparameter unterscheiden (siehe Unterabschnitt 5.3.4).

Neben den funktionalen Anforderungen existiert noch die Anforderung der Diversität der Algorithmen. Diese fordert Vergleiche verschiedener Algorithmen, wobei explizit Agent, die auf den DQN und PPO Algorithmen basieren, miteinander verglichen werden sollen. Diese Anforderung kann ebenfalls als erfüllt angesehen werden, da sowohl ein DQN (siehe Unterabschnitt 6.3.3) als auch ein PPO Agenten (siehe Unterabschnitt 6.4.4) implementiert wurden.

## 7.2.3. Anforderungsevaluation an die Datenerhebung

Auch an die Datenerhebung wurden einige Anforderungen im Rahmen dieser Ausarbeitung gestellt. Zu diesen gehört die Forderung, dass die zu erhebenden Daten mehrfach erhoben werden sollen. Dies soll die Validität der statistischen Untersuchung steigern. Wie im Abschnitt der Datenerhebung (siehe Unterabschnitt 5.5.1) zu sehen ist, werden die auszuwertenden Daten doppelt erhoben.

Daraus lässt sich ebenfalls schließen, dass die Daten für die Statistiken gespeichert wurden. Damit wird die Anforderung der Datenspeicherung erfüllt. Dies wurde darüber hinaus in dem Unterabschnitt 5.5.1 und in der Implementierung (siehe Abschnitt 6.5) dargestellt.

### **7.2.4. Anforderungen an die Evaluation**

In den Anforderungen der Evaluation war gefordert, dass die Evaluationskriterien Performance, Siegrate, Robustheit und Effizienz untersucht werden. Wie im Abschnitt 7.1 zu erkennen ist, wurde genau dies durchgeführt. Weiterhin wird ersichtlich, dass Statistiken zu den einzelnen Evaluationskriterien generiert wurden. Mit Hilfe dieser konnte auf Grundlage der erhobenen Statistiken ein optimaler Agent für jedes Kriterium ausgewählt werden. Weiterhin konnte mit der Auswertung, entsprechend der Forschungsfrage, der optimale Agent zum Lösen des Spiels Snake ermittelt werden.

# Kapitel 8

## Fazit

Im Fazit sollen die Ergebnisse der Vergleiche (siehe Abschnitt 7.1) zusammengefasst und komprimiert dargestellt werden. Des Weiteren wird beurteilt, ob die Forschungsfrage (siehe Abschnitt 1.2) durch die Ausarbeitung beantwortet wurde. Anschließend wird ein Ausblick auf weitere Schritte in diesem Forschungsgebiet gegeben.

### 8.1. Beantwortung der Forschungsfrage

In diesem Abschnitt soll die Beantwortung der eingangs gestellten Forschungsfrage erfolgen. Diese lautet:

**„Wie kann am Beispiel des Spiels Snake für eine nicht triviale gering dimensionale Umgebung ein möglichst optimaler RL Agent ermittelt werden?“**

Da das Wort „optimal“ einen großen Interpretationsspielraum zulässt, wurde sich auf vier Evaluationskriterien konzentriert. Zu diesen zählen die Performance, Siegrate, Robustheit und Effizienz. Für jedes dieser Kriterien wurde der optimale Agent bestimmt (siehe Abschnitt 7.1). Die Forschungsfrage wurde dabei mithilfe einer, im Rahmen dieser Ausarbeitung erarbeiteten, Methodik beantwortet (siehe Abschnitt 5.1). Bei der Erstellung der Agenten besitzt der Anwender prinzipiell eine große Freiheit, nach welchen Gesichtspunkten er die Agenten definiert. In dieser Ausarbeitung wurden die Hyperparameter so ausgewählt das stets ein langsamer, ein schneller und ein Hybrid aus den vorher erwähnten Agenten erstellt wurde. Dies sollte eine große Bandbreite an Möglichkeiten abdecken.

Danach wurden die vordefinierte Agenten im Rahmen der Baseline Vergleiche miteinander verglichen. Diese Baseline Agenten verfügen außer den initialen Hyperparametern keine weiteren und ließen sich mithilfe eines erarbeiteten Konzepts (siehe Kapitel 5), welches als Basis zur Beantwortung der Forschungsfrage dient, durchführen. Auf Grundlage dieses Konzepts wurde eine Implementierung (siehe Kapitel 6)

angefertigt.

Die Baseline Agenten wurde auf Basis der Evaluationskriterien verglichen und der beste (Baseline Winner Agenten) wurde für die Optimized Vergleiche ausgewählt. Für die Baseline Vergleiche waren dies der PPO-03 für die Performance und Robustheit, der PPO-01 für die Siegrate und der PPO-02 für die Effizienz.

In den folgenden Optimized Vergleichen traten die Agenten gegen ihre optimierten Varianten an, entsprechend des Vorgehens (siehe Abschnitt 5.1). Daraus ergab sich, dass der PPO-03-opt-b der optimale Agent für die Kriterien der Performance, Siegrate und Robustheit ist. Einzig bei der Effizienz unterlag dieser dem PPO-03-opt-a, welcher der optimale Agent für die Effizienz ist. Basierend auf diesen Ergebnissen wurde der PPO-03-opt-b zum optimalen Agenten erklärt (siehe Unterabschnitt 7.1.3). Aufgrund dieser Ergebnisse kann die Forschungsfrage als beantwortet angesehen werden.

## 8.2. Ausblick

Nach der Durchführung der Vergleiche, welche zur Bestimmung des optimalen Agenten geführt haben, ergeben sich weiterführende Fragestellungen.

Die DQN Agenten konnten, wie in der Evaluation dargestellt, keine guten Ergebnisse erzielen. Die Vermutung, dass die Wahl von Zufallsaktionen dazu führt, könnte in einer anschließenden Ausarbeitung weiter untersucht werden.

Aber auch bezüglich der Methodik lassen sich noch weitere Untersuchungen durchführen. So würden zusätzliche Vergleiche von weiteren Agenten, die eventuell auch auf anderen Algorithmen basieren, eine gute Erweiterung darstellen.

Möglicherweise könnte auch eine Änderung der Untersuchungsparameter zu veränderten Resultaten führen. Zu diesen Veränderungen könnten beispielsweise die Spielregeln des Spiels Snake, die Evaluationskriterien und die Optimierungen gehören.

Denkbar wäre auch ein praktischer Einsatz der Methodik in RL Anwendungen. Eingangs wurde die Quelle Chunxue u. a. (2019) erwähnt, da diese die Steuerung von unbemannte Drohnen mit RL Agenten thematisiert. Die erhobenen Ergebnisse legen nahe, dass die Wahl eines PPO Agenten zu besseren Resultaten führen würde als die Wahl des im Paper verwendeten DQN Agent.

Denkbar wäre auch die Anwendung des Verfahrens auf Probleme, welche nicht im thematischen Zusammenhang mit dem Spiel Snake stehen, wie z.B. Finanzapplikationen oder Steuerungsprogramme für Roboter.

Aufgrund der Vorgehensweise ist dies einfach möglich, da das Verfahren nicht von der zu lösenden Aufgabe abhängig ist. Zu jedem Problem, welches durch RL Ver-

fahren gelöst werden soll, können mehrere Agenten definiert und mit der Methodik verglichen werden.

Die Möglichkeiten für weiterführende Forschungen auf dem Gebiet der Auswahl von RL Agenten sind zahlreich und diese Arbeit soll einen kleinen Beitrag zu diesem Forschungszweig leisten.

# Literaturverzeichnis

- [Barhate 2021] BARHATE, Nikhil: *Minimal PyTorch Implementation of Proximal Policy Optimization.* <https://github.com/nikhilbarhate99/PPO-PyTorch>. 2021. – Zugriffsdatum 2021-11-01
- [Bowi Ma 2016] BOWEI MA, Jun Z.: *Exploration of Reinforcement Learning to SNAKE.* 2016. – URL <http://cs229.stanford.edu/proj2016spr/report/060.pdf>
- [Chunxue u. a. 2019] CHUNXUE, Wu ; JU, Bobo ; WU, Yan ; LIN, Xiao ; XIONG, Naixue ; XU, Guangquan ; LI, Hongyan ; LIANG, Xuefeng: UAV Autonomous Target Search Based on Deep Reinforcement Learning in Complex Disaster Scene. In: *IEEE Access* PP (2019), 08, S. 1–1. – URL <https://ieeexplore.ieee.org/abstract/document/8787847>
- [Glassner 1989] GLASSNER, Andrew S. (Hrsg.): *An Introduction to Ray Tracing.* GBR : Academic Press Ltd., 1989. – ISBN 0122861604
- [Goodfellow u. a. 2018] GOODFELLOW, Ian ; BENGIO, Yoshua ; COURVILLE, Aaron: *Deep Learning. Das umfassende Handbuch.* MITP Verlags GmbH, 2018. – URL [https://www.ebook.de/de/product/31366940/ian\\_goodfellow\\_yoshua\\_bengio\\_aaron\\_courville\\_deep\\_learning\\_das\\_umfassende\\_handbuch.html](https://www.ebook.de/de/product/31366940/ian_goodfellow_yoshua_bengio_aaron_courville_deep_learning_das_umfassende_handbuch.html). – ISBN 3958457002
- [Haarnoja u. a. 2018] HAARNOJA, Tuomas ; ZHOU, Aurick ; ABBEEL, Pieter ; LEVINE, Sergey: Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor. In: *CoRR* abs/1801.01290 (2018). – URL <http://arxiv.org/abs/1801.01290>
- [Lapan 2020] LAPAN, Maxim: *Deep Reinforcement Learning - Das umfassende Praxis-Handbuch.* MITP Verlags GmbH, 2020. – URL [https://www.ebook.de/de/product/37826629/maxim\\_lapan\\_deep\\_reinforcement\\_learning.html](https://www.ebook.de/de/product/37826629/maxim_lapan_deep_reinforcement_learning.html). – ISBN 3747500366
- [Mnih u. a. 2016] MNIH, Volodymyr ; BADIA, Adrià P. ; MIRZA, Mehdi ; GRAVES, Alex ; LILLICRAP, Timothy P. ; HARLEY, Tim ; SILVER, David ; KAVUKCUOGLU,

- Koray: Asynchronous Methods for Deep Reinforcement Learning. In: *CoRR* abs/1602.01783 (2016). – URL <http://arxiv.org/abs/1602.01783>
- [Mnih u. a. 2013] MNIH, Volodymyr ; KAVUKCUOGLU, Koray ; SILVER, David ; GRAVES, Alex ; ANTONOGLOU, Ioannis ; WIERSTRA, Daan ; RIEDMILLER, Martin A.: Playing Atari with Deep Reinforcement Learning. In: *CoRR* abs/1312.5602 (2013). – URL <http://arxiv.org/abs/1312.5602>
- [Mnih u. a. 2015] MNIH, Volodymyr ; KAVUKCUOGLU, Koray ; SILVER, David ; RUSU, Andrei A. ; VENESS, Joel ; BELLEMARE, Marc G. ; GRAVES, Alex ; RIEDMILLER, Martin ; FIDJELAND, Andreas K. ; OSTROVSKI, Georg ; PETERSEN, Stig ; BEATTIE, Charles ; SADIK, Amir ; ANTONOGLOU, Ioannis ; KING, Helen ; KUMARAN, Dharshan ; WIERSTRA, Daan ; LEGG, Shane ; HASSABIS, Demis: Human-level control through deep reinforcement learning. In: *Nature* 518 (2015), Februar, Nr. 7540, S. 529–533. – URL <http://dx.doi.org/10.1038/nature14236>. – ISSN 00280836
- [Schulman 2017] SCHULMAN, John: *Deep RL Bootcamp Lecture 5: Natural Policy Gradients, TRPO, PPO*. Oktober 2017. – URL <https://www.youtube.com/watch?v=xvRrgxcpaHY>. – Zugriffsdatum 2021-11-01
- [Schulman u. a. 2015] SCHULMAN, John ; LEVINE, Sergey ; MORITZ, Philipp ; JORDAN, Michael I. ; ABBEEL, Pieter: Trust Region Policy Optimization. In: *CoRR* abs/1502.05477 (2015). – URL <http://arxiv.org/abs/1502.05477>
- [Schulman u. a. 2017] SCHULMAN, John ; WOLSKI, Filip ; DHARIWAL, Prafulla ; RADFORD, Alec ; KLIMOV, Oleg: Proximal Policy Optimization Algorithms. In: *CoRR* abs/1707.06347 (2017). – URL <http://arxiv.org/abs/1707.06347>
- [Shannon 1948] SHANNON, Claude E.: A Mathematical Theory of Communication. In: *The Bell System Technical Journal* 27 (1948), S. 379–423. – URL <http://plan9.bell-labs.com/cm/ms/what/shannonday/shannon1948.pdf>. – Zugriffsdatum: 2021-11-01
- [Sutton und Barto 2018] SUTTON, Richard S. ; BARTO, Andrew G.: *Reinforcement Learning: An Introduction*. Second. The MIT Press, 2018. – URL <http://incompleteideas.net/book/bookdraft2018jan1.pdf>
- [Tabor 2020] TABOR, Phil: *Youtube-Code-Repository*. <https://github.com/philtabor/Youtube-Code-Repository/tree/master/ReinforcementLearning/PolicyGradient/PPO/torch>. Dezember 2020. – Zugriffsdatum 2021-11-01

- [Wei u. a. 2018] WEI, Zhepei ; WANG, Di ; ZHANG, Ming ; TAN, Ah-Hwee ; MIAO, Chunyan ; ZHOU, You: Autonomous Agents in Snake Game via Deep Reinforcement Learning. In: *2018 IEEE International Conference on Agents (ICA)*, URL [https://www.researchgate.net/publication/327638529\\_Autonomous\\_Agents\\_in\\_Snake\\_Game\\_via\\_Deep\\_Reinforcement\\_Learning](https://www.researchgate.net/publication/327638529_Autonomous_Agents_in_Snake_Game_via_Deep_Reinforcement_Learning), 2018, S. 20–25

# Anhang A

## Anhang

### A.1. Implementierung

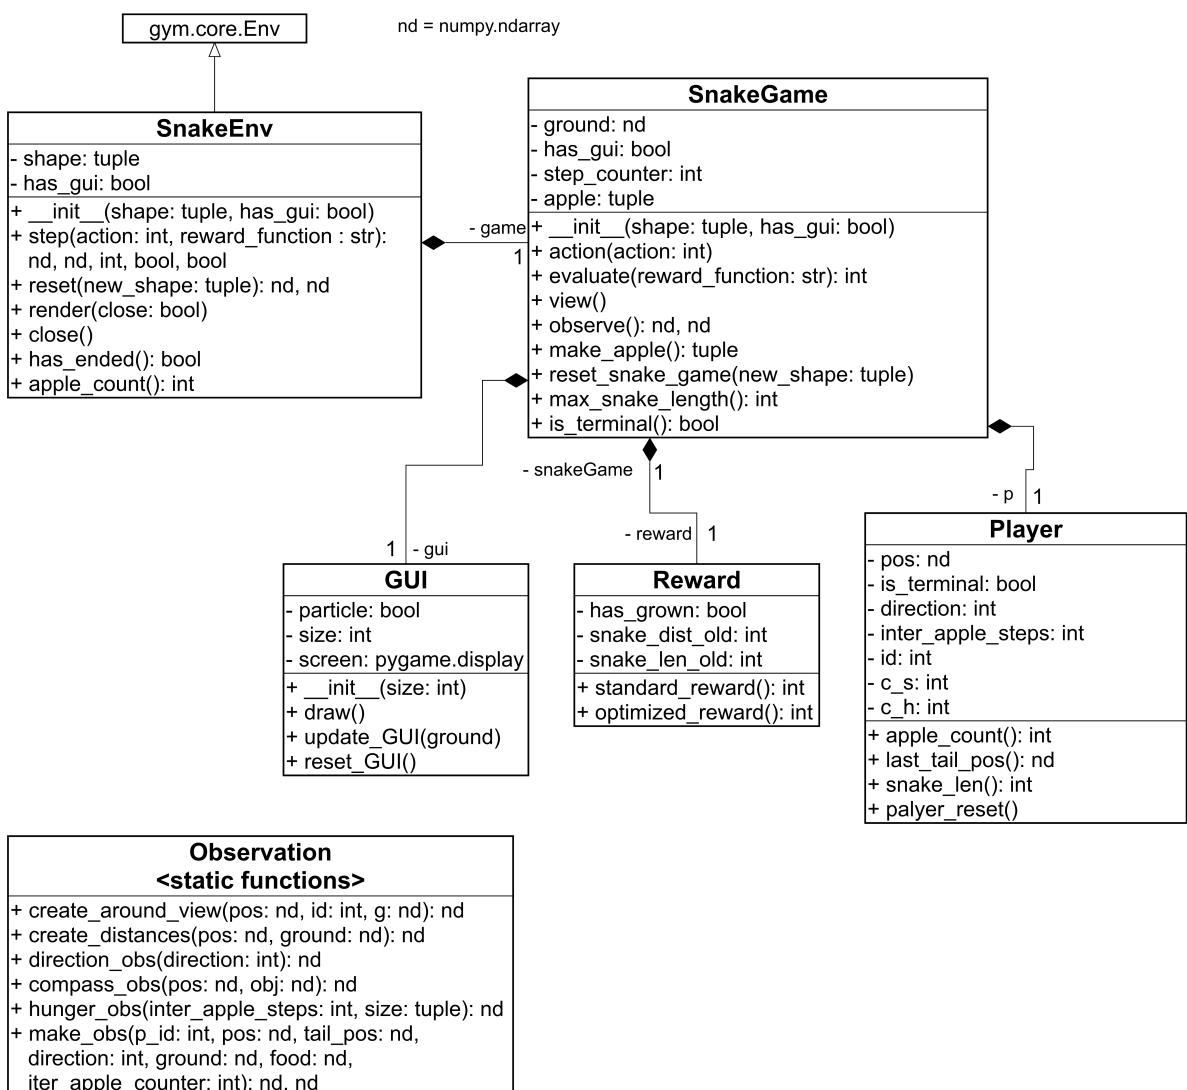


Abbildung A.1.: SnakeEnv

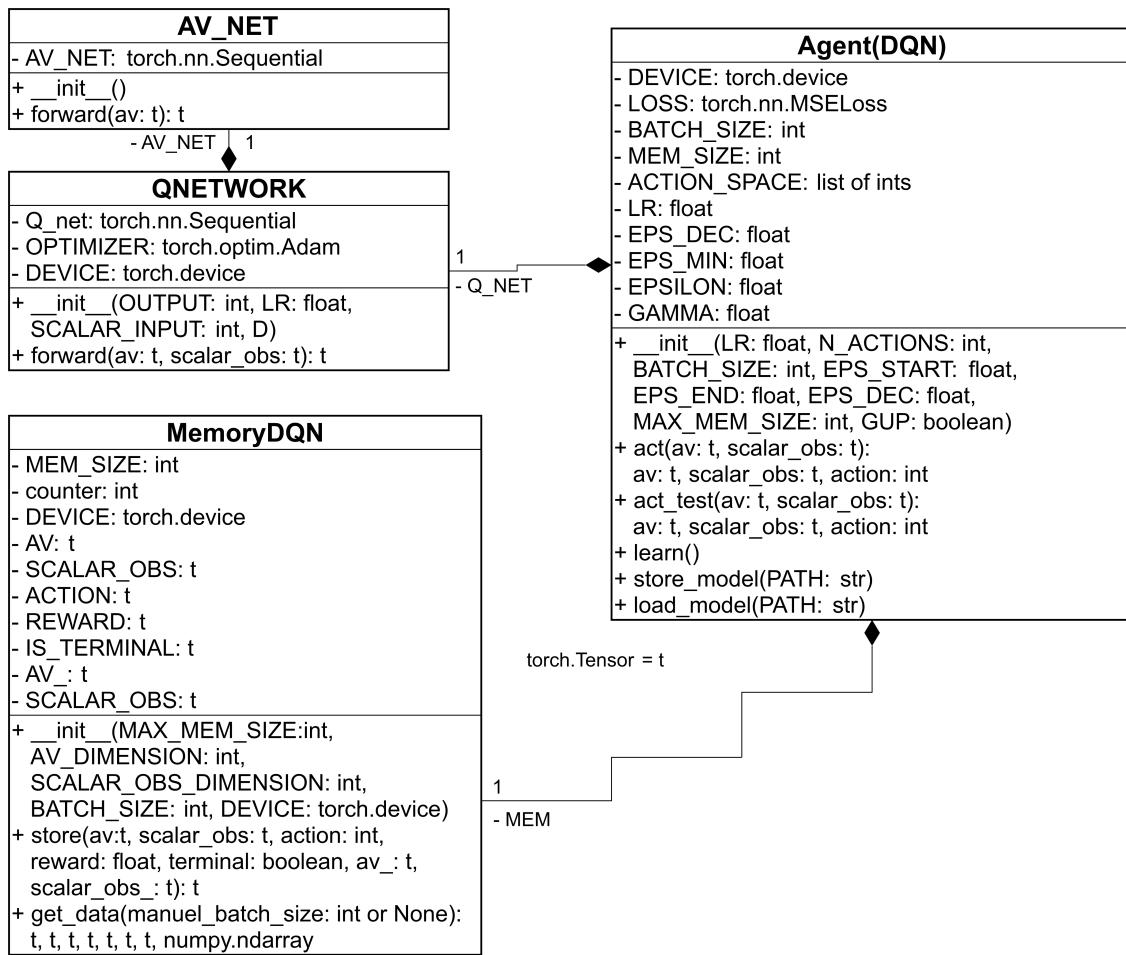


Abbildung A.2.: DQN Klassendiagramm

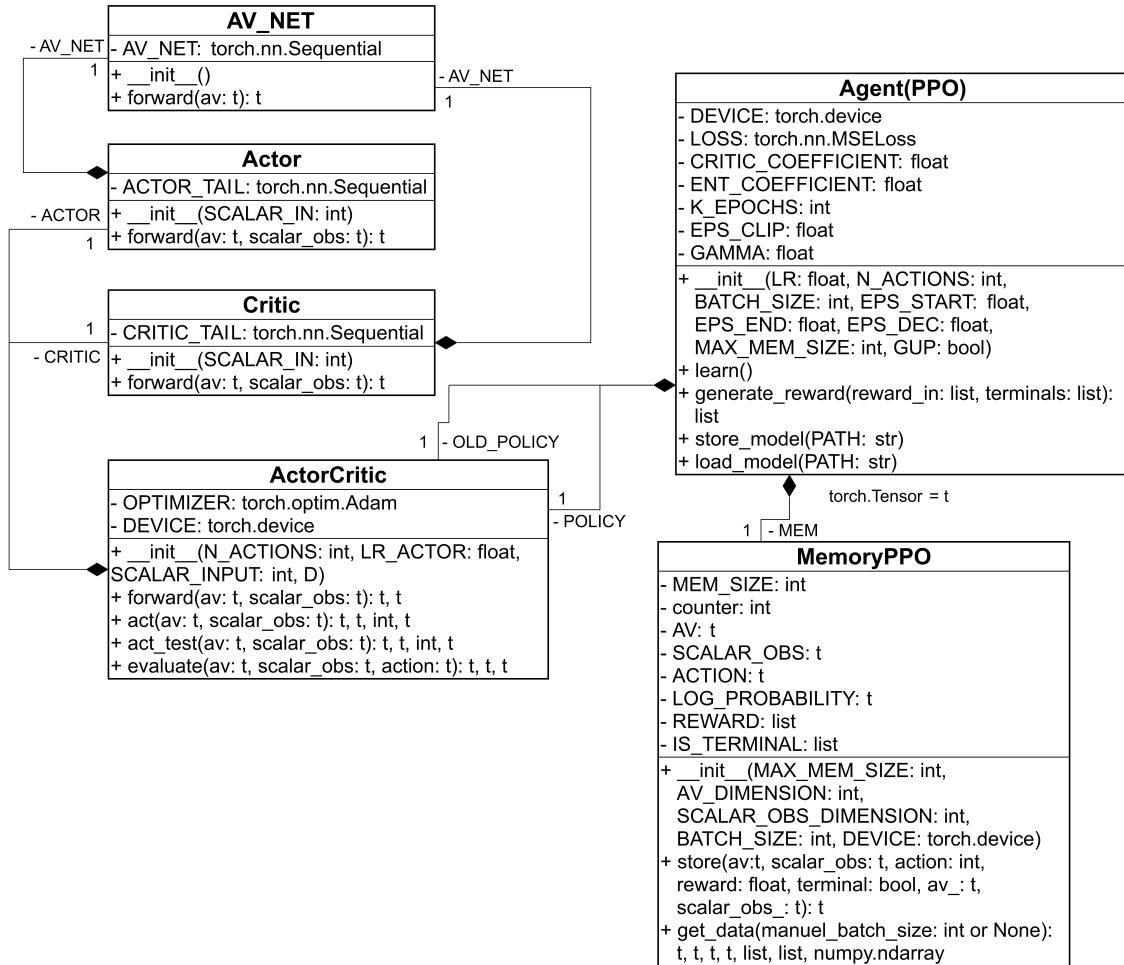


Abbildung A.3.: PPO Klassendiagramm

# **Erklärung**

Hiermit versichere ich, Lorenz Mumm, dass ich diese Arbeit selbständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Außerdem versichere ich, dass ich die allgemeinen Prinzipien wissenschaftlicher Arbeit und Veröffentlichung, wie sie in den Leitlinien guter wissenschaftlicher Praxis der Carl von Ossietzky Universität Oldenburg festgelegt sind, befolgt habe.

---

Lorenz Mumm